

속도는벡터 → 임채림 연구원님 — 본 연구 측정 데이터 정리

수신: 임채림 연구원 (BDAI 연구실) 발신: 속도는벡터 (박세은 팀장 경유 · 조현빈 작성) 작성: 2026-05-24 목적: 본 연구 (Exqutor §V-B 표본 선택 단계 controlled verification) 의 실험 환경·핵심 측정값·우리가 시도한 방법 중 가장 정확한 것·그 method 의 실제 엔진 효과·메커니즘 규명·학술 정직성·한계 정리. 본 자료의 모든 수치는 Claude·Codex·Gemini 3 모델로 적대 검증을 거친 정보이다.

1. 본 연구의 핵심 질문 한 줄

인덱스가 없는 상황에서 Exqutor 논문의 적응적 표본 추출(§V-B) 의 "표본 선택 단계" 를 무작위 베르누이에서 분포 인지 총화로 바꾸면, 카디널리티 추정이 더 정확해지는가?

본 자료는 이 질문에 대한 실험 환경·핵심 측정값·결론을 5 항목으로 정리한다 — (가) 측정한 베이스라인의 정확도와 응답 시간, (나) 우리가 시도한 16 방법 중 가장 정확한 것의 값과 알고리즘, (다) 그 방법의 실제 엔진 응답 시간과 plan 회복, (라) 89% 우위의 진짜 메커니즘을 규명한 통제 측정, (마) 측정의 한계.

2. 실험 환경

2.1 서버 하드웨어

항목	값
호스트	BDAI 연구실 서버 165.132.140.240 (계정 capstone2026)
CPU	Intel Xeon Gold 6530 · 128 vCPUs
RAM	1.0 TB
GPU	4× NVIDIA RTX 6000 Ada 49 GB (본 측정은 CPU 만 사용)
Disk	/mnt/hdd0 13 TB
PostgreSQL	Exqutor patched pgvector · 포트 55435 · DB wns41559
OS·환경	Linux + tmux 다중 세션

본 연구의 측정 환경은 Exqutor 논문의 측정 환경과 동일하다 ("Intel Xeon Gold 6530 with 128 vCPUs and 1.0 TB of RAM", arXiv:2512.09695v2 §VI verbatim).

2.2 데이터셋

5 개 단일 벡터 데이터셋 + 다중·연접(concat) 조합:

데이터셋	차원	서버 테이블
DEEP	96	partsupp_deep_{1,10,100}
SIFT	128	partsupp_sift_{1,10,100}
SimSearchNet++ (SSN)	256	partsupp_fb_{1,10,100} (alias: SSN ↔ fb 서버 명칭)
WIKI	768	partsupp_wiki_{1,10}
YFCC	192	partsupp_yfcc_{1,10}
다중 (DEEP+SIFT 등)	224·288·864·1024	(직접 연접)

2.3 측정 평면 (1,508 측정 portfolio)

변인	값
TPC-H 분석 쿼리	Q3·Q9·Q10·Q12 (벡터 술어가 SeqScan 분기에서 평가)
Scale Factor	1 · 10 · 100
거리 임계값 D 의 selectivity	0.001 · 0.01 · 0.10
총화 수 K	10 · 20 · 30
표본 선택 method	16 종 (7 paradigm 대표)
측정 mode (3-way matched)	베이스라인 (B1, 논문 그대로) · 단독 대체 (분포 인지 표본 통째 치환) · 결합 (두 추정값 산술 평균)
trials per 측정	10 회 반복 × 1,000 queries per trial
총 측정 수	1,508 측정 portfolio (각 측정 = 3 mode matched, 합 4,524 행)

본 portfolio 는 의도된 구조화 분할로, 완전 요인 설계 (max 3,600) 의 약 42% 다. $K=20 \cdot sel=0.01$ 중심으로 측정 밀도를 두텁게 두었다.

2.4 Adaptive Sampling Hyperparam (논문 §V-B verbatim 그대로 carry)

변수	값	의미
N	385	초기 표본 예산 (식 1: $\lceil 1.96^2 \cdot 0.25 / 0.05^2 \rceil = 385$)
m	0.9	momentum coefficient (식 4)
η_0	0.1	초기 학습률 (식 4)
α	50	target Q-error 가중치 (식 3)
β	1.5	target Q-error (식 3)
γ	0.99	학습률 감쇠 (식 6)
update_period	50 queries	표본 크기 갱신 주기

본 연구는 위 hyperparam·식 1-6 을 모두 그대로 두고 표본을 어디서 뽑을 것인가 하는 한 단계만 변경했다.

3. Exqutor 베이스라인 (B1) 측정 결과

3.1 카디널리티 추정 정확도

- 1,508 측정 × 베이스라인 mode 의 Q-error trim mean = **1.4582**
- median 1.5616 · std 0.1925 · range [1.15, 1.66]

(Q-error 정의: 식 2 verbatim — $q = \max(C_est/C_true, C_true/C_est)$, 1.0 이 완벽, 작을수록 정확)

3.2 실제 엔진 응답 시간 (DEEP sf=10, 12 셀 × 15 회 반복)

조건	응답 시간 (median, 12 셀 평균)	가속 배수
기본 pgvector (카디널리티 미주입)	5,677 ms	1.0× (기준)
Exqutor 베이스라인 inject	978 ms	5.77×
정답 카디널리티 inject (oracle)	992 ms	5.65×

본 연구의 12 셀 측정에서 베이스라인이 기본 pgvector 대비 **평균 5.77 배 가속** 을 달성한다 (보고서 §5.2 trim mean 기준 12 셀 oracle 가속 평균 5.67×, 범위 2.93~7.40×).

3.3 정답 plan 회복

- 12 셀 중 베이스라인이 정답 plan 으로 회복한 수: **7/12 = 58.3%** (셀 단위)
- qid 별: qid 0 = 0/4 · qid 1 = 4/4 · qid 2 = 3/4

- 회복 실패 cell 은 sel=0.001 의 결정 경계 cell (베르누이 적중 0 회 시 측정 harness 가 MIN_INJECT=1.0 으로 강제 보정, 클램프된 1.0 이 planner 결정 경계 가까이 떨어져 plan 이 갈림 — 이는 \$V-B 베르누이가 극단 selectivity 에서 마주치는 실패 모드의 정직한 노출이다).

3.4 통계 검정 — 베이스라인 가속의 견고성

- paired Wilcoxon 부호 순위 검정 + Holm-Bonferroni 보정 (anchor=기본 pgvector, 180 비교): **180/180 = 100% 유의** + 100% large effect (Hedges' $g \geq 0.8$)
- 베이스라인 가속은 통계적으로 압도적·견고하게 확정된다.

4. 우리가 시도한 16 방법 중 가장 정확한 method

4.1 정확도 ranking 상위 5 (paired vs 베이스라인 기준)

Method (정정 후 명칭)	알고리즘 한 줄 설명	paired better%	median Δ% (개선 폭)
chao_weighted	Chao 1982 가중 우선순위 sampling: 각 벡터에 norm·PCA·iDistance 가중치 w 부여 후 priority $u_i^{1/w}$ 의 quantile 분할	100.0%	-6.22%
pca2d_hilbert_xy2d	PCA 로 2 차원 환원 후 Wikipedia 표준 xy2d Hilbert curve algorithm 으로 1D 순서 분할	98.9%	-5.91%
pca4_skilling_hilbert_approx	PCA 로 4 차원 환원 후 Skilling 2004 알고리즘 근사 (4-axis × 8-bit Hilbert key, exact swap 일부 생략)	100.0%	-5.75%
ica_fastica	Hyvärinen 1999 FastICA 의 독립 성분 분석 1D 투영 후 quantile 분할	100.0%	-5.69%
pca1d	Pearson 1901 PCA 의 첫 주성분 1D 투영 후 quantile 분할	97.9%	-5.55%

★ 본 연구의 최저 Q-error method = **chao_weighted** (Chao 1982)

알고리즘 본질: 각 벡터에 가중치 w_i (L2 norm·PCA 1D 절대값·KMeans iDistance 중 하나) 를 부여하고, 균등 무작위값 u_i 의 $1/w_i$ 제곱을 priority 로 두어 quantile 로 $K=20$ stratum 에 분할한다 (Chao 1982 의 "weighted reservoir" 기법, 큰 가중치를 가진 벡터가 우선순위 상위에 놓이는 핵심 trick). 본 method 는 paradigm P3 Streaming (스트리밍) 에 속하며, PCA 환원 없이 원본 차원에서 직접 동작하므로 다른 상위 method (Hilbert·Skilling) 와 달리 학술 정직성 측면에서 명칭과 실제 알고리즘이 완전 일치한다.

4.2 chao_weighted 의 정확도 절대값

- 베이스라인 평균 Q-error = 1.4582 → chao_weighted 결합 mode 평균 Q-error $\approx$ **1.37** (paired median Δ% -6.22% 기준)
- 분포 파악 1 회 cost (fit_time) = **11.03 초** (다른 상위 method 중 sparse_rp 가 가장 빠른 2.91 초, pca4_skilling_hilbert_approx 가 가장 느린 53.92 초)
- Pareto frontier 1순위** — 정확도와 분포 파악 속도의 균형이 가장 좋다.

5. chao_weighted 의 실제 엔진 응답 시간·plan 회복

5.1 응답 시간

- Exqutor 베이스라인 inject 와 paired 비교: paired Δ% **mean +0.30%**, median **+0.11%** (4-way 확장 측정 5/24, 12 셀 × 18 variant × 15 회 = 3,240 측정)
- 통계적으로 **사실상 동등** (paired Wilcoxon $p_{holm} < 0.05 = 7.7\%$ 만 유의, **86.9% small effect**, 17 inject variant 모두 $|\Delta\%| \leq 1.12\%$ 안에 모임)

- 즉 추정 정확도의 6.22% 향상이 엔진 응답 시간 추가 가속으로 직결되지 않는다.

5.2 plan 회복 robustness (결합 13 method 평균)

- 12 셀 × 13 결합 method = 156 measurement 중 **148/156 = 94.9%** 가 정답 plan 으로 회복
- 베이스라인 7/12 = 58.3% 대비 **plan 회복 robustness 크게 향상**
- 회복 실패 8 건은 모두 Q3 (가장 풍부한 join space 가진 쿼리) 에서 발생

5.3 변동 분해 (실제 엔진 응답 시간)

- $\log(\text{exec_ms}) \sim C(\text{query}) + C(\text{qid}) + C(\text{sel}) + C(\text{condition: B1} \cdot \text{CaseB} \cdot \text{oracle}) + \text{교호작용의 분산 분해 (3 평면 통합 2,250 obs, } R^2=0.83)$
- 조건 (B1·결합·oracle) % SS = **0.00%** · p = **0.945**
- 즉 어느 추정값을 주입했는지가 응답 시간 변동에 사실상 기여하지 않는다.

5.4 종합 — chao_weighted 의 가치

본 연구의 최저 Q-error method 인 chao_weighted (그리고 결합 13 method 전체) 의 실제 엔진 가치는 **추가 latency 가속이 아니라 plan 회복의 robustness** 에 있다. 베이스라인은 결정 경계 가까운 cell 에서 fragile 하게 다른 plan 으로 미끄러질 수 있는 반면, 결합 13 method 는 같은 cell 에서도 정답 plan 을 안정적으로 회복한다.

6. 메커니즘 규명 — 사전 등록 통제 측정

6.1 통제 측정의 필요성

"분포 인지 method 가 베이스라인의 베르누이보다 정확하다" 는 결과 (89.1% 우위) 가 정말 **분포 인지의 효과인지**, 아니면 두 독립 추정량을 평균하는 **일반 통계 효과인지** 를 구분하기 위해 method 자리에 또 다른 무작위 베르누이를 둔 **이중 베르누이 ensemble** 통제군 (이하 CaseC) 측정.

CaseC 의 두 베르누이 표본은 같은 카디널리티 추정 알고리즘 (식 1-6) 위에서 서로 독립 seed 로 작동하며, 두 추정값을 산술 평균한다. 따라서 분포 인지 정보는 사용되지 않고, 두 독립 표본의 평균에 따른 분산 감소 효과만 작동한다.

6.2 통제 측정 결과 (95 측정 cell 전수)

본 측정은 25 셀 × 3 selectivity × 3 K 평면의 95 (cell × sel × K) 조합 전수에 대해 수행했다.

비교	better%	median Δ%
CaseC vs 베이스라인	95/95 = 100%	-11.32%
CaseC vs 결합 (CaseB)	95/95 = 100%	-5.98%

- CaseC 평균 Q-error = **1.3060** (베이스라인 1.4595 · 결합 1.4022 대비 모두 더 정확)
- 95 측정 전수에서 통제군이 결합 방식 (분포 인지 method) 보다 더 정확하다.

6.3 결론 — 89% 우위의 진짜 메커니즘

본 연구의 89.1% 결합 우위 메커니즘은 다음과 같이 분해된다:

1. 두 독립 추정량 평균에 따른 분산 감소 효과 (일반 양상불 효과, 베이스라인 단일 표본 대비 표본 용량 2배 효과) — 지배적 원인
2. 분포 인지 method 의 추가 효과 — CaseC 와 결합의 비교에서 분포 인지가 양의 효과를 더하지 못함 (오히려 미세 음의 잡음)

→ **결합의 우위는 분포 인지 자체가 아니라 두 독립 추정량 평균의 분산 감소 효과** 가 지배적이다. 본 연구의 핵심 **negative · methodological 결과** 이며, "분포 인지 method 가 베르누이보다 우월하다" 라는 단순 인과로 결과를 해석해선 안 된다.

7. 학술 정직성 명시 — method 명칭 정정 (5/24 3-multi-AI audit)

본 연구의 16 method 중 8 method 가 명칭과 실제 구현 사이에 부분 불일치가 있어 학술 정직성 차원에서 정정한다. Claude (자체 raw 직접 분석)·Codex (적대 코드 read)·Gemini (학술 reference 검증) 3 모델의 통합 권고 결과이다.

이전 명칭	정정 후 명칭	정정 사유
<code>hilbert_real</code>	<code>pca2d_hilbert_xy2d</code>	PCA 2D 환원 후 Wikipedia xy2d Hilbert curve 적용 — 고차원 Hilbert curve (Faloutsos 1989) 가 아니다
<code>skilling_hilbert</code>	<code>pca4_skilling_hilbert_approx</code>	PCA 4D 환원 + Skilling 알고리즘 근사 (exact swap 일부 생략)
<code>zorder_morton</code>	<code>pca2d_zorder_morton</code>	PCA 2D 환원 후 Morton bit-interleave (Morton 1966 의 native multidim 아님)
<code>mhists2</code>	<code>pca2d_equi_depth_grid</code>	PCA 2D + equi-depth grid (Poosala 1997 MHIST-2 의 MaxDiff 미사용)
<code>hyperloglog</code>	<code>md5_prefix_hash_bucket</code>	md5 hash leading prefix bits 로 partition (Flajolet 2007 HyperLogLog 의 카디널리티 estimator 미사용)
<code>lavallee_hidiroglou</code>	<code>takeall_cumsqrtf</code>	take-all + cum- $\sqrt{f}$ 만 적용 (Lavallée-Hidiroglou 1988 의 Neyman σ_h allocation 미적용)
<code>rabitq_strat</code>	<code>rabitq_1bit_bucket</code>	1-bit sign partition only (Gao-Lin 2024 의 full RaBitQ codebook 아님)
<code>sparse_rp</code> (carry)	명칭 유지 · reference 정정	1/ $\sqrt{D}$ 희소 무작위 투영의 정보 출처: Li-Hastie-Church 2006 (이전 Achlioptas 2003 표명 정정)

★ 본 정정의 핵심: §4.1 정확도 ranking 상위의 `pca2d_hilbert_xy2d` (구 `hilbert_real`, 2위) 와 `pca4_skilling_hilbert_approx` (구 `skilling_hilbert`, 3위) 의 순위는 고차원 공간 곡선의 효과가 아니라 PCA 분산 요약 + 공간 채움 곡선 hybrid 의 효과 로 해석해야 한다. 1 위 `chao_weighted` 만 PCA 환원 없이 원본 차원에서 동작하며 명칭과 알고리즘이 완전 일치한다.

paradigm 분류도 정정 반영: - 구 P9 InfoTheoretic 폐지·P5b Hashing 신설 (`md5_prefix_hash_bucket` 이동) - 구 P5 QMC → P5 Classical Stratification (`cum_sqrtf·takeall_cumsqrtf` 의 Cochran 1977 표본 이론 본질 명시) - P2 Spatial 의 PCA-reduced 부분 명시 (`pca2d/pca4` prefix 로 명명)

8. 측정 한계 (honest limitation)

8.1 측정 평면 한계

- **A2-Fig8 (DEEP+CC3M sf=10, 1024d)**: 16 method 중 4 method 만 측정 (희소 cell, 단독 finding 인용 안 함)
- **WIKI sf=10 실제 엔진 측정**: 768d SeqScan 이 statement_timeout (180 초) 초과 — 측정 불가 (honest exception)
- **scale factor 1·100 실제 엔진 측정**: sf=1 은 작은 테이블이라 IndexScan 경로 선택 → 카디널리티 주입 미발동 (plan-invariant), sf=100 은 carry 미진행 (Future Work)
- **타 엔진 (VBASE·DuckDB-vss·Milvus)**: 미측정 (Future Work)
- 측정 portfolio = **41.9%** (1,508 / 의도 max 3,600), 완전 요인 설계 아닌 구조화 portfolio — K=20·sel=0.01 중심으로 측정 밀도 집중

8.2 측정의 통계 검정 floor

- trial 10 회로 한쪽 꼬리 Wilcoxon 최소 p값 $1/1024 \approx 0.001$ 에 몰림
- method·paradigm 우열은 p값보다 $\Delta\%$ ·효과 크기 (Hedges' g · Cliff's δ) 로 판단

8.3 sf=10 한정 일반화

본 연구의 실제 엔진 측정은 모두 **sf=10 (DEEP·SIFT·SSN·YFCC 4 데이터셋) 환경 기준** 이다. sf=1 (in-memory fit) 과 sf=100 (Disk I/O bound) 환경에서는 plan 변경 시 latency 증감 폭이 다를 수 있다.

8.4 method 명칭 정직성 한계 (§7 carry)

본 §7 의 8 method 명칭 정정은 외부 공유 자료 (본 자료 포함)·발표·보고서에 모두 반영되었다. 측정 raw 데이터의 method 명칭 column 자체는 호환성을 위해 이전 명칭 carry 하되, 해석·발표·보고에는 정정된 명칭과 paradigm 분류를 사용한다.

9. Future Work — 후속 작업 두 갈래

9.1 검증 범위 확장

- scale factor 더 넓게 (sf 1 ~ 100+)
- 타 엔진 — VBASE · DuckDB-vss · Milvus
- 산업 자원 trade-off — RAM · CPU · sample storage cost 분석

9.2 History-aware Adaptive Sampling (신 방향)

- 유사 query 의 과거 selectivity feedback 누적
- 현재 vector predicate 의 카디널리티를 더 적은 sampling 으로 추정
- sampling cost ↓ · 정확도 carry · 본 연구에서 보이지 않았던 latency 개선 후보

10. 검증 수준 (3-multi-AI cross-check)

본 자료의 모든 수치·algorithm·paradigm 명칭은 다음 3 모델의 적대 cross-check 를 거쳤다 (5/24 dispatch):

AI	역할	신뢰도
Claude (Opus 4.7)	자체 정본 raw parquet 직접 read + 통계 재계산	pass
Codex (GPT-5.5 xhigh effort)	적대 코드 read + 통계 재계산 + algorithm-reference 정합	82/100 · conditional pass
Gemini (3.1 Pro)	학술 reference 검증 + naming convention + paradigm taxonomy	91.5/100 · conditional pass
3-axis 종합	—	~87/100 · conditional pass

검증 결과 발견된 정정 항목 (수치 drift·표기 오류·method 명칭 8 건·paradigm 재분류) 은 모두 본 자료 + 보고서 + 발표 자료에 반영 완료.

11. 결론 한 줄

본 연구는 Exqutor 논문의 적응적 표본 추출에서 표본 선택 단계 한 곳만 통제 변인으로 분리해 1,508 측정으로 검증한 controlled verification experiment 다. **베이스라인의 가속 효과는 견고하게 확정** (기본 pgvector 대비 평균 5.77 배), **결합 13 method 가 정답 plan 회복 robustness 를 94.9% 까지 향상** 시키지만, **추정 정확도의 추가 향상은 실제 엔진 응답 시간 추가 가속으로 직결되지 않으며** (paired 분산 분해에서 조건 % SS = 0.00%), **89% 우위의 진짜 메커니즘은 분포 인지 효과가 아니라 두 독립 추정량 평균의 분산 감소 효과** 가 지배적임 (사전 등록 dual-Bernoulli 통제 측정 95/95 = 100% 입증) 이라는 negative · methodological 결과다.

작성: 2026-05-24 23:33 KST · 속도는벡터 (조현빈, 박세은 팀장 검토 후 임채림 연구원께 전달) 3-multi-AI 검증 완료 (Claude+Codex+Gemini, 종합 신뢰도 ~87/100, 명칭 정정 8 건 반영 carry)