

자문 요청 — W1 Sprint 결과 보고 및 잔여 자문 사항

2026-1학기 종합설계프로젝트 — 속도는벡터 채림 석사님 + 지도교수님 송부용 2026-05-07 작성, ~5/15 발송 예정

항목	내용
팀명	속도는벡터 (인증설)
소속	연세대학교 컴퓨터과학과
연구 주제	Exqutor 기반 단일 테이블 벡터 범위 쿼리에서의 분포 인식 샘플링 연구
원논문	Exqutor — Extended Query Optimizer for Vector-augmented Analytical Queries (arXiv:2512.09695v2)
작성일	2026-05-07
송부자	박세은 (팀장)
수신	임채림 석사님, (지도교수님 성함)
후속	5/8 (목) 19:00 비대면 회의에서 합의된 잔여 자문 사항 포함

1. 5/5 자문 후 진행 사항

5월 5일자 연구 지도 확인서 ([속도는벡터_연구지도확인서_20260505.md](#)) 를 통해 보고드린 RQ 재정립 (RQ1: skew 영향 정량화, RQ2: 분포 인식 ablation, RQ3: distribution-agnostic 7-way) 에 따라, 2026-05-06 하루 동안 W1 Sprint 의 RQ1 + RQ2 영역 4 개 실험 (SIFT × SYSTEM, Allocation 5-way, Sample size sensitivity 4 ssize, BH-FDR 보강) 을 모두 완료하였습니다. 측정 인프라는 vector.c 패치 시도 시 메모리 누수 문제로 인해 Python 시뮬레이션으로 우회하였으며, 25,000 + 40,000 + 2,500 rows 의 raw 측정 데이터를 확보하였습니다. 다음은 그 결과의 요약과 잔여 자문 사항입니다.

2. RQ1 — H1 정량 입증 (실험 #1)

박세은 팀장이 5/5 회의에서 제기한 "Normal vs Skew BERN baseline 직접 비교 부재" 의문에 대한 정량 답변으로, RQ1 의 2x2 표 (DEEP/SIFT × SYSTEM/BERNOULLI) 의 마지막 한 cell — SIFT × SYSTEM(block) — 을 측정하였습니다. 5 sel × 5 seed × 100 query = 2,500 rows, 측정 28.6 초.

핵심 결과는 모든 selectivity 에서 SIFT(skew) 의 SYSTEM-BERN 격차가 DEEP(normal) 의 격차보다 크다는 것이며, 좁은 selectivity 영역에서 격차가 가장 두드러집니다.

sel	SIFT(skew) Δ%	DEEP(normal) Δ%	(SIFT – DEEP)
0.01	+10.27%	+4.66%	+5.61%p
0.05	+17.32%	+12.61%	+4.71%p
0.10	+16.68%	+14.76%	+1.92%p
0.30	+14.85%	+14.05%	+0.80%p
0.50	+14.36%	+12.59%	+1.77%p

paired Wilcoxon 검정 결과 SIFT 의 5 selectivity 모두에서 매우 유의한 신호가 검출되었으며 ($p \leq 1e-4 \sim 1e-49$, Cohen's d 0.24~1.01), Benjamini-Hochberg 다중 비교 보정 후에도 모두 유의 유지됩니다. 이로써 박세은 팀장이 제기한 핵심 narrative — "normal 분포에서 잘 작동하던 random sampling 이 skew 분포에서는 이렇게 부정확해진다" — 가 정량 증거로 입증되었습니다.

부수적으로 5/6 오전 측정 시 의심된 PostgreSQL **setseed** 비작동 의혹이 query 별 raw q_error 분석을 통해 해소되었습니다. seed 간 median q_error 의 우연한 일치는 좁은 selectivity 에서 q_error 가 매우 discrete 하게 분포한다는 데이터 특성에서 비롯한 것이며, query 단위로 분해하면 seed 간 분산이 충분히 검출됩니다.

3. RQ2 — 분포 인식 샘플링의 ablation (실험 #2 + #3 + #4)

3.1 Allocation 5-way 비교 (실험 #2 + #3)

기존 KM20 stratified 가 vector.c 코드 점검 결과 Equal Allocation 임을 확인하고, 그 위에 Proportional/Neyman/Anti-Neyman 3 mode 를 추가하여 BERN baseline 과 함께 5-way 비교를 수행하였습니다 (DEEP/SIFT × 5 sel × 5 seed × 100 query × 5 mode = 25,000 rows).

각 cluster 의 σ_i 는 $\text{sel}=0.10$ D_target anchor 의 query 100 개 평균 Bernoulli SD 로 정의 — $\sigma_i^2 = \text{mean}_q[p_{\{i,q\}} \times (1-p_{\{i,q\}})]$. DEEP 1M 의 σ_i 변동은 1.5 배 (0.1925~0.2936), SIFT 1.5M 은 2.6 배 (0.1232~0.3211) 이며, N_i 변동 (DEEP 3.1 배, SIFT 4.4 배) 보다 신호가 약합니다.

핵심 결과 4 가지를 다음과 같이 정리하였습니다.

(가) **모든 stratified mode > BERN baseline**: paired Wilcoxon $n=500/\text{cell}$ 기준 DEEP -1.3 ~ -7.0%, SIFT -3.7 ~ -10.5% 개선이며 $p \leq 1e-7 \sim 1e-50$. SIFT 의 effect size (Cohen's d) 가 DEEP 의 2 배 이상으로, cluster 비균질성에서 stratified 의 가치가 정통 통계학과 일치합니다.

(나) **Neyman vs Equal 부분 입증 (H2-N)**: SIFT $\times$ 좁은 selectivity 에서만 통계적으로 유의한 추가 효과가 검출됩니다 ($s=0.01$ -11.91%, $p_{\text{BH}}=0.024$; $s=0.05$ -3.07%, $p_{\text{BH}}=0.010$). DEEP 에서는 모든 selectivity 에서 비유의하며, σ_i 단일 정의의 한계가 다중 비교 보정 결과에서 직접 드러납니다.

(다) **Anti-Neyman vs Proportional 반증 (H2-AN)**: 모든 case 에서 통계적으로 유의하지 않습니다 (DEEP $p=0.193 \sim 0.846$, SIFT $p=0.205 \sim 0.994$). σ_i 신호가 N_i 보다 약해 ablation 효과가 통계 noise 안에 묻혔다고 해석됩니다.

(라) **새 발견 — SIFT $\times$ Equal $\times s=0.01$ anomaly**: Equal Allocation 의 q_{error} (1.8463) 가 BERN baseline (1.6925) 보다도 부정확하게 나왔습니다. cluster 크기 변동이 큰 SIFT 에서 Equal 의 균등 배분 ($385/20 \approx 19$ 표본/cluster) 이 큰 cluster (148K) 에서 sample 부족을 야기한 것으로 해석되며, Proportional/Neyman 이 이를 해결합니다. 이는 "Equal 은 normal 데이터엔 적합하나, skew 에서는 Proportional 이상이 필요하다" 는 narrative 의 직접 증거입니다.

3.2 Sample size sensitivity (실험 #4)

5/5 회의의 비판 "Exqutor 대비 효과 약함" 에 대한 직접 답변으로 KM20-Proportional 의 BERN 대비 개선이 sample_size 에 어떻게 의존하는지 측정하였습니다 (4 ssize $\times$ 2 dataset $\times$ 5 sel $\times$ 5 seed $\times$ 100 query $\times$ 2 mode = 40,000 rows).

가설 H2-S (sample_size 작을수록 KM20 효과 큼) 는 DEEP $s=0.05$ 에서만 부분 단조이며 다른 case 는 non-monotonic 하여 미입증되었습니다. 그러나 모든 40 조합에서 KM20 > BERN 일관 ($\Delta\%$ -1.09 ~ -13.50%) 이라는 새 발견이 있었으며, 이는 sample_size 30 배 차이 (100 ~ 3000) 에 걸쳐 KM20 의 가치가 robust 하게 유지됨을 의미합니다. production 관점에서는 "어느 sample_size 영역에서도 KM20 가치 유지" 라는 cost-tunable 한 narrative 가 H2-S 단조성보다 오히려 강한 메시지로 평가되며, 이 narrative 전환의 정당성이 본 자문의 검토 사항 중 하나입니다.

4. 통계 robustness + 박세은 의문 강화 답변 (보강 작업)

4.1 BH-FDR 다중 비교 보정

다중 비교 false discovery rate 통제를 위한 Benjamini-Hochberg 보정을 다음 세 영역에 적용하였습니다.

영역	비교 수	p_raw < 0.05	p_BH < 0.05	결론
RQ1 SIFT × SYSTEM vs BERN	5	5	5	모두 유의 유지 (max p_BH = 4.99e-49)
RQ2 stratified vs BERN	40	32	32	80% 유의 (비유의는 모두 s=0.01 — sample 부족)
RQ2 Neyman vs Equal	10	2	2	SIFT × {s=0.01: p_BH=0.024, s=0.05: p_BH=0.010} 유의 유지

모든 핵심 결과가 BH-FDR 보정 후에도 robust 하며, 특히 SIFT × {s=0.01, s=0.05} 에서의 Neyman 가치는 다중 비교 보정 후에도 명확히 검출됩니다.

4.2 DEEP query difficulty 분석

박세은 팀장의 4/30 직후 질문 — "DEEP × SYSTEM 의 절대값이 SIFT 보다 클 때가 있는데?" — 에 대한 정량 답변을 정리하였습니다. DEEP × s=0.01 에서 mean q_error 는 1.6185 로 SIFT (1.9205) 보다 작으나, q_error > 2 인 query 의 비율은 DEEP 9% vs SIFT 39.4% 로 본질적 query difficulty 는 SIFT 가 4 배 이상 큼니다. DEEP × s=0.01 의 max q_error 가 가끔 SIFT 보다 큰 것은 BERN sampling 의 small-sample fallback artifact 로, true_card=10000 → BERN 385개에서 평균 hit=3.85개 → 우연히 hit=0 발생 시 fallback estimator 가 동일한 plan_rows 값으로 떨어지는 현상에서 비롯합니다. 따라서 절대값 비교가 sometimes SIFT < DEEP 인 것은 DEEP query pool 의 우연한 fallback artifact 이며, SIFT 의 본질적 difficulty 가 더 크다는 사실은 q_error > 2 query 비율 + Δ% gradient 의 두 metric 으로 일관되게 입증됩니다.

5. RQ3 진행 계획 (W2 ~ W3)

7-way distribution-agnostic 비교 (Offline 4종 + Online 2종 + Weight 1종) 를 핵심 metric Recovery Rate 로 정량화합니다. recovery_rate = (방법X - RANDOM20) / (KM20 - RANDOM20) 로 정의되며, 1.0 이면 KM20 oracle 수준 회수, 0.0 이면 RANDOM20 (공간 인식 없음) 수준입니다. 분모 붕괴 ($|KM20 - RANDOM20| \leq 1\%p$) 인 셀에서는 절대 Q-error 개선폭으로 fall back 하며 이는 사전 등록되어 있습니다.

7 개 method 의 우선순위와 기대 recovery 는 다음과 같습니다.

#	방법	패러다임	기대 recovery	시간
1	F. MiniBatch K-means	Offline (학습 1~5%)	75~95%	~1h
2	C. Random Projection	Offline (단순 하한)	10~40%	~2h
3	E. Hilbert Curve	Offline (결정론)	20~60% (contribution 후보)	~4h
4	A. LSH	Offline (확률)	30~60%	~4h
5	B. KDE-pilot	Online (정교)	50~80% (이론 상한)	~6h
6	G. Distance-Shell	Online (단순)	25~50%	~4h
7	H. Importance Sampling	비분할 (가중치)	30~70% (2x2 factorial)	~6h

W1 의 RQ2 5-way 측정 인프라 (cluster 별 LIMIT 500 sample 캐시 + fresh conn per cluster + HT estimator) 가 그대로 재사용되며, 방법별 차이는 stratum_id 부여 알고리즘 (또는 H 의 weight 정의) 뿐입니다. 이로써 7 method $\times$ 2 dataset $\times$ 5 sel $\times$ 5 seed $\times$ 100 query = 35,000 rows 의 측정이 W2 ~ W3 (5/12~5/22) 안에 가능할 것으로 추정합니다.

6. 잔여 자문 사항

5/5 자문 이후 W1 측정 결과를 토대로 다음 사항에 대한 검토 의견을 요청드립니다. 본 자문은 5/8 (목) 19:00 비대면 회의에서 팀 전원의 합의를 거쳐 송부됩니다.

6.1 채림 석사님께 (통계 방법론 영역)

(1) **σ_i 정의의 적절성** — 본 측정에서 σ_i 를 sel=0.10 D_target anchor 의 query 평균 Bernoulli SD 로 단일 정의 하였는데, 이로 인해 SIFT $\times$ 좁은 sel 에서만 Neyman 효과가 검출되었습니다 (BH-FDR 보정 후 $p=0.010\sim0.024$). σ_i 를 query-aware 로 정교화하면 더 강한 신호를 검출할 수 있을지, 아니면 RQ3 의 Online (B/G) 영역으로 미루는 것이 더 학술적으로 정당한지의 판단을 요청드립니다.

(2) **Anti-Neyman 반증의 의미 해석** — H2-AN 이 모든 case 에서 통계적으로 유의하지 않게 나온 것 (DEEP $p=0.193\sim0.846$, SIFT $p=0.205\sim0.994$) 이 (a) σ_i 신호 자체의 부족 때문인지 (b) Anti-Neyman 의 이론적 손해가 N_i 신호의 우세에 의해 nullify 되어 검출이 불가능한 것인지의 통계학적 해석 의견. 후자라면 본 데이터의 N_i 변동 (DEEP 3.1배, SIFT 4.4배) 이 σ_i 변동 (DEEP 1.5배, SIFT 2.6배) 을 압도하는 구조 자체가 본 연구의 발견점이 될 수 있다고 보입니다.

(3) **H2-S 미입증 → robustness narrative 전환의 적절성** — H2-S 의 sample_size 단조 감소 가설이 미입증된 후 KM20 robustness 라는 새 narrative 로 전환하였습니다. 이 narrative 전환이 (a) 사후 합리화 (post-hoc rationalization) 의 위험을 갖는지 (b) production 관점의 가치 메시지로 정당화되는지 판단. 만약 (a) 의 위험이 있다면 W2 측정에서 추가 sample size 를 더 측정하여 명확히 가설 형태로 재진술할 의향이 있습니다.

(4) **Recovery Rate 의 통계적 valid 성** — $\text{recovery_rate} = (\text{방법X} - \text{RANDOM20}) / (\text{KM20} - \text{RANDOM20})$ 의 분모 분산이 분자 분산을 압도할 가능성이 있어, paired bootstrap CI 로 별도 검증할 계획입니다. bootstrap iteration 수와 CI 구간 정의에 대한 권고 의견.

6.2 지도교수님께 (연구 positioning 영역)

(1) **본 연구의 positioning** — "Exqutor 가 미작동하는 단일 테이블 영역에 대한 분포 정보의 가치 정량화" framing 의 적절성. 본 연구는 Exqutor 의 개선이 아니라 Exqutor 가 다루지 않는 영역의 새로운 검증이며, Limitation 4 (단일 → 멀티 일반화 future work) 의 명시 방향.

(2) **RQ3 의 contribution 형태** — 7-way 비교 자체로 학부 캡스톤 contribution 이 충분한지, 아니면 ranking 위 에 새 method (Hilbert Curve 의 결정론적 장점을 살린 변형 등) 를 제안해야 할지의 방향 결정. 측정 결과에 따라 W3 안에 method 제안 1 종을 추가할 여력은 있습니다.

(3) **5/27 최종 발표까지의 일정** — W2 (5/12~5/18) RQ3 Online + Weight 측정, W3 (5/19~5/22) Recovery Rate cross-analysis 와 발표 자료 초안의 압축 일정이 현실적인지의 판단. 만약 압축이 부담된다면 RQ3 의 7 방법 중 일부를 future work 로 명시하고 핵심 4 종 (F, C, E, B 또는 H) 만으로 contribution 를 마무리하는 옵션을 검토 중입니다.

(4) **Two-Level Decomposition + Recovery Rate 의 공동 framework** — RQ2 의 Level 1 (Proportional, K 등분 효과) + Level 2 (Spatial, 공간 인식 효과) 분해와 RQ3 의 Recovery Rate 가 의미적으로 결합되어 "분포 정보의 가치 = Level 1 + Level 2 = Recovery Rate × oracle gain" 의 통합 framework 으로 정리될 수 있는지의 학술적 정당성.

7. 첨부 자료

- 5/5 자문 (선행): [submission/_drafts/속도는벡터_연구지도확인서_20260505.md](#)
- 5/8 회의 outline: [plans/5_8_19시_회의_outline.md](#)
- RQ 재정립 설계안 v6: [plans/RQ재정립_20260505_2122.md](#)
- RQ3 7-way 상세 설계: [plans/RQ3설계안_20260416_213500.md](#)
- RQ1+RQ2 측정 결과 통합 정리: [experiments/results/RQ1_RQ2 실험 결과 정리.pdf](#)
- 4단계 narrative 보고서:

- 실험 #1 (RQ1 SIFT SYSTEM): `experiments/results/rq1_motivation/sift_rq1_2026_05_06/실험1_결과정리_20260506.md`
- 실험 #2+#3 (RQ2 Allocation): `experiments/results/rq2_aware/2026_05_06_alloc/실험2_3_결과정리_20260506.md`
- 실험 #4 (RQ2 Sample size): `experiments/results/rq2_aware/2026_05_06_alloc/실험4_결과정리_20260506.md`
- 발표용 figures (5종, W1): `experiments/figures/rq1_rq2_w1_sprint/`
- BH-FDR + DEEP difficulty 분석:
`experiments/results/rq2_aware/2026_05_06_alloc/bh_fdr_difficulty_analysis.json`
- raw 측정 데이터:
- SIFT × SYSTEM: `experiments/results/rq1_motivation/sift_rq1_2026_05_06/sift_rq1_system.parquet`
- RQ2 5-mode: `experiments/results/rq2_aware/2026_05_06_alloc/rq2_alloc.parquet`
- RQ2 sample size 5sel:
`experiments/results/rq2_aware/2026_05_06_alloc/rq2_size_sensitivity_5sel.parquet`

본 자문 요청에 대한 검토 의견을 회신해 주시면 W2 (5/12~5/18) 시작 전까지 반영하여 RQ3 측정 방향을 조정하겠습니다. 5/22 (목) 교수님 미팅에서 회신 내용을 토대로 최종 발표 자료의 방향을 합의하고자 합니다. 감사합니다.

— 속도는벡터 일동 (박세은, 강재현, 조현빈, 이동욱)