

팀원 상황 공유 — 본 연구 현황 정리 (v2)

수신: 박세은(팀장) · 강재현 · 이동욱 발신: 조현빈 일시: 2026-05-14 (5/13 v1 → 5/14 v2 4차 정정) 용도: 5월 한 달의 측정 결과를 팀원들과 빠르게 공유 (1-2 page)

들어가는 말

지난 한 달 동안 진행한 측정과 분석의 핵심 결과를 정리했어. 5월 27일 발표와 6월 11일 보고서를 향해 우리가 어디까지 와 있는지를 한 번에 보기 위한 자료야. 발표는 청자가 따라올 수 있는 7 단계 순차 흐름으로 잡았어 — (1) 문제 정의, (2) 분포 인지 방법 56 의 탐색과 폐기 분류, (3) 단독 대체 가능성, (4) 결합 framework, (5) 자원 효율, (6) 권장 design, (7) 마무리. 자세한 내용은 박광현 교수님 미팅 자료와 발표 시나리오에 있으니까, 이걸 그냥 빠른 현황 확인 정도로 봐 줘.

본 v2 의 핵심 변화 두 가지를 먼저 짚어 둘게. 첫째, 5/14 새벽까지의 추가 측정 결과 (가중치 변화 sweep + 저비용 결합 방식 4 후보 + 자원 효율 Pareto 분석) 가 회수되면서 우리 연구의 narrative 가 분명해졌어 — **단독 대체 가능 method 의 발견이 본 연구의 main finding 이고, 결합 framework 의 가치는 "더 큰 개선" 이 아니라 "안정성" 이라는 정직한 narrative** 로 정리됨. 둘째, 박세은 5/13 카톡 피드백 (method 개수 너무 많아서 헷갈림 + 숫자/공식 최소화) 을 반영해서 본문에서는 핵심 method 만 짚고 폐기 method 명 list 는 부록에 모았어.

1. 본 연구 한 줄 요약

본 논문 (Exqutor) 의 §V-B 적응적 샘플링 영역에서, 본 논문 베르누이를 우리의 분포 인지 계층적 표집으로 단독 대체하면 15 개 method 가 평균 -5 ~ -12% 정확도 개선을 보이고 (paper 자체 재현 변동의 1.2 ~ 3 배 큰 의미 있는 개선), 두 추정값을 산술 평균으로 결합하면 짝지어 비교한 측정의 92.5% 에서 안정적으로 베르누이 단일 baseline 보다 더 정확하다 (단독 best 보다는 약하지만 cell 별 spread 가 줄어 산업 적용에 더 안정적).

2. 측정 portfolio — 폐기 분류 (3 범주)

본 연구의 RQ3 는 분포 정보를 얻으려는 후보 method 56 개를 8 패러다임 (클러스터링, 공간 분할, 스트리밍, 차원 축소, 정보 이론, 양자화, 준 무작위, 밀도 추정) 으로 모아 9 cell 매트릭스에서 측정한 결과야. 측정을 진행하면서 일부 method 는 그대로 둘 수 없어서 폐기했는데, 폐기 사유를 3 범주로 정직하게 정리했어.

(1) **자원 한계** — 측정 서버의 메모리 한계로 실행이 불가능하거나, 한 cell 측정에 4 시간 이상의 timeout 이 필요해서 전체 portfolio 마감에 맞추기 어려웠던 method 6 종. 가장 대표적인 birch 는 클러스터를 트리 구조로 저장하는 부분이 50 ~ 200GB 메모리를 차지해서 실행 자체가 불가능했고, agglomerative 는 256 차원 데이터셋에서 메모리 부족으로 실패했어.

(2) **알고리즘 구현 결함** — 5월 10일에 8-agent 정독 검토로 발견된 reference 위반이나 알고리즘 잘못 표기 23 종. 가장 인상적인 사례는 vinecopula 가 코드 구현이 rank 변환 + PCA 1 차원 정렬의 별칭으로 되어 있어서 Bedford-Cooke 1986 의 진짜 vine copula 가 아니라는 점, 그리고 neuram 이 코드 한 줄씩 검토한 결과 PCA1D 와 100% 동일하다는 점이야.

(3) **정합성 위반** — 큰 데이터셋에서 추정값이 +145,483% 같은 외곽 값으로 튀어서 paper 가 정의한 N=385 sample budget 안에서 estimator 가 안정적이지 않은 method 9 종.

폐기를 거치고 남은 측정 가능 method 는 약 43 개. 본 연구의 비교 실험군은 9 cells × 2 modes 가 모두 완료된 method 한정. paper 재현 정합성도 네 축에서 검증 — 절사 평균 Q-error 가 본 측정 vs paper 보고값에서 -4.3% 차이로 측정 변동 범위 안에서 일치.

폐기 method 명 전체 list 는 부록 A 로 분리 (박세은 5/13 12:13 피드백 반영).

3. 핵심 결과 — 7 단계 순차 흐름

3.1 단독 대체 가능성 분석 (단계 3) — 본 연구 main finding

남은 43 method 의 추정값을 본 논문의 베르누이 대신 그대로 갈아 끼우는 단독 대체 모드의 결과를 정직하게 풀면:

- **평균 우위 약 40%**: 56 방법 중 약 40% 가 평균적으로 베르누이 기준선보다 정확.
- **통계 일관 우위 7.6% (15/197)**: 통계 검정으로 cell 전반에서 안정적으로 우위인 method 는 7.6%. 같은 method 라도 cell 마다 효과 편차 큼.
- **★ 15 method 의 평균 개선폭 -5 ~ -12%**: 단독 대체로 통계 일관 우위인 15 method 의 평균 개선폭은 -5 ~ -12% 다. 이는 paper 자체 재현 시 발생하는 측정 변동 (-4.3%) 보다 1.2 ~ 3 배 큰 의미 있는 개선. **단독 best 인 minibatch_partial 의 CaseA 단독 대체 결과가 -10.17% 로, 결합 best (-7.37%) 보다도 큰 개선폭.**

즉 단독 대체로도 noise floor 를 넘는 실제 개선이 가능한 method 가 일부 존재 (15/197 = 7.6%) 한다는 점이 본 연구의 핵심 finding 이야. 다만 cell 별 spread 가 커서 산업 적용 안정성 부족 — 이 안정성 부족이 결합 framework 검토의 motivation.

3.2 결합 framework — 안정성 보강 (단계 4)

베르누이 추정값과 우리 method 의 추정값을 산술 평균하면, 492 짝지어 비교한 측정 중 92.5% 가 베르누이 baseline 보다 더 정확. 통계 검정에서도 분명한 차이.

중요한 정직 disclosure — 결합 best 가 단독 best 보다 약함. 결합 best 인 sparse_rp 의 가장 좋은 가중치 결과가 -6.58%, 단독 best 인 minibatch_partial 의 CaseA 단독 대체 결과는 -10.17%. 즉 **"결합으로 더 큰 개선"** 이 본 연구의 결론이 아니라:

- 단독 대체로 의미 있는 개선 가능 (15 method, -5 ~ -12%, main finding)
- 결합은 단독 best 보다 효과 약하지만, 92.5% 짝지어 비교 우위로 cell 별 spread 가 줄어 산업 적용에 더 안정적
- 결합의 진짜 가치 = method 선택 robustness + cell spread 줄임

3.3 결합 가중치 sweep + 저비용 결합 방식 4 후보 (5/14 새벽 회수)

내가 5/13 23:38 + 5/14 새벽에 추가 측정을 진행한 결과로 결합 framework 의 정확한 위치를 정량 검증했어.

가중치 sweep (5/14 00:13 회수): 베르누이 가중치 0.3 / 0.4 / 0.5 / 0.6 / 0.7 다섯 값으로 가중 평균. 4 anchor method 중 3 개가 가중치 0.5 (산술 평균) 에서 best, 양쪽 극단 (0.3 / 0.7) 에서 효과 감소. **가중치 변화로 산술 평균보다 더 큰 개선 어려움 = 산술 평균이 결합 방식 중 best 이며 robust** 라는 확정 결과.

저비용 결합 방식 4 후보 (5/14 새벽 회수): Centroid tuple (5/13 강재현 14:27 카톡 제시) / Hash bucketing / PCA preprocessing / Iterative refinement. 4 후보 중 **Centroid tuple 만 CaseB 결합 모드에서 4 method 모두 보편 우위 (평균 -0.84%p 추가 정확도)**. 나머지 3 후보는 method × mode 별로 spread 크거나 일부 영역에서 marginal/harmful.

3.4 자원 효율 분석 (단계 5) — ★ reservoir O(1) memory 의 산업 적용 핵심 finding

성능만으로 산업 적용을 결정할 수 없어서 학습 시간 / 메모리 / 차원 한계를 결합한 자원 효율 axis 분석을 했어. 그 결과 본 연구의 가장 강력한 산업 적용 finding 이 나옴:

Pareto frontier Top 5 method (학습 시간 cheap + 정확도 anchor 수준 동시): - **sparse_rp** (학습 0.1초, 정확도 anchor 수준) - **chao_weighted** (학습 0.5초, 정확도 anchor 수준, 메모리 가장 적음) - **neuram** (학습 0.5초, 정확도 최고) - **pca1d** (학습 0.5초, 정확도 매우 강력) - **hilbert / hilbert_real** (학습 0.1-0.5초, 정확도 매우 강력)

산업 적용 3 영역 추천:

- **영역 A — 일반 OLAP server (Best of Both Worlds):** sparse_rp 또는 chao_weighted. 학습 cheap + 정확도 anchor 수준 + 메모리 작음.
- **영역 B — 정확도 우선:** neuram. 학습 0.5초이지만 본 측정 portfolio 정확도 최고.
- **★ 영역 C — Resource-First (모바일/embedded/streaming):** reservoir. 학습 0.1초 + 정확도 anchor 수준 + 메모리 $O(1)$ — 본 측정 portfolio 최저. 이 발견이 본 연구의 가장 강력한 산업 적용 narrative 야.

3.5 multi-join 재학습 결과 (재현이 5/13 0:20 카톡 제시 방향)

multi-table cell 에서 비싼 multi-join 재학습 (864 차원으로 합친 후 KM20 재학습) 의 8 measurement 결과: CaseA 단독 대체 모드에서 sparse_rp 와 chao_weighted 는 추가 개선 효과, Hilbert curve 와 HyperLogLog 는 거의 차이 없음. CaseB 결합 모드에서는 4 method 모두 차이 없음 — **결합 모드는 학습 방식 변경에 안정적** 이라는 분명한 evidence.

4. paradigm 별 결과 (보조 표)

8 패러다임 중 다섯 개가 평균적으로 의미 있는 우위.

paradigm	평균 개선폭	대표 anchor method
밀도 추정	-11.93% (n=1)	KDE Parzen
정보 이론	-7.60% (n=9)	HyperLogLog
스트리밍	-6.63%	Chao 1982 weighted reservoir
차원 축소	-6.03%	Sparse Random Projection
공간 분할	-5.57%	Hilbert curve, Z-order

[5/13 1:00 재현이 지적 반영] — paradigm 평균만으로는 paradigm 우위를 단정 짓기 어렵다. paradigm 안의 일부 method 가 극단값으로 평균을 끌어 올리거나 끌어 내릴 수 있음. 우리는 paradigm 평균과 함께 12 anchor method 의 일관성을 학술 도메인 자문 영역 (박광현 교수님 / 임채림 박사님) 으로 묶어서 별도 부록으로 다룰 예정.

5. 한계 및 정직하게 짚어 둘 부분

5월 측정 portfolio 의 미커버 영역을 9 카테고리 분류했다. 그리고 method 단위로 정직하게 짚어 둘 부분이 두 가지:

첫째, hilbert method 가 코드에서 실제로는 PCA 2D 정렬로 구현되어 있어서 진짜 Hilbert curve 효과가 아니라 PCA 대용 (proxy) 효과를 측정한 거였다. 별칭으로 `pca2d_lex` 라고 명명하고, 진짜 Hilbert curve (hilbert_real, Wikipedia xy2d 표준) 를 별도 9 cells × 2 modes 로 따로 측정해서 paradigm 대표 방법으로 추가.

둘째, RQ2 의 Neyman 할당이 비례 할당보다 약간 부정확한 역설 (paradox) 이 발견됐는데, 이는 PartSupp PK 의 클러스터 균등 분포 (CV=0) 와 클러스터 내 분산 범위 1.3 ~ 1.6 배의 좁은 특성 때문에 σ -가중 Neyman 이 proportional 과 통계적으로 동등이 되는 자연 결과.

6. 본 연구 권장 design 과 산업 적용 영역 (단계 6)

5월 측정 결과를 종합하면 본 연구가 권장하는 design 은 다음 세 가지 원칙의 조합 (5/14 시나리오 B 확정 narrative 반영).

1. **단독 대체 적용 우선** — 15 단독 대체 가능 method 중 산업 환경에 맞는 method 선택 후 단독 대체. paper 베르누이를 우리 method 의 추정값으로 갈아 끼우는 가장 단순한 방식이며, 평균 -5 ~ -12% 의 의미 있는 정확도 개선이 가능.
2. **결합 framework 보조 사용** — 단독 대체의 cell 별 spread 가 산업 적용에 부담될 때, 산술 평균 결합으로 안정성 보강. 92.5% 짝지어 비교 우위로 cell spread 가 줄어들고 method 선택의 robustness 가 확보됨. multi-table 영역에서는 Centroid tuple 저비용 결합 방식이 학습 비용 추가 0 으로 추가 정확도 개선 제공.
3. **method-aware 선택적 적용** — 12 anchor method 중에서도 cell 별 K-민감도와 quality-민감도 패턴이 다르므로 cell 특성에 맞게 method 선택.

산업 적용 영역 3 가지:

1. **영역 A (일반 OLAP server)**: sparse_rp 또는 chao_weighted 단독 대체 + 산술 평균 결합 보조. 학습 cheap + 정확도 anchor 수준 + 메모리 작음.
2. **영역 B (정확도 우선)**: neuram 단독 대체 + 산술 평균 결합. 본 측정 portfolio 정확도 최고.
3. ★ **영역 C (모바일/embedded)**: reservoir 단독 대체. 메모리 O(1) + 학습 0.1초 + 정확도 anchor 수준. 자원 제약이 매우 큰 환경에 가장 적합.

산업 적용 영역 두 가지 통합 방향. (1) PostgreSQL pgvector 의 default sampling 메커니즘에 우리 method 의 stratified estimator 를 산술 평균으로 추가. (2) Exqutor 의 §V-B 모듈에 우리 안 (단독 대체 우선 + 결합 보조 + cheap 근사 + method-aware) 을 통합.

7. 향후 연구 방향

본 연구는 산술 평균이라는 가장 단순한 결합 방식부터 측정을 시작해서 결합 framework 자체의 효과를 baseline 수준에서 입증한 거야. 실제 산업 적용을 위해서는 데이터셋의 분포 특성, 차원, 질의 선택도에 따라 결합 방식이 동적으로 결정되는 data-aware ensemble framework 가 필요하고, 우리 산술 평균 결과는 그 framework 의 출발점이야.

7.1 Data-aware ensemble framework — 핵심 5 영역

1. **Distribution-aware ensemble** — skew / dense 데이터셋에 따라 결합 가중치 동적 결정
2. **Dimensionality-aware ensemble** — 차원 별 결합 방식 선택
3. **Estimator-confidence-aware** — 각 estimator 의 분산 추정 기반 분산 최소화 가중치
4. **Query-aware ensemble** — 선택도 별 결합 방식 변경
5. **Meta-learning adaptive ensemble** — 측정 환경 특성으로 결합 가중치 학습

7.2 일반 확장 5 영역

1. **다른 데이터셋 일반화** — YFCC, GLOVE 등에서 동일 패턴 검증
 2. **이론적 분산 분해** — Cochran 1977 §11.10 composite estimator 적용
 3. **논문 동적 framework 와의 완전 정합** — Q-error 신호 source 명시
 4. **실제 시스템 적용** — pgvector 또는 Exqutor prototype 통합
 5. **다른 결합 방식 추가 비교** — 본 연구의 가중치 sweep + 4 cheap 근사 후보 외 다른 결합 방식
-

8. 다음 단계

일시	event
5/15 (금) 14:00	박광현 교수님 미팅 (사전 자료 4 file 준비 완료, 4차 정정 본 v2 반영)
5/16 ~ 5/26	5/27 발표 슬라이드 최종 정리
5/27 (화) 19:00	최종 발표
5/28 (목)	임채림 박사님 SAP 미팅
5/29 ~ 6/10	6/11 보고서 본문 작성
6/11	보고서 제출

9. 팀원별 역할 — 5월 ~ 6월

중간 보고서 시점의 역할 분담을 기본으로 유지.

- **박세은 (팀장)**: 전체 일정 관리, 박광현 교수님 / 임채림 박사님 자문 회신 정리, 4인 합의 주재
- **강재현 (주 발표자)**: 5월 27일 발표 slide 최종 정리, 발표
- **조현빈 (실험·분석)**: 측정 진행, 측정 결과 분석, 보고서 본문 작성
- **이동욱 (문서화·검토)**: 보고서 본문 검토 및 수정, 발표 slide 검토

5월 ~ 6월 중에는 5월 27일 발표 준비가 우선이라 강재현의 비중이 크고, 5월 28일 임채림 미팅 이후부터는 6월 11일 보고서 작성으로 무게 중심이 이동. 보고서 본문 30 page 분량 작성은 4 장 (RQ3 결과, 약 10 page) 이 가장 크기 때문에, 조현빈이 RQ3 본문 작성을 메인으로 가져가고 박세은이 1 ~ 3 장 (도입, 기존 연구, 차별성, 약 9 page), 이동욱이 5 ~ 6 장 (한계와 향후 확장, 결론, 약 4 page) 과 전체 검토, 강재현이 RQ1 ~ RQ2 본문 (약 5 page) 으로 분담하는 방향을 제안. 분담 비율은 미팅에서 합의.

10. 자세히 보고 싶으면

- **박광현 미팅 핵심 정리 v2** (3-4 page): [submission/_drafts/속도는벡터_5_15_박광현미팅_핵심정리_v1.md](#)
- **5/27 발표 시나리오 v2** (5-7 page, 7 단계 흐름): [submission/_drafts/속도는벡터_5_27_최종발표_storyline_v1.md](#)

- 6/11 보고서 outline v2 (7-9 page, 7 단계 + 부록): `submission/_drafts/속도는벡터_6_11_최종보고서_outline_v1.md`
- 5월 측정 분석 file: `_internal/analysis/{alpha_sweep, cheap_approximation_extended, resource_efficiency_pareto, multi_join_restratification, centroid_tuple_cheap_approximation, method_level_breakdown, km_granularity_sensitivity_3way}.md`

질문이나 추가 분석 필요한 부분 있으면 카톡으로.

부록 A — 폐기 method 명 전체 list

박세은 5/13 12:13 카톡 피드백 "method 개수 등이 너무 많이 나와서 좀 헷갈리는 측면이 있습니다" 반영. 본문에 핵심 method 만 짚고 폐기 method 명 전체 list 는 이 부록으로 분리.

(1) 자원 한계 폐기 6 종

birch, agglomerative, hdbscan, kde_parzen, dirichlet, kernelpca, neuocard.

(2) 알고리즘 구현 결함 폐기 23 종

kdtree, vinecopula, neuram, ams_count_sketch, dbscan, ccsketch, lsh 등을 포함한 5월 10일 8-agent code audit 발견 method. 자세한 method 별 발견 사항은 박광현 미팅 핵심 정리 v2 또는 6/11 보고서 부록 F 참조.

(3) 정합성 위반 폐기 9 종

halton, sobol, lhs, hammersley, dense_rp, random_projection, dbscan, ccsketch, lsh, ams_count_sketch. SSN sf=100 같은 큰 dataset 에서 +145,483%, +213,065% 외곽 값.

부록 B — 12 anchor method 명단 + 3 axis 민감도 분류

본 연구의 비교 실험군 12 anchor method:

lpm2, hilbert, sparse_rp, hilbert_real, minibatch, chao_weighted, neuram, pca1d, reservoir, thompson_sampling, hyperloglog, opq, pq.

3-axis 분류 매트릭스 (K granularity / multi-join 재학습 / cheap 근사 친화도):

Method	K granularity	Multi-jn	Cheap 근사 친화도
sparse_rp	K-sensitive (U-shape)	sensitive (-3.55p)	Indifferent
chao_weighted	K=20 sweet	sensitive (-2.63p)	Friendly
hilbert_real	K-robust	robust	Hostile (CaseA harmful)
hyperloglog	K-robust	robust	Friendly

K granularity 와 multi-table 재계층화 두 axis 는 method 별 민감도 분류가 일치 (sparse_rp + chao_weighted sensitive vs hilbert_real + hyperloglog robust). 그러나 저비용 근사 친화도는 다른 분류 (Friendly: hyperloglog + chao_weighted). 즉 method 의 내부 메커니즘이 측정 영역에 따라 다른 영향을 미친다. 2 axis 일치는 method-level consistency 의 evidence 이지만, 1 axis 다른 분류는 단순 sensitivity 분류로 환원되지 않는 점을 정직하게 표기.

작성: 2026-05-14 KST · 조현빈 · v2 (4차 정정)