

속도는벡터

연세대학교
2026 캠퍼스 디자인

벡터 분석 쿼리의 카디널리티 추정을 위한 분포 인지 표본 선택

박세은 · 강재현 · 조현빈 · 이동욱 · 지도교수 박광현 교수

1 연구 배경

데이터베이스는 쿼리를 실행하기 전, 조건을 만족하는 행이 몇 개일지 — 카디널리티 — 를 추정한다. 이 추정이 틀리면 잘못된 실행 계획으로 쿼리가 느려진다.



기존 벡터 데이터베이스는 데이터 분포를 보지 않고 데이터와 무관한 고정 비율로 어림한다 — 추정이 크게 어긋날 수밖에 없다.

2 우리 방법

논문 Exqutor의 추정 알고리즘은 그대로 두고, 표본을 뽑는 방식 하나만 바꾼다. 데이터가 한쪽으로 쏠려 있을 때, 무작위는 쏠린 곳만 뽑지만 분포를 반영하면 골고루 뽑는다.



3 측정 설계



세 가지 방식을 똑같은 데이터·조건으로 한 측정에서 동시에 비교하고, 다섯 측을 교차해 측정했다.

기준 방식	완전 대체	결합		
논문 그대로의 무작위 — 비교의 기준	무작위를 우리 표본으로 통째 교체	두 추정값을 평균 — 우리가 제안하는 방식		
데이터셋 9종 96~1024차원	데이터 규모 10만~ 1000만 행	쿼리 조건 0.1 · 1 · 10%	표본 선택 방법 16가지	그룹 수 10 · 20 · 30개

다섯 측을 빠짐없이 교차 — 단일 벡터와 다중 벡터를 아우른다

1508번 측정

4 핵심 결과



5 결론

- 분포를 반영한 표본 선택이 추정 오차를 89.1%에서 줄였다.
- 통째 교체는 불안정 — 두 추정값의 결합이 답이다.
- 선택도·데이터 구조·그룹 수, 모든 조건에서 일관되게 우월하다.
- 데이터 유형에 따라 표본 선택 방법을 자동으로 고르는 방식을 제안한다.

다음 단계 — 다른 데이터베이스 엔진에서도 같은 효과가 있는지 검증해 나간다.

▶ 소개 영상 보기
동영상 업로드 후 QR이 삽입됩니다

QR 삽입 예정