

속도는벡터 — 6/11 결과보고서 표지·소중 요약본 내용

작성: 2026-05-19 · 팀 「속도는벡터」(연세대학교) 용도: 학교 공식 .hwp 양식 두 종 — 「종합설계 결과보고서 표지 양식」과 「산학협력프로젝트결과보고서(소중 요약본)」 — 에 전사할 내용 정리본. 표기 규칙 — **[팀 기입]**: 학번·예산 등 행정 데이터로 팀이 records에서 확인해 채운다. **[팀 확정]**: 팀 합의가 필요한 항목. 함께 제공되는 .hwp 재현본을 한컴오피스에서 바로 열어 편집·제출해도 된다.

1. 종합설계 결과보고서 표지

항목	내용
문서명	산학협력 프로젝트 결과보고서
제출일	2026. 06. 11.
프로젝트명	분포 인지 표본 선택을 통한 벡터 증강 분석 쿼리 카디널리티 추정 정확도 검증 [팀 확정]
팀명	속도는벡터
지도교수명	박광현 교수
수행기간	2026년 3월 ~ 2026년 6월

개요

본 연구는 벡터 증강 분석 쿼리(VAQ)의 카디널리티 추정에서 표본을 뽑는 방식이 추정 정확도에 미치는 효과를 검증하였다. Exquor 논문(arXiv:2512.09695v2) §V-B의 무작위 베르누이 표본 추출을 분포 인지 증화 표본 추출과 결합하는 단일 개입을, 다섯 데이터셋과 다섯 조작 변인에 걸쳐 1,508건의 3-way 대응 측정으로 평가하였다. 결합 방식(CaseB)은 대조군 대비 89.1%의 측정에서 Q-error가 개선되어, 표본 예산을 늘리지 않고도 추정 정확도를 일관되게 높일 수 있음을 확인하였다.

프로젝트명 변경 (수행계획서 대비)

- **(변경 전 프로젝트명)** 벡터 증강 분석 쿼리(VAQ)를 위한 Cascaded Vector Similarity Decomposition 연구
- **(변경 사유)** 수행계획서 단계의 쿼리 구조 분해(Cascaded Vector Similarity Decomposition) 접근은, 1차 산학 자문과 초기 실험을 거치며 카디널리티 추정 파이프라인의 표본 선택 단계 개입 — 무작위 베르누이 표본 추출을 분포 인지 증화 표본 추출로 바꾸는 방식 — 의 효과를 검증하는 연구로 구체화되었다.

멘토

소속	직위	성명
삼성전자 AI센터	[팀 기입]	박성원

팀원 (4명)

소속	학과	학번	성명
인공지능융합대학	컴퓨터과학과	[팀 기입]	박세은 (팀장)
인공지능융합대학	컴퓨터과학과	[팀 기입]	강재현
인공지능융합대학	컴퓨터과학과	[팀 기입]	조현빈
인공지능융합대학	컴퓨터과학과	[팀 기입]	이동욱

2. 산학협력 프로젝트 결과보고서 (소중 요약본)

항목	내용
프로젝트명	분포 인지 표본 선택을 통한 벡터 증강 분석 쿼리 카디널리티 추정 정확도 검증 [팀 확정]
협력기관(국가)	삼성전자 AI센터 (한국) [팀 확인 — 수행계획서엔 미기재]
과제책임자	박광현 교수
수행기간	2026년 3월 ~ 2026년 6월 (약 4개월)
소요예산	[팀 기입] 천원
소요예산 세부내역	[팀 기입] — 예: 자문료(멘토 자문), 회의비 등

참여인원

구분	인원수	성명(모두 기재)
교수	1	박광현
학부생	4	박세은, 강재현, 조현빈, 이동욱 (컴퓨터과학과)
기업체	1	박성원
계	6	—

추진배경

- 이미지·텍스트 등 비정형 데이터를 임베딩한 고차원 벡터와 정형 데이터를 함께 다루는 벡터 증강 분석 쿼리(VAQ)가 RAG·추천·멀티모달 검색의 핵심 워크로드로 자리잡았다. VAQ를 효율적으로 실행하려면 쿼리 옵티마이저가 카디널리티를 정확히 추정해야 하나, pgvector·VBASE·DuckDB 등 주요 시스템은 거리 조건의 선택도를 각각 33.3%·50%·100%의 고정 비율로 가정하여 데이터 분포를 반영하지 못한다.
- Exquitor 논문(arXiv:2512.09695v2)은 인덱스가 없을 때 무작위 베르누이 표본 추출에 모멘텀 기반 동적 조정을 더한 적응적 표본 추출로 이 문제를 보완한다. 그러나 무작위 베르누이 추출은 데이터 공간의 구조를 구분하지 않는 비계층 추출이라, 데이터가 특정 구간에 몰릴 때 표본의 대표성이 떨어지고 추정량의 분산이 커진다. 표본을 뽑는 방식을 분포 인지 층화 표본 추출로 바꾸는 단일 개입이 추정 오차를 실제로 개선하는지 측정으로 검증할 필요가 있다.

목표 및 내용

- 본 연구의 목표는 카디널리티 추정 파이프라인에서 표본 선택 단계 하나만을 통제 변인으로 삼아, 그 개입의 효과를 전 측정 조건에 걸쳐 정량 검증하는 것이다. 카디널리티 추정 알고리즘과 모멘텀 보정식, 표본 예산 $N=385$ 는 모두 Exqutor 논문의 것을 그대로 유지한다.
- 측정은 세 갈래(3-way)로 짝지어 수행하였다 — 대조군 B1(논문 그대로의 무작위 베르누이 표본 추출), 완전 대체 (CaseA, 베르누이 표본을 분포 인지 층화 표본으로 통째 치환한 음성 대조군), 결합(CaseB, 두 추정값을 산술 평균으로 묶은 방식).
- 다섯 데이터셋(DEEP·SIFT·SimSearchNet++·WIKI·YFCC)과 직접 합성한 다중 벡터 데이터셋에 걸쳐, 선택도·표본 선택 method·데이터 구조·규모·계층 수 K 의 다섯 조작 변인을 교차하여 총 1,508건의 3-way 대응 측정을 설계·수행하였다.

수행결과

- 결합(CaseB)은 대조군 B1 대비 1,508건의 측정 가운데 1,344건, 곧 89.1%에서 Q-error가 개선되었으며 개선 폭의 중앙값은 -4.38%였다. 반면 음성 대조군인 완전 대체(CaseA)는 개선 비율이 35.2%에 그쳐, 추정 정확도 향상의 원천이 분포 인지 방식으로의 단순 교체가 아니라 두 방식을 함께 쓰는 결합에 있음을 입증하였다.
- 표본 선택 method 16종 가운데 13종이 견고하게 우월하였으며(개선 측정 비율 84% 이상), 선택도가 높아질수록 개선 폭이 커지는 단조 패턴이 확인되었다. 이 개선은 표본 예산 $N=385$ 를 늘리지 않고 같은 예산 안에서 표본을 뽑는 계층만 분포 인지 층화로 바꾼 결과다.
- 측정 결과를 토대로, 데이터셋의 규모·구조·차원을 읽어 적합한 표본 선택 method를 자동으로 고르는 동적 method 선택 모델을 제안하였다.

다음 단계 (팀 작업): 위 내용을 학교 공식 .hwp 양식 두 종에 전사한다. [팀 기입] 항목(팀원 4명 학번, 멘토 직위, 소요예산·세부내역)은 행정 records에서 확인해 채우고, [팀 확정] 프로젝트명은 팀 합의로 최종 확정한다. 함께 제공된 .hwp 재현본을 한컴오피스에서 열어 바로 편집·제출하는 것도 가능하다.