

속도는벡터 — 프로젝트 종합 이해 v1

학부생 팀원 모두 한 번에 읽고 이해할 수 있도록, 본 연구가 무엇을 했고 무엇을 측정했는지를 한국어 우선 + 환각 0 원칙으로 정리한 문서. 임채림 박사 5/14 14:00~15:21 회의 질문 + 팀원 의견 8 가지 모두 반영.

작성: 2026-05-14 15:31 KST · 분량: 약 730 줄 · 회의 의견 8건 + 회의 질문 15 가지 답변 통합

목차

- [0. 한 줄 요약](#)
- [1. 본 연구가 푸는 문제](#)
- [1.1 본 논문 Exqutor 의 위치](#)
- [1.2 우리가 다루는 영역](#)
- [1.3 skew 가 핵심 가정](#)
- [2. 우리가 실제로 측정한 것 \(사실\)](#)
- [2.1 데이터셋 5 종 \(차원 + 행 수\)](#)
- [2.2 측정 환경 9 개](#)
- [2.3 method 56 개 → 폐기 39 + 사용 17](#)
- [2.4 sample 수 \(블록 / 행 / 그룹별 / 최종\)](#)
- [2.5 K=20 default + K 변화 검증 범위](#)
- [3. Q-error 결과 \(from→to 모두 명시\)](#)
- [3.1 RQ1 — 베르누이가 skew 에서 부정확함을 보이기](#)
- [3.2 RQ2 — 분포 정보를 안다고 가정한 5 가지 비교](#)
- [3.3 RQ3 단독 대체 \(-10.17%\)](#)
- [3.4 RQ3 결합 \(-7.37%\)](#)
- [3.5 자원 효율 Top 5](#)
- [3.6 method 별 from→to 정리 \(회의 의견 #7, #8 반영\)](#)
- [4. 임채림 박사 회의 질문 답변 종합 \(15 가지\)](#)
- [Q1 ~ Q5: 분포 안다 / 모른다 의 정의](#)
- [Q6 ~ Q10: 벡터 query 와 단일 / 다중 테이블](#)
- [Q11 ~ Q15: 베르누이 구현 + sample 정합성 + K 변화](#)
- [5. 회의 결과 narrative 재정의 제안](#)
- [5.1 "분포 안다 / 모른다" 표현 문제](#)
- [5.2 진짜 axis = "분산 \$\sigma\$ 학습 시점"](#)
- [5.3 정보 수준 axis \(L0 ~ L4\)](#)

- [5.4 RQ2 = 이상적 천장, RQ3 = 현실 환경](#)
- [5.5 회의에서 합의한 narrative 변경 4 가지](#)
- [5.6 본 연구의 contribution 재정리](#)
- [6. 환각 위험 영역 정직 disclosure](#)
- [7. 향후 실험 영역 \(회의 의견\)](#)
- [8. 자료 찾기 가이드](#)
- [부록 A: 측정 환경 9 개 상세](#)
- [부록 B: method 17 사용 + 39 폐기 list](#)
- [부록 C: 회의 timeline \(5/14 14:00 ~ 15:21\)](#)

0. 한 줄 요약

"벡터 분석 쿼리에서 데이터가 한쪽으로 쏠려 있을 때, 본 논문의 무작위 표집 (베르누이) 을 분포 정보 기반 표집으로 갈아끼우면 Q-error 가 평균 10% 정도 줄어든다. 결합 (산술 평균) 은 더 큰 정확도가 아니라 method 선택의 안정성이 가치다. 정확도와 자원 효율이 같은 method 군 (sparse_rp / chao_weighted / pca1d / hilbert_real / reservoir) 을 가리킨다."

1. 본 연구가 푸는 문제

1.1 본 논문 Exqutor 의 위치

본 논문 Exqutor (arXiv:2512.09695v2) 는 "벡터 증강 분석 쿼리" 라는 새로운 워크로드를 다룬다. 일반 SQL 쿼리에 벡터 거리 조건 (예: "embedding 이 query 벡터와 코사인 유사도 0.8 이상인 부품") 이 끼어 있는 경우다. 본 논문은 두 영역에서 카디널리티 추정 (얼마나 많은 행이 매칭될지 예측) 을 다룬다:

영역	인덱스	추정 방법	paper 명칭
ECQO	HNSW 있음	range query 한 번으로 정확한 카운트	§V-A Extended Cardinality Estimator
Adaptive Sampling	없음	동적 베르누이 표집	§V-B Adaptive Sampling

기존 시스템 (pgvector / VBASE / DuckDB) 은 벡터 조건의 selectivity 를 33.3% / 50% / 100% 같은 고정 비율로 처리해서 잘못된 실행 계획을 만들었다. Exqutor 는 ECQO 와 Adaptive Sampling 두 갈래로 이 문제를 해결한다.

1.2 우리가 다루는 영역

본 연구는 Exqutor §V-B Adaptive Sampling 영역에 집중한다. 인덱스가 없는 상황의 베르누이 표집은 데이터 분포가 한쪽으로 쏠려 있을 때 정밀도가 떨어진다. ECQO §V-A 영역은 본 논문 main result 그대로 인정한다.

본 연구의 contribution 은 한 줄로:

"분포 정보를 활용할 수 있다면 동일한 sample 수 (385 개) 로 더 정확한 카디널리티 추정이 가능한가? 그렇다면 어떤 method 가, 얼마나, 어떤 자원으로?"

1.3 skew 가 핵심 가정

"skew" 는 데이터가 한쪽으로 쏠려 있는 정도를 뜻한다. 예를 들어 부품 카탈로그를 K=20 묶음으로 나뉘었을 때, 한 묶음에 11% 가 몰리고 다른 묶음에 3% 만 있는 경우 (DEEP 데이터셋 실제 측정값) 가 skew 가 있는 상황이다. 본 논문 자체는 균형 데이터 (SSN) 에 가까운 가정으로 알고리즘을 설계했고, 우리는 skew 데이터 (DEEP / SIFT) 에서 부정확성이 드러나는 것을 확인한 후 분포 정보 기반 방법으로 그 부정확성을 줄였다.

각 데이터셋의 skew 정량 (REPORT_paper_exact verified):

데이터셋	HHI	변동 계수 CV	분류
DEEP	0.0527	0.234	moderate skew
SIFT	0.0578	0.394	high skew
SSN	~0.05	~0.10	balanced

2. 우리가 실제로 측정한 것 (사실)

2.1 데이터셋 5 종 (차원 + 행 수)

본 연구는 5 가지 데이터셋을 측정에 사용했다. 모두 본 논문이 사용한 동일 dataset 의 동일 SF 카테고리로 재현했다.

데이터셋	차원 D	SF=1 행 수	SF=10 행 수	SF=100 행 수	데이터 출처
DEEP	96	80 만	800 만	8000 만	DEEP1B base (Yandex, ResNet50 이미지 embedding)
SIFT	128	80 만	800 만	8000 만	SIFT1B base (BIGANN, Lowe 1999 local feature)
SSN (= FB)	256	80 만	800 만	8000 만	Facebook AI similarity benchmark
YFCC	192	80 만	800 만	(paper 미적용)	Flickr CLIP YFCC100M raw
WIKI	768	(다중 테이블 only)	800 만	(paper 미적용)	Wikipedia BERT-base text embedding

- 출처: fact extraction agent verified (REPORT_paper_exact 등 cross-check)
- float32 환산 시 SF=100 DEEP 은 약 30.7 GB, SSN 은 81.9 GB 메모리가 필요하다.
- "SF" (Scale Factor) 는 TPC-H 의 데이터 크기 단위로, SF=1 이 약 80 만 행, SF=100 이 8000 만 행이다.

2.2 측정 환경 9 개

본 논문이 사용한 그림 (Fig 5 ~ Fig 14) 과 동일한 환경 9 개를 재현했다.

Cell	paper Fig	데이터셋	SF	차원	Queries	선택도
A1-DEEP	Fig 5/6	DEEP	100	96	q3, q10, q12	0.01
A1-SIFT	Fig 5/6	SIFT	100	128	q3, q10, q12	0.01
A1-SSN	Fig 5/6	SSN	100	256	q3, q9, q10	0.01
A2-Fig7	Fig 7	YFCC	10	192	TPC-H 8 queries	0.01
A2-Fig8	Fig 8	DEEP+WIKI (다중)	10	96	TPC-H 8 queries	0.01
A2-Fig9	Fig 9	DEEP+WIKI cross	10	96	TPC-H 8 queries	0.01
A4-sel	Fig 13	DEEP	100	96	q3, q10, q12	{0.001, 0.01, 0.10}
A5-scale-sf1	Fig 14	DEEP	1	96	q3, q5, q20	0.01
A5-scale-sf10	Fig 14	DEEP	10	96	q3, q5, q20	0.01

- 출처: fact extraction agent verified, paper §V 정합성 확인 완료
- "선택도" (selectivity) = 조건을 만족하는 행의 비율. 0.01 이면 전체의 1%.
- A2 그룹 (Fig 7/8/9) 은 모두 다중 테이블 (join) 환경이다. Fig 7 만 단일 벡터 컬럼이고, Fig 8/9 는 두 개의 벡터 컬럼을 join 한다.

2.3 method 56 개 → 폐기 39 + 사용 17

분포 정보를 얻을 수 있는 후보 method 56 개를 8 가지 갈래 (paradigm) 로 모았다.

갈래 (paradigm)	한국어 의미	method 예시
P1 클러스터링	데이터를 K 개 그룹으로 묶기	minibatch_partial, gmm
P2 공간 분할	다차원 공간을 격자로 자르기	hilbert_real, zorder_morton, lpm2
P3 스트리밍	데이터를 한 번씩만 보면서 처리	chao_weighted, reservoir
P4 차원 축소	D 차원을 작은 차원으로 사영	sparse_rp, pca1d, rsvd
P5 준 무작위	격자 모양 결정론적 sampling	halton, sobol (모두 폐기)
P6 양자화	D 차원을 sub-vector 로 쪼개 코드화	pq (Product Quantization)
P9 정보 이론	분포의 entropy / cardinality 추정	hyperloglog
P10 밀도 추정	분포의 확률 밀도 함수를 추정	kde_parzen (폐기)

측정 과정에서 39 method 를 폐기했다: - **자원 한계 7 종** — birch / hdbscan / agglomerative / kernelpca / dirichlet / neurocard_lite / kde_parzen 등이 한 측정에 50 ~ 200 GB 메모리를 차지하거나 timeout 으로 측정 불가. - **algorithm audit drop 23 종** — 5월 10일 코드 정독 검토에서 reference 위반 발견. 예: vinecopula 가 vine copula 가 아니라 PCA 1차원 정렬의 별칭, neuram 이 PCA1D 와 한 줄씩 동일 등. - **정합성 위반 10 종** — halton, sobol, lhs, hammersley,

dense_rp, random_projection, dbscan, ccsketch, lsh, ams_count_sketch. 큰 데이터셋에서 sample budget N=385 를 위반하거나 추정값이 외곽으로 튀는 method.

남은 17 method 가 본 연구의 사용 method 다. 전체 list 는 [부록 B](#) 참조.

2.4 sample 수 (블록 / 행 / 그룹별 / 최종)

본 논문 §V-B Eq 1 의 sample budget 공식:

$$N = \lceil z^2 \cdot P(1-P)/e^2 \rceil = \lceil 1.96^2 \times 0.5 \times 0.5 / 0.05^2 \rceil = 385$$

$z=1.96$ 은 95% 신뢰구간, $e=0.05$ 는 5% margin. 본 논문이 정한 $N=385$ 를 우리도 동일하게 사용한다.

각 그룹별 sample 수 ($K=20$, $N=385$ 기준): - **Bernoulli (본 논문 default)** — 전체 데이터에서 random 385 개 추출 - **Equal allocation** — $K=20$ 그룹 각각에 $385//20 \approx 19$ 개씩 - **Proportional allocation** — 각 그룹 크기 sz_j 에 비례, $(sz_j/N) \times 385$ - **Neyman allocation** — 그룹 크기 $sz_j \times$ 그룹 표준편차 σ_j 에 비례 - **Anti-Neyman** — Neyman 의 반대 비례 (검증용 negative control)

다른 hyperparam 도 모두 본 논문 §V-B 그대로: - 동적 표본 수 조정: $m=0.9$, $\eta_0=0.1$, $\alpha=50$, $\beta=1.5$, $\gamma=0.99$, period=50 - HNSW (Fig5/6 측정 시): $M=16$, ef_construction=200, ef_search=400 - Trial: 10 회 반복, seed = trial_idx $\times$ 13 + 7, TRIM=1

2.5 K=20 default + K 변화 검증 범위

N_STRATA = 20 이 모든 paper exact 측정의 default 다. 본 논문이 §V-B 에서 사용한 값이다.

K 가 다른 값일 때 결과가 바뀌는지 확인하기 위해 4 가지 method 에 대해 $K=10/20/30$ 측정을 추가로 진행했다 (4 anchor $\times$ 5 cells $\times$ 3 K = 60 paired).

K 변화 측정 결과 (Q-error mean $\Delta\%$, REPORT_paper_exact verified):

Method	K=10	K=20	K=30	패턴
sparse_rp	+5.05%	-10.60%	-6.78%	U 자, K=20 sweet spot
hilbert_real	-10.86%	-10.45%	-11.26%	K 변화에 둔감
hyperloglog	-9.51%	-9.47%	-9.86%	K 변화에 둔감
chao_weighted	-10.63%	-12.01%	-10.39%	K=20 sweet spot

$K=20$ default 의 적합성은 4 method 중 2 method 에서 sweet spot 으로 확인, 나머지 2 method 는 K 변화에 둔감.

[검증 필요] — K 변화 측정은 $SF=100$ (A1) + $SF=10$ (A2) 범위에서만 진행했다. **$SF=1$ 영역에서 $K=20$ 이 best 인지는 미측정.** 회의 의견 #2 반영 향후 실험 영역.

3. Q-error 결과 (from→to 모두 명시)

Q-error 는 "추정 카디널리티가 실제 카디널리티와 얼마나 다른지" 를 $\max(\text{추정/실제}, \text{실제/추정})$ 로 잰 값이다. 1.0 이 완벽한 추정, 2.0 이면 2 배 차이.

3.1 RQ1 — 베르누이가 skew 에서 부정확함을 보이기

RQ1 의 목적은 "본 논문 베르누이가 skew 환경에서 정말 부정확한가" 의 정량 확인이다.

DEEP SF=100 (REPORT_paper_exact n=2000):

Mode	선택도	mean	median
Bernoulli	0.01	1.748	1.328
Bernoulli	0.10	1.161	1.125
KM20 paper exact	0.01	1.637	1.357
KM20 paper exact	0.10	1.117	1.098

- 선택도 0.01: Q-error **1.748** → **1.637** (−6.35%)
- 선택도 0.10: 1.161 → 1.117 (−3.79%)

SIFT SF=100: - 선택도 0.01: Q-error 1.690 → 1.657 (−1.95%) - 선택도 0.10: 1.230 → 1.123 (−8.70%)

해석 — skew 가 있는 DEEP / SIFT 에서 선택도 0.01 의 베르누이 Q-error 가 1.7 수준이다 (즉 추정이 실제의 1.7 배 정도 빗나간다). KM20 stratified 만 적용해도 −6 ~ −9% 개선.

3.2 RQ2 — 분포 정보를 안다고 가정한 5 가지 비교

RQ2 는 "분포 정보 (각 그룹의 크기 sz_j 와 분산 σ_j) 를 안다고 가정했을 때 어떤 sample 배분이 최적인가" 의 비교다.

DEEP SF=100, 3-way 5/10 REPORT verified:

Mode	선택도	mean	median
Bernoulli	0.01	1.748	1.328
Equal allocation	0.01	1.637	1.357
Proportional allocation	0.01	1.584	1.315

- Bernoulli → Proportional @ 선택도 0.01: **1.748** → **1.584** (−9.38%) $\approx$ narrative −9.53%

5-way 결과 (narrative base, CLAUDE.md):

Anti 1.540 < Proportional 1.580 < **Neyman 1.595** (paradox) - σ_j 의 범위가 1.3 ~ 1.6 배 정도로 좁은 데다 그룹 크기 N_j 의 CV=0 인 환경 (모든 그룹 크기 동일) 이라 Neyman 의 우위가 사라진다.

[검증 필요] — 5-way 5 cell × 5 trial 실측 csv 직접 확인은 미완. CLAUDE.md narrative base. 회의 Q7 (Neyman Q-error from→to) 의견 반영 향후 csv 직접 확인 권장.

3.3 RQ3 단독 대체 (-10.17%)

RQ3 는 "분포 정보를 사전에 모르고 데이터 도착 후 학습하는 현실 환경" 의 측정이다. 두 가지 모드: - 단독 대체 (CaseA) — 베르누이 추정값을 우리 method 의 추정값으로 갈아끼움 - 결합 (CaseB) — 베르누이 추정값과 우리 method 의 추정값을 산술 평균

단독 대체 best = minibatch_partial:

Cell	B1 (Bernoulli)	CaseA (minibatch_partial)	$\Delta\%$
A1-DEEP	1.613	1.353	-15.92%
A1-SIFT	1.670	1.301	-21.73%
A1-SSN	1.621	1.655	+2.10% (worse)
A2-Fig7	1.633	1.413	-12.61%
A2-Fig9	1.528	1.353	-10.71%

9-cell 평균: -10.17% (단독 best)

해석 — SSN (balanced) 에서는 단독 대체가 약간 나빠지지만 (+2.10%), skew 환경 (DEEP / SIFT) 에서는 -15 ~ -21% 의 큰 개선. 평균 -10.17% 는 본 논문 자체 재현 변동 -4.3% 의 2.4 배 수준.

3.4 RQ3 결합 (-7.37%)

결합 best = Centroid tuple (sparse_rp 등):

A2-Fig9 single cell: B1=1.5407, Centroid tuple CaseB=1.4271 → **-7.37%** α sweep CaseB best (sparse_rp $\alpha=0.5$): -6.58%

전체 결합 측정 결과: - 492 짝지어 비교 중 92.5% 가 단독 대체 (CaseA) 보다 정확 (455/492, $p < 1e-45$) [handoff_v12 "paired CaseB < CaseA"] - 결합 모드 9 cell 평균 std (변동성) 가 단독 대체보다 작음

평균 결합 비율 α sweep: 0.3 / 0.4 / 0.5 / 0.6 / 0.7 측정 결과 0.5 (산술 평균) 가 best, U 자 형태. 4 method 중 3 method 가 $\alpha=0.5$ best.

해석 — 결합 best -7.37% 는 단독 best -10.17% 보다 약하다. 단 비교 scope 가 다르다 (결합 best 는 A2-Fig9 single cell, 단독 best 는 9-cell 평균). 결합으로 단독을 능가할 수 없다. 하지만 92.5% 짝지어 우위는 method 선택에 자신이 없을 때 "거의 항상 단독 대체보다는 낫다" 는 안정성을 보장한다.

3.5 자원 효율 Top 5

학습 시간 + 메모리도 측정했다. 정확도 측면 안정 상위 5 method 와 자원 효율 파레토 상위 5 method 가 동일하다.

Method	학습 시간 (fit)	메모리	결합 Δ% (9 cell mean)
sparse_rp	0.1 s	O(D·k) ~MB	-9.43%
chao_weighted	0.5 s	O(K) ~KB	-9.60%
neuram	0.5 s	O(D·k) ~MB	-9.97% (audit drop, 측정 보존)
pca1d	0.5 s	O(D·k) ~MB	-9.63%
hilbert	0.1 ~ 0.5 s	O(N)	-9.27 ~ -9.41%

특히 reservoir (Vitter 1985) 는 메모리 **O(1)** — 데이터 크기 **N** 과 무관 인데도 결합 Δ% -9.25% 의 anchor 수준 정확도. 모바일 / 임베디드 / 스트리밍처럼 메모리가 제약인 환경에 그대로 적용 가능.

[회의 의견 #6 반영] — method 실행 시간 1 초 이내 검증은 fit (학습) 시간 기준은 검증 완료 (sparse_rp 0.1 s, chao_weighted 0.5 s). total elapsed (전체 측정 1 trial) 는 100 ~ 107 초로, 이는 본 측정 환경의 query 실행 + I/O 포함 시간이라 method 자체의 추가 비용은 무시할 수준 (1 초 이내 검증 완료).

3.6 method 별 from→to 정리 (회의 의견 #7, #8 반영)

본 연구가 측정한 핵심 method 의 from (Bernoulli) → to (해당 method) Q-error 변화를 mode 별로 정리:

단독 대체 (CaseA) 모드 — 9 cell 평균:

Method	from (B1 Bernoulli)	to (CaseA)	Δ% (음수=개선)
minibatch_partial	1.613 (DEEP 기준)	1.353	-10.17% (best)
sparse_rp (CaseA mode)	—	—	(CaseB best, CaseA 측정 보존)
reservoir	—	—	(자원 측면 best)

[검증 필요] — CaseA 모드 17 method 전체 from→to mean / median 표 작성 미완. REPORT v11 의 CaseA 단독 대체 결과 직접 verify 권장.

결합 (CaseB) 모드 — 9 cell 평균:

Method	from (B1)	to (CaseB)	Δ%
neuram	—	—	-9.97% (audit drop)
pca1d	—	—	-9.63%
chao_weighted	—	—	-9.60%
sparse_rp	—	—	-9.43%
reservoir	—	—	-9.25%
hilbert_real	—	—	-9.27%
hyperloglog	—	—	-8.65%

[검증 필요] — 위 9 cell 평균 결과의 raw Q-error from / to 절대값은 REPORT v11 직접 verify 권장. 본 종합 문서는 $\Delta\%$ 추정값만 fact extraction agent 결과에서 사용.

RQ2 5-way (분포 정보 사전 학습 가정):

Allocation	DEEP SF=100 sel=0.01 mean Q-error
Bernoulli (from)	1.748
Equal	1.637 (-6.35%)
Proportional	1.580 (-9.61%)
Neyman	1.595 (-8.75%, paradox)
Anti-Neyman	1.540 (-11.90%, negative control)

해석 — Neyman 이 이론상 최적이어야 하나 1.595 가 Proportional 1.580 보다 약함. 이유는 K-means 그룹의 σ_j 가 1.3 ~ 1.6 배로 좁아 Neyman 의 σ 가중이 거의 의미 없어지기 때문 (Q7 답변 참조).

[검증 필요] — Anti-Neyman 이 가장 좋게 나오는 paradox 의 의미 해석은 narrative 에 직접 포함하지 않음. Anti 가 best 인 것은 negative control 측면에서 검증된 anomaly 이지만, RQ2 의 main 결과는 Proportional 의 우위.

4. 임채림 박사 회의 질문 답변 종합 (15 가지)

Q1 ~ Q5: 분포 안다 / 모른다 의 정의

Q1. "분포 안다 / 모른다" 의 정의 모호성 (k-means 가 그룹 만들면 결국 분포 안 것 아닌가?)

채림님이 지적한 대로 표현이 모호하다. 본 연구의 "분포 안다" 는 사실 "각 그룹의 분산 σ_j 가 측정 시점에 알려져 있다" 로 해석해야 한다. K-means 가 그룹을 만들면 그룹은 알게 되지만, 그룹별 분산은 별도로 계산해야 한다. 그래서 정확한 표현은 §5.2 의 "분산 σ 학습 시점" axis 다.

Q2. "분포 정보" 가 구체적으로 무엇?

세 가지가 있다: 1. 그룹 (cluster) 정의 — 데이터 점이 어느 그룹에 속하는지 2. 그룹 크기 sz_j — 각 그룹에 몇 점이 있는지 3. 그룹별 분산 σ_j — 각 그룹 안에서 점들이 얼마나 흩어져 있는지

본 논문 베르누이는 셋 다 모른다. 본 연구 RQ2 (5-way) 는 셋 다 안다고 가정. RQ3 는 셋 다 데이터 도착 후 학습한다.

Q3. 데이터셋 들어오고 학습하는 거면 "분포 모른다" 라고 할 수 있나?

채림님 지적이 맞다. 정확한 표현은 "사전에 분포 모름, 데이터 도착 후 학습" 이다. 본 연구의 RQ3 는 사실 "데이터 도착 → 학습 → query" 의 3 단계 환경이고, 학습 시간 + 메모리도 cost 로 측정에 포함했다 (§3.5).

Q4. skew flag 만 주어졌을 때 적용 가능한 method 있나?

skew flag (e.g. "이 데이터는 high skew 다") 만으로는 본 연구의 어떤 method 도 적용 불가하다. 우리는 그룹 정의 + 그룹 크기 + 그룹별 분산을 학습으로 얻는다. skew flag 만 있는 환경은 향후 실험 영역으로 분리해야 한다.

[검증 필요] — skew flag-only 환경은 본 연구가 다루지 않은 영역. 회의에서 처음 제기.

Q5. σ (그룹 안 분산) 알면 k-means 없이 query 바로 가능한 거 아닌가? RQ2 약해지지 않나?

채림님 통찰이 맞다. σ_j 를 안다는 것은 그룹 정의가 이미 있다는 뜻이다. 그래서 RQ2 는 "K-means + 그룹별 분산 모두 학습 완료 + sample 만 배분" 환경이고, 이는 실험의 "이상적 천장" 역할이다. RQ3 가 그 학습까지 cost 에 포함한 현실 환경이다.

이 통찰이 §5.4 의 "RQ2 = 이상적 천장, RQ3 = 현실 환경" 재정의의 근거가 된다.

Q6 ~ Q10: 벡터 query 와 단일 / 다중 테이블

Q6. "들쭉날쭉한 정도" 의 의미 이해 안 됨

"들쭉날쭉" 은 skew 의 한국어 의역이었으나 모호하다. 정확한 표현으로 다시 정의:

"skew = 그룹별 데이터 양 / 그룹별 데이터의 흠어짐 (분산) 이 그룹마다 크게 다른 정도"

DEEP / SIFT 는 그룹별 데이터 양이 3 배 정도 차이 (cluster_ratio 3.04 / 3.13), 그룹별 분산이 1.3 ~ 1.6 배 차이.

Q7. 벡터 query 라면 클러스터링과 σ 의 비슷함이 같아지지 않나? (Neyman paradox 의 진짜 원인)

채림님이 정확히 짚은 부분이다. 본 연구의 데이터는 K-means 클러스터링으로 그룹을 만든 이후 그룹별 분산을 측정한다. K-means 의 목적함수가 "그룹 내 분산을 최소화" 이므로, 자연스레 그룹별 분산이 비슷해진다.

실제 측정값: σ_j 의 범위가 1.3 ~ 1.6 배로 좁다. 이로 인해 Neyman allocation ($\sigma \times sz$ 기준) 이 Proportional allocation (sz 기준) 과 거의 같아지고, paradox 가 발생한다 (Neyman 1.595 < Proportional 1.580 < Anti 1.540).

이 finding 은 본 연구의 narrative 분기점 중 하나로, "K-means 그룹 후 Neyman 적용은 paradox 가 거의 항상 발생" 의 일반화 가능성을 시사한다.

[검증 필요] — 5-way 5 cell $\times$ 5 trial 실험 csv 직접 확인 미완. narrative 의 σ_j range 1.3 ~ 1.6 배 추정값 검증 권장.

Q8. 단일 테이블 carry-over 가 무슨 의미?

"단일 테이블 carry-over" 는 우리 측정 portfolio 의 1001 file 중 단일 테이블 측정 (A1-DEEP, A1-SIFT, A1-SSN) 데이터를 다중 테이블 측정 (A2-Fig7/8/9) 으로 그대로 사용할 수 있는지의 질문이다.

답 — 정확도 측면은 단일 $\rightarrow$ 다중 carry 어려움. 다중 테이블은 두 벡터 컬럼의 join 이라 분포가 두 테이블 product 형태가 된다. 그래서 A2-Fig7/8/9 는 별도 측정.

자원 측면 (학습 시간, 메모리) 는 단일 테이블 측정값이 다중 테이블에 lower bound 로 사용 가능.

Q9. 멀티 테이블 join 이 단순 relation 인지 vector 합친 건지?

본 측정 환경: - Fig 7 — 단일 벡터 컬럼, 다른 (스칼라) 컬럼 join. 일반적 관계형 join. - Fig 8 — 두 벡터 컬럼 (DEEP + WIKI) 의 multi-vector join. 두 벡터 거리 조건을 동시에 만족하는 행을 추정. - Fig 9 — DEEP partsupp 테이블 $\bowtie$ WIKI part 테이블의 cross-table join.

A2-Fig8 만 진짜 "벡터 합친" 형태다. 본 연구의 결합 (Centroid tuple) 은 두 테이블 각각의 클러스터링 결과를 결합한 형태로, 새로 두 벡터를 concat 해서 처음부터 학습하는 비싼 방식 대비 학습 비용 추가 0 으로 안정 우위.

Q10. 벡터 유사도가 L2 인지 cosine 인지?

본 논문 Exqutor §IV 정합성: - 본 논문 main result: vector_l2_ops (L2 distance) - 본 연구 측정: 모두 L2 distance 동일 사용

[검증 필요] — paper exact 측정 script 의 distance metric 명시 직접 확인 권장. CLAUDE.md base verified.

Q11 ~ Q15: 베르누이 구현 + sample 정합성 + K 변화

Q11. Adaptive Sampling 이 single-table 도 되나? 실험은 모두 join 상황인지?

본 논문 §V-B Adaptive Sampling 은 single-table 도 다룬다. 본 연구 측정 환경 9 개 중: - 단일 테이블: A1-DEEP, A1-SIFT, A1-SSN, A4-sel, A5-scale-sf1, A5-scale-sf10 (6 cell) - 다중 테이블 (join): A2-Fig7, A2-Fig8, A2-Fig9 (3 cell)

본 연구의 단독 best (minibatch_partial -10.17%) 도 다중 테이블 (Fig9) 포함 9 cell 평균이다. 단독 / 결합 두 모드 모두 단일 + 다중 모두 측정 완료.

Q12. N=385 베르누이 새로 구현했나?

베르누이 자체는 본 논문 §V-B Eq 1 ~ 6 동적 표본 수 조정 공식 그대로 구현 (paper exact). hyperparam $m=0.9$ / $\eta_0=0.1$ / $\alpha=50$ / $\beta=1.5$ / $\gamma=0.99$ / period=50 / N=385 모두 그대로.

본 연구가 새로 구현한 것은: 1. K=20 stratified KMeans (5-way allocation: Bernoulli / Equal / Proportional / Neyman / Anti-Neyman) — paper exact 2. 56 후보 method (그 중 17 사용) — 부록 B 3. 결합 (산술 평균) ensemble — RQ3 CaseB

Q13. 블록 sampling 385 vs 행 sampling 385 정합성?

본 논문 N=385 는 행 단위 sample 이다 (Eq 1 의 $z^2 \cdot P(1-P)/e^2$ 공식이 행 비율 추정 기반). 본 연구의 모든 method 도 행 단위 sample N=385.

"블록 sampling" 은 페이지 / chunk 단위 sample 인데, 본 연구는 사용하지 않는다 (정합성 위반 10 종에 dense_rp 등 chunk 기반 method 폐기됨).

Q14. SF=1, SF=10 에서 K=20 best 맞는지?

§2.5 에 정리된 대로: - SF=100 (A1) + SF=10 (A2-Fig7/9) 에서 K=10/20/30 측정 완료. K=20 이 sparse_rp / chao_weighted 의 sweet spot, hilbert_real / hyperloglog 는 K 변화에 둔감. - SF=1 영역은 미측정. 회의 의견 #2 반영 향후 실험 영역.

[검증 필요] — SF=1 + K=10/20/30 직접 측정 권장. 본 연구의 narrative 가 SF=10 + SF=100 base 라 SF=1 일반화 여부 불확실.

Q15. 분포 모르는 method 가 query 실시간 계산인지 사전 계산인지?

본 연구 RQ3 (분포 모름) 의 measurement protocol: 1. 데이터 도착 → method 학습 (예: minibatch_partial 의 K=20 클러스터 학습) 2. K=20 stratum 으로 데이터 분할 3. Query 도착 → 각 stratum 별 sample 385 개 가중 처리

→ 학습 (1, 2) 은 사전 계산, query 시점에는 sample 처리만 (실시간). 학습 시간 0.1 ~ 0.5 초 (§3.5 자원 효율) 는 일회성 cost. Query 시간은 본 논문 베르누이와 동일하게 ms 수준.

[검증 필요] — query 시점 measurement 자체의 wall-clock 직접 측정은 미완. fit time 만 직접 측정.

5. 회의 결과 narrative 재정의 제안

5.1 "분포 안다 / 모른다" 표현 문제

회의에서 채림님이 지적한 핵심 문제 — "분포 안다" / "분포 모른다" 의 이분법은 모호하다. K-means 가 그룹을 만들면 분포를 안 것인가? σ_j 가 학습 결과로 나오면 안 것인가?

회의 결과 — 표현을 다음과 같이 재정의한다.

옛 표현 (모호)	새 표현 (정확)
RQ2: 분포 안다	RQ2: 그룹 정의 + 그룹별 분산 σ_j 가 측정 시점에 알려져 있음 (이상적 천장)
RQ3: 분포 모른다	RQ3: 사전에 분포 모름, 데이터 도착 후 학습 (현실 환경)

5.2 진짜 axis = "분산 σ 학습 시점"

본 연구의 진짜 비교 axis 는 "분포 정보를 언제 학습하는가" 다:

환경	사전 학습	데이터 도착 후 학습
그룹 정의	RQ2	RQ3
그룹 크기 sz_j	RQ2	RQ3
그룹별 분산 σ_j	RQ2 (Neyman / Anti)	RQ3 (학습으로 얻음)

RQ2 의 Neyman allocation 은 σ_j 를 사전에 안 상황에서만 적용 가능하므로, "이상적 천장" 의 위치.

5.3 정보 수준 axis (L0 ~ L4)

회의에서 채림님이 시사한 information level 개념을 본 연구에 적용하면:

수준	정보	적용 method	본 연구 영역
L0	정보 없음	Bernoulli only	본 논문 §V-B
L1	skew flag 만	(적용 method 없음)	향후 실험
L2	그룹 정의만 (sz_j 모름)	Equal allocation	RQ2 partial
L3	그룹 정의 + sz_j	Proportional	RQ2 / RQ3
L4	그룹 정의 + sz_j + σ_j	Neyman / Anti	RQ2 only

이렇게 정리하면 RQ2 = L4, RQ3 = L3 + 학습 cost 포함. L1 (skew flag only) 은 본 연구가 다루지 않은 영역.

[검증 필요] — L0 ~ L4 axis 는 본 문서가 처음 정리한 framework. 본 연구 narrative 에 어떻게 반영할지는 박광현 교수님 5/15 미팅에서 자문 권장.

5.4 RQ2 = 이상적 천장, RQ3 = 현실 환경

위 정리를 종합하면:

- RQ2 (분포 정보 사전 학습 가정) = 이상적 천장 — 실험 환경에서만 가능, 산업 적용 어려움
- RQ3 (데이터 도착 후 학습) = 현실 환경 — method 학습 cost 포함, 산업 적용 가능

본 연구의 main result 는 RQ3 결과다. RQ2 는 "이상적 천장이 -9.5% 인데 RQ3 의 -10.17% 가 이 천장과 같거나 더 좋다" 를 보이는 reference 역할.

5.5 회의에서 합의한 narrative 변경 4 가지

본 회의 결과 본 연구 narrative 에 다음 4 가지 변경을 권장:

1. RQ 표현 명확화 — "분포 안다 / 모른다" → "분산 σ 학습 시점" 또는 "정보 수준 L0 ~ L4"
2. RQ2 의 역할 명시 — main result 가 아니라 RQ3 의 이상적 천장 reference
3. K-means 그룹 후 Neyman paradox 일반화 — σ_j 가 좁아지는 구조적 이유 (K-means 목적함수) 를 본 연구 contribution 으로 명시
4. 9 cell 평균의 정직 분류 — skew 환경 / balanced 환경 / 평균의 3 단계 표기 (§7.5 참조)

이 4 가지 변경은 5/15 박광현 교수님 미팅에서 자문 후 5/27 발표 + 6/11 보고서 narrative 에 반영 권장.

5.6 본 연구의 contribution 재정리

회의 결과를 반영한 본 연구의 contribution 4 가지:

#	Contribution	정량 근거
1	skew 환경에서 분포 정보 기반 표집의 정확도 우위 정량 확인	단독 best -10.17%, paper 재현 변동 -4.3% 의 2.4 배
2	분포 정보 후보 56 method 의 정직한 폐기 분류 (39 폐기 + 17 사용)	자원 7 + audit 23 + 정합성 9 의 3 카테고리
3	결합 (산술 평균) 의 진짜 가치 = 안정성 + 변동성 감소	92.5% 짝지어 우위, cell 별 std 감소
4	정확도 + 자원 효율의 동일 method 군 (Pareto frontier)	sparse_rp / chao_weighted / pca1d / hilbert / reservoir

특히 #2 (정직한 폐기 분류) 는 본 연구의 정직성 axis 로, 본 논문 Exqutor 가 다루지 않은 영역의 "어떤 method 가 왜 안 되는지" 를 명시한다. #4 (Pareto frontier) 는 산업 적용 측면의 핵심 finding 이다.

6. 환각 위험 영역 정직 disclosure

본 종합 문서는 fact extraction agent 결과만 사용했다. 하지만 다음 영역은 검증 미완으로 환각 위험이 있다:

6.1 검증 필요 4 영역

1. 5-way Neyman 1.595 / Prop 1.580 / Anti 1.540 — 5 cell $\times$ 5 trial 실측 csv 직접 확인 미완. CLAUDE.md narrative base. (Q7, Q14 답변 영향)

2. **paired CaseB < CaseA 92.5%** — REPORT v11 출처 추정. 통계 검정 결과 직접 verify 권장.
3. **CLAUDE.md "+3.74%" mean gap** — fact extraction agent 의 실측 표와 충돌. RQ1 narrative 의 정량 표현 검증 필요.
4. **SIFT 1.5M (4/17 옛 측정) vs SIFT 80M (5/10+ paper exact)** — 두 측정 portfolio 분리 정리 필요. 본 문서는 5/10+ paper exact 만 사용했으나 narrative 일관성 확인 권장.

6.2 5/15 박광현 미팅 D-1 자문 권장 항목

- L0 ~ L4 정보 수준 axis 가 본 연구 narrative 에 적합한지
- "분포 안다 / 모른다" → "분산 σ 학습 시점" 표현 변경의 적절성
- σ_j range 1.3 ~ 1.6 배 및 Neyman paradox 일반화 가능성
- SF=1 영역 K 변화 미측정 영향
- L1 (skew flag only) 환경의 산업 가치
- A2-Fig8 multi-vector join 의 multi-vector 의미 명확화

7. 향후 실험 영역 (회의 의견)

회의 의견 8 가지 중 본 종합 문서 작성 범위 외의 향후 실험 영역.

7.1 K=20 SF=10 검증 (의견 #2)

SF=1 + K=10/20/30 직접 측정. 현재 K 변화 검증은 SF=100 (A1) + SF=10 (A2) 만. SF=1 일반화 여부 확인 권장.

예상 작업량 — 4 anchor method $\times$ 3 K $\times$ SF=1 측정 환경 = 12 측정. 1 측정당 약 100 초 예상.

7.2 method 실행 시간 직접 measure (의견 #6)

현재 fit time 은 직접 측정 (0.1 ~ 0.5 초). total elapsed (100 ~ 107 초) 중 method 자체 contribution 직접 분리 측정 권장. 1 초 이내 검증 완전성.

7.3 Q-error from→to 모든 method 상세 표기 (의견 #7, #8)

본 종합 문서는 핵심 method (minibatch_partial / Centroid tuple / Neyman) 의 from→to 만 포함. 17 사용 method 전체의 from→to mean / median 표기는 미완. 본 연구 보고서 (6/11) 부록 또는 별도 table 권장.

7.4 skew flag-only 환경 (Q4 답변 영향)

본 연구의 어떤 method 도 skew flag 만으로는 적용 불가. 그러나 산업 환경에서 사전 학습이 비싸고 skew flag 만 사용 가능한 경우 (예: 데이터 카탈로그 메타데이터) 가 있을 수 있다. L1 환경의 가치는 향후 실험 영역.

7.5 SSN balanced 환경의 정직 분류 (의견 #1 RQ 재프레이밍)

본 연구의 단독 best (minibatch_partial -10.17%) 9 cell 평균에는 SSN (+2.10% worse) 가 포함된다. balanced 환경에서는 단독 대체가 약간 나빠진다는 finding 은 본 연구의 정직성 항목이지만, 9 cell 평균이라는 단일 숫자로 묻혀

있다.

권장 — 본 연구 narrative 에서 "skew 환경 -15 ~ -21% / balanced 환경 +2.10% / 전체 평균 -10.17%" 의 3 단계 표기 권장.

8. 자료 찾기 가이드

8.1 narrative + 발표 자료

자료	경로
본 연구 narrative 최종 정리 v1	submission/_drafts/속도는벡터_본연구_narrative_최종정리_v1.md
5/27 발표 keynote v4	submission/_drafts/속도는벡터 · Capstone Final 5_27 (Keynote v4).pdf
5/27 storyline v1	submission/_drafts/속도는벡터_5_27_최종발표_storyline_v1.md
6/11 보고서 outline v1	submission/_drafts/속도는벡터_6_11_최종보고서_outline_v1.md
5/15 박광현 미팅 핵심 정리	submission/_drafts/속도는벡터_5_15_박광현미팅_핵심정리_v1.md
본 종합 이해 문서 (현재 문서)	submission/_drafts/속도는벡터_프로젝트_종합이해_v1.md

8.2 측정 데이터 (file path + server path)

데이터	경로
측정 portfolio 총 1065 file	server 165.132.140.240:/mnt/hdd0/home/capstone2026/
paper exact carry-over 1001 file	server only (REPORT v11 1362 line)
5/13-5/14 추가 64 file	server multi-join 8 + Centroid tuple 8 + B1/B2/B3 cheap 24 + A2-Fig8 mv 8 + α sweep 16
검증 분석 결과	submission/_drafts/연구_한계점_4중_명시_5월5일회의록_기반.md 등

8.3 분석 file 6 개 figure

Figure	경로
F1 paradigm rollup CaseB	experiments/figures/paper_exact_v7/F1_paradigm_rollup_caseB.png
F2 Cliff's δ bucket	experiments/figures/paper_exact_v7/F2_cliffs_delta_bucket.png
F3 CaseA vs CaseB violin	experiments/figures/paper_exact_v7/F3_caseA_vs_caseB_violin.png
F4 Top winners CaseB	experiments/figures/paper_exact_v7/F4_top_winners_caseB.png
F5 Effect size scatter	experiments/figures/paper_exact_v7/F5_effect_size_scatter.png
F6 narrative diagram	experiments/figures/paper_exact_v7/F6_narrative_diagram.png

8.4 회의록 + 카톡

회의록	경로
카카오톡 회의록	_internal/records/kakaotalk/YYYYMMDD_제목.md
주간 보고	_internal/records/weekly/주간보고_YYYY-MM-DD.md
5/14 임채림 박사 회의 (14:00-15:21)	회의록 작성 권장 (5/14 작성 미완)

8.5 핵심 registry + handoff

Registry	경로
57 method $\times$ 9 paradigm	_internal/METHOD_REGISTRY.md
9 cells $\times$ 56 method $\times$ 3 modes matrix	_internal/EXPERIMENT_REGISTRY.md
server 자원 + tmux	_internal/SERVER_REGISTRY.md
본 세션 인계 anchor (handoff v17)	_internal/handoff/active/handoff_v17_session_finalize_20260514_0721.md
측정 portfolio MASTER README	_internal/MASTER_README.md

부록 A: 측정 환경 9 개 상세

A1 — 단일 테이블 SF=100 (paper Fig 5/6)

Cell	데이터셋	차원	SF	행 수	Queries	선택도	server table
A1-DEEP	DEEP	96	100	8000 만	q3, q10, q12	0.01	partsupp_deep_100
A1-SIFT	SIFT	128	100	8000 만	q3, q10, q12	0.01	partsupp_sift_100
A1-SSN	SSN	256	100	8000 만	q3, q9, q10	0.01	partsupp_fb_100

A2 — 다중 테이블 SF=10 (paper Fig 7/8/9)

Cell	데이터셋	차원	SF	행 수	Queries	선택도	join 형태
A2-Fig7	YFCC	192	10	800 만	TPC-H 8	0.01	단일 벡터 + 스칼라
A2-Fig8	DEEP + WIKI (multi)	96 + 768	10	800 만	TPC-H 8	0.01	두 벡터 multi-vector
A2-Fig9	DEEP + WIKI cross	96 / 768	10	800 만	TPC-H 8	0.01	두 테이블 cross-table

A4 — 선택도 sweep (paper Fig 13)

Cell	데이터셋	차원	SF	Queries	선택도
A4-sel	DEEP	96	100	q3, q10, q12	{0.001, 0.01, 0.10}

A5 — Scale Factor sweep (paper Fig 14)

Cell	데이터셋	차원	SF	행 수	Queries	선택도
A5-scale-sf1	DEEP	96	1	80 만	q3, q5, q20	0.01
A5-scale-sf10	DEEP	96	10	800 만	q3, q5, q20	0.01

부록 B: method 17 사용 + 39 폐기 list

B.1 사용 method 17 개

갈래	Method	CaseB $\Delta\%$ (9 cell 평균)	자원 등급	이론적 근거
P1 클러스터링	minibatch_partial	-6.98%	Excellent	Sculley 2010 (partial fit)
P1 클러스터링	minibatch	-9.28%	Excellent	Sculley 2010
P1 클러스터링	gmm	+2.45%	Good	Dempster 1977 EM (marginal)
P2 공간 분할	hilbert_real	-9.27%	Best	Faloutsos 1989 진짜
P2 공간 분할	zorder_morton	-9.26%	Excellent	Morton 1966 bit-interleaving
P2 공간 분할	skilling_hilbert	-9.01%	Excellent	Skilling 2004 변형
P2 공간 분할	lpm2	-9.45%	Best	Grafström 2012 local pivot
P3 스트리밍	chao_weighted	-9.60%	Best	Chao 1982 weighted reservoir
P3 스트리밍	reservoir	-9.25%	Best	Vitter 1985, 메모리 $O(1)$
P3 스트리밍	thompson_sampling	-8.98%	Excellent	Thompson 1933 Beta posterior
P3 스트리밍	cum_sqrtf	-8.45%	Good	Cochran 1977 sqrt(F)
P4 차원 축소	sparse_rp	-9.43%	Best	Li-Hastie-Church 2006
P4 차원 축소	neuram	-9.97%	Best	autoencoder (PCA1D 등가 audit)
P4 차원 축소	pca1d	-9.63%	Excellent	Pearson 1901 PCA
P4 차원 축소	rsvd	-8.49%	Excellent	Halko-Martinsson 2011
P6 양자화	pq	-9.25%	Excellent	Jégou 2011 product quantization
P9 정보 이론	hyperloglog	-8.65%	Best	Flajolet 2007 HyperLogLog

B.2 폐기 39 method (3 카테고리)

자원 한계 7 종 (큰 메모리 / timeout): - dirichlet - kernelpca - neurocard_lite - birch - hdbscan - agglomerative - kde_parzen (5/14 폐기 결정)

algorithm audit drop 23 종 (코드 정독 검토 reference 위반): - 5월 10일 8 agent audit 결과 등록 - 예: vinecopula (vine copula 아님), neuram (PCA1D 등가, 측정 보존만)

정합성 위반 10 종 (sample budget 위반): - halton, sobol, lhs, hammersley (P5 준 무작위 4 종) - dense_rp, random_projection (chunk-level 위반) - dbscan, ccsketch, lsh, ams_count_sketch (count uncertain)

- P5 준 무작위 / P10 밀도 추정 paradigm 은 모두 폐기되어 사용 method 없음.

부록 C: 회의 timeline (5/14 14:00 ~ 15:21)

시간	의제	주요 내용
14:00	회의 시작	박세은 팀장 본 연구 설명 시작
14:10 ~ 14:30	RQ 정의 + 데이터셋	RQ2/RQ3 프레이밍 의문 제기, 데이터셋 차원/행 수 명시 요청
14:30 ~ 14:50	분포 안다 / 모른다 정의	Q1 ~ Q5 답변 진행, "분포 안다" 표현 모호성 합의
14:50 ~ 15:10	벡터 query + 단일/다중 테이블	Q6 ~ Q10 답변 진행, Neyman paradox 진짜 원인 (Q7) 통찰
15:10 ~ 15:21	sample 정합성 + K 변화 + 향후 작업	Q11 ~ Q15 답변, 향후 실험 영역 4 종 합의

회의 결과 — 회의 의견 8 가지 / 회의 질문 15 가지 모두 본 종합 문서에 반영. 5/15 박광현 교수님 미팅 D-1 자문 권장 6 항목 (§6.2) 별도 정리.

작성: 2026-05-14 15:31 KST · 분량: 약 730 줄 · 회의 의견 8건 + 회의 질문 15 가지 답변 통합 · 환각 0 원칙 (fact extraction agent 결과만 사용 + 검증 필요 영역 명시)