

팀원 슬라이드 가이드 — 5/8 19:00 회의 보조 자료

이 문서를 어떻게 읽나 1. Claude Design link 으로 16-slide academic deck 열기 (사용자가 카톡 link 공유 예정) 2. 슬라이드 한 장씩 보면서 본 문서의 해당 절 같이 읽기 3. 각 슬라이드 = "한 줄 메시지 + 풀어 말하면 + 비유 + 결론" 4 항목 정리

본 자료의 목적: deck 의 학술 narrative 가 어렵게 느껴질 때 같이 읽는 풀어쓴 보조. 회의 5분 전 read 가능.

작성: 5/8 17:50 KST PM (회의 1h 전)

🕒 회의 흐름 (19:00~21:00, 2시간)

시간	단계	자료
19:00~19:10 (10')	인사 + 단일 100% 결과 공유 (팀원 5분 read 가정)	본 슬라이드 가이드 + Claude Design deck
19:10~19:40 (30')	4강 method ranking + Tier 1 17종 + Sweet Spot boundary 토론	Slide 6~11
19:40~20:00 (20')	PDX confirmation + multi 진행 상황 공유	Slide 4 + Slide 13
20:00~20:30 (30')	자문 메일 4 의제 합의	자문메일초안 PDF
20:30~21:00 (30')	5/27 발표 plan 합의 (자문 후 v2)	5/27 plan PDF



본 연구 한 줄 요약

"벡터 데이터의 분포가 한쪽으로 치우쳐 있을 때, 그 분포를 알면 더 정확한 카디널리티 추정이 가능하다 — 그 가치를 정량 측정"

비유: 인구 조사를 할 때, 연령대별로 인구 분포에 맞춰 가중치 두고 표집하면 더 정확한 평균을 얻는다. 본 연구 = 벡터 임베딩의 분포에 맞춰 sampling 가중치 두는 방법의 가치.

3 줄 결론: 1. 분포 인지 방법은 강력 효과 (단일 dataset 4강 method 평균 -7~-8%, SIFT 에서 -32%) 2. method 선택은 부차 (Tier 1 살아남기 17종 spread 1.21%p) — "어느 분포 인지 method 든 Tier 1 이면 OK" 3. multi 환경에서는 효과 25.4x 약화 (단일 17.13% → multi 0.67%) — "단일 정확성 = multi 정확성 필요조건만, 충분조건 X"



Slide 1 (Cover) — 우리 연구 제목

화면: Skew-Aware Stratified Sampling for Vector-Augmented Analytical Query

풀어 말하면: - "Skew" = 분포가 한쪽으로 치우침 (편향) - "Stratified Sampling" = 분포를 cluster (strata) 로 나누고 각 cluster 에서 sampling - "Vector-Augmented Analytical Query" = 벡터 임베딩이 포함된 분석 쿼리

→ "분포 편향을 인지한 stratified sampling 의 정량적 가치"

비유: 시험 점수 조사할 때, "전체 학생 중 무작위로 100명" (random) 보다 "각 학년에서 25명씩" (stratified) 가 더 정확한 평균. 학년별 분포 차이 (skew) 를 알면 stratified 가 더 정확.

결론: 분포 정보 활용 = 정확도 ↑



Slide 2 (TOC) — 오늘의 흐름

10 단계: Problem → Prior Work → Approach → RQ1 → RQ2 → RQ3 → Cross-scale → Mechanism → Effect Honesty → Future

3 가지 RQ 한 줄 요약: - **RQ1** (진단): 분포 차이가 추정 정확도에 영향 주는가? → "그렇다, 단조적으로" - **RQ2** (distribution-aware): 분포 알 때 활용 효과는? → "강력 (51/52 cell 통계 유의)" - **RQ3** (distribution-agnostic): 분포 모를 때는? → "4강 method 가 70~100% 회복"



Slide 3 (Problem) — 무엇이 문제인가

화면: pgvector 33.3% / VBASE 50% / DuckDB 100%

풀어 말하면: - 기존 vector DB 들은 cardinality (= query 결과 row 수) 추정할 때 **고정 비율** 사용 - pgvector = "전체의 33%일 거야" 무조건 가정 - 그러나 실제 query 의 selectivity 는 **0.001%~90%** 까지 매우 다양 - 잘못된 가정 → 잘못된 plan (예: hash join vs nested loop) → 1000~10000× 느린 query

비유: 식당에서 "오늘 손님 100명" 라고 매일 똑같이 가정 → 실제 50명 와도, 200명 와도 다 잘못 준비. 적절한 손님 수 예측이 필수.

결론: 고정 비율 = "기술적으로 좋은 추정" 이지만 "실행 계획에 진짜 도움 되는 추정" 이 아님 → 그 간극을 메우는 게 본 연구.



Slide 4 (Prior Work + PDX) — 우리가 기반하는 토대

(이전 연구) **Exqutor** (BDAI Research Lab, 박세은 팀장 연구실, arXiv:2512.09695v2): - **ECQO**: HNSW 인덱스 있을 때 1~2 ms 에 정확 cardinality - **Adaptive Sampling**: 인덱스 없을 때 동적 sampling (1000× 비용 절감)

(추가 발견) **PDX** (CWI Amsterdam, SIGMOD 2025, arXiv:2503.04422): - **Quote**: "intrinsic_dim + skewness 가 algorithm selection 결정" - 우리 thesis 와 **정확 일치** → SIGMOD 2025 학술 confirmation 확보 → 본 연구 정당성 강화

PDX 와 본 연구의 차이 — Complementary: | 영역 | PDX | 본 연구 | |---|---|---| | Layer | compute | pre-process | | Goal | fast similarity (data layout) | accurate cardinality (sampling/clustering) | | 대상 | distance 계산 자체 | sample 분배 전략 |

비유: 자동차 = engine (PDX, 빠른 similarity) + navigation (본 연구, 정확한 cardinality). 둘 다 좋은 차에 필요.

결론: 우리 연구 = Exqutor 의 빈 공간 (단일 테이블 비인덱스 skewed) 메우기 + PDX 의 compute layer 와 complementary.



Slide 5 (Approach) — 우리 접근 3 단계

3 카드: - **RQ1 진단:** 분포 차이 → 정확도 영향 정량 - **RQ2 distribution-aware:** 분포 알 때 효과 측정 - **RQ3 distribution-agnostic:** 분포 모를 때 차선택

비유: 의학 검진 흐름 = 진단 (분포 측정) → 처방 (분포 활용) → 일반 약 (분포 모를 때).

결론: 분포가 펼쳐 있을 때 cardinality 정확도와 안정성을 명확히 계량.

Slide 6 (RQ1) — 분포 차이가 정확도에 영향 주는가? → "그렇다"

화면: 12 cell $\times \rho < 0$ 100% 일관 (-0.366 ~ -0.609)

풀어 말하면: - 12 cell = 5 dataset (DEEP/SIFT/SSN/WIKI/YFCC) $\times$ 2 scale (sf1/sf10) $\times$ 1~2 method - ρ (Spearman rho) = -1~+1 범위의 상관계수. selectivity 와 추정 오차의 단조 관계 강도 - $\rho < 0$ = "selectivity 가 커질수록 추정 오차는 작아진다" (단조 감소) - 100% 일관 = 12 cell 모두 $\rho < 0$ (예외 없음) - DEEP_sf1 KM20 의 $\rho = -0.680$ [-0.800, -0.440] 95% 신뢰구간이 0 을 제외 → 통계적 유의

비유: 키 측정 정확도. 1000명 측정하면 평균 잘 맞고 (selectivity 큼 → 오차 작음), 10명만 측정하면 평균 부정확 (selectivity 작음 → 오차 큼). 표본 크기 효과의 단조 관계.

결론: 분포 차이 (selectivity 차이) 가 추정 오차에 일관되게 영향 → RQ1 답: "그렇다, 단조적으로"

Slide 7 (RQ2) — 분포 알 때 활용 효과? → "강력"

화면: 51/52 cells CI 0 제외 (sel=0.10) + σ -allocation 격차 $< 1\%$ (7/12 cell)

풀어 말하면: - 51/52 cell = 12 cell $\times$ 4 mode (BERN/proportional/Neyman/Anti-Neyman) - 1 outlier - CI 0 제외 = paired 통계로 "분포 활용 효과 $\neq 0$ " 통계적 유의 (즉 분포 활용 효과 99% 신뢰) - σ -allocation 격차 $< 1\%$ = Neyman vs Anti-Neyman 의 차이가 1% 이내 (7/12 cell) - **결론:** 분포 활용 효과는 강력하지만, σ 정확성 (Neyman) 보다 "분포 인지 자체" 가 결정적 — 단순 균등 stratification 으로 충분

Anti-Neyman counterfactual: " σ 를 반대로 쓰면 systematically 나빠짐" (DEEP +5.21%, SIFT +9.49% CI 0 제외) → σ 신호가 약하지만 존재함을 정량 증명 (negative control)

비유: 인구 조사. 연령대별 sample size 를 정확하게 (Neyman) vs 균등 (proportional) → 결과 거의 같음. 그러나 정반대로 (Anti-Neyman) → 명확히 나빠짐 → "균등도 충분, 정확도는 marginal"

결론: 분포 활용 효과 강력. 단순 균등 stratification 충분. σ 정확성은 marginal.



Slide 8 (RQ3) — 분포 모를 때는? → "4강 method 가 강력"

화면: 4강 ranking 표 + 10-cell × 4-method heatmap

4강 method (단일 10 cell × 5 sel × paired $\Delta\%$ sel=0.10):

Rank	Method	avg $\Delta\%$	neg cells	CI ex	특성
★1	HDBSCAN	-8.04	8/10	8/10	가장 강력 — strongest narrative (oracle 영역)
★2	MB_partial	-7.63	8/10	9/10	OLTP friendly 유일 (online learning)
★3	Hilbert	-7.54	8/10	9/10	production sweet spot (가장 가벼움)
★4	Hybrid	-7.13	8/10	8/10	mechanism narrative (MB+Hilbert 결합)

풀어 말하면: - "BERN baseline 대비 평균 7~8% 더 정확" (10 cell 평균) - "8/10 cell 에서 정확도 항상 부호 일관" (예외: SSN_sf1, SSN_sf10 의 +1~+2%) - "9/10 cell 에서 통계적 유의 (CI 0 제외)" — MB_partial / Hilbert 가 장 robust

가장 강력한 효과 (SIFT_sf1): HDBSCAN -32.63%, Hilbert -33.53%, Hybrid -30.46%, MB_partial -33.13% — 4강 모두 -28~-34%

SSN++ 만 +1~+2% (positive direction): 분포 균형 dataset 에서는 효과 없음 (boundary, 자세히 Slide 11)

비유: 운동 효과. 비만인 사람 (분포 차이 강한 dataset) 은 운동 강력 효과 (-30%). 정상 체중 (균형 분포 SSN++) 은 변화 적음 (+1~+2%) → 본 연구의 outer boundary 자연스러움.

결론: 분포 모를 때 4강 method 가 BERN 대비 평균 7~8% 향상. SIFT 같은 분포 차이 강한 dataset 에서 32% 강력.



Slide 9 (Hilbert + Tier 1 17종 spread)

화면: Tier 1 17 method spread 1.21%p (HDBSCAN -8.04 ~ kdtree -6.83)

풀어 말하면: - 30 method 중 17종이 "Tier 1" (살아남는 method). 나머지 13종은 가지치기. - Tier 1 17종의 평균 $\Delta\%$ 차이 = 단 1.21%p (HDBSCAN 1위 -8.04% ~ kdtree 17위 -6.83%) - 즉 "어느 분포 인지 method 든 Tier 1 이면 OK" → method choice 부차

핵심 결론: "method 선택보다 '분포 인지 vs 미인지' boundary 가 결정적"

비유: 같은 학원 다닌 17명 학생들의 성적 차이가 단 1점 → 학원 자체가 좋은 거지 (분포 인지) 어느 선생님 만나도 별 차이 없음 (method 선택 부차).

Hilbert 의 위치: 4강 중 #3 = 학습 비용 0 + production sweet spot. 즉 "공짜로 90% 효과" 의 가치. - inverse Manhattan distance 보존: Hilbert 1.000 vs Z-order 1.992 → 거리 보존이 정확히 2× 좋음 (locality preservation)



Slide 10 (MiniBatch K-means)

화면: 1,189× speedup + ARI 1.000 + CI ex 9/10

풀어 말하면: - **MiniBatch K-means** = full K-means 의 빠른 버전 (mini-batch update 으로 incremental learning) - **1,189× speedup** = full K-means 의 1/1189 시간에 학습 (분 → 초) - **ARI 1.000** (Adjusted Rand Index) = clustering 결과 정확도 = full K-means 와 **완전 동일** - **CI ex 9/10** = 4강 중 가장 강력한 statistical robustness

특징: `partial_fit` 가능 → streaming 환경에서 OLTP friendly. 즉 production 에서 새 데이터 들어올 때마다 cluster 갱신 가능 (online learning).

비유: "빠른 사진 vs 정밀 사진. 같은 사진을 1/1000 시간에 찍었는데 화질 동일 → production 에서는 빠른 사진 채택"

결론: MB_partial = "정확도 동일 + 1000× cheaper + OLTP-ready" → production 채택의 결정적 근거.



Slide 11 (Sweet Spot 정량 boundary)

화면: $\text{cluster_ratio} > 1.4 + \text{intrinsic_dim} < 0.85 \rightarrow \text{SWEET} / \text{반대} \rightarrow \text{CEILING}$

풀어 말하면: - "분포가 어떻게 생긴 dataset 에서 본 method 가 강력한가" 의 **정량 정의** - **cluster_ratio** = 가장 큰 cluster / 가장 작은 cluster 크기 비율 (1.0 = 완전 균등, > 1 = 불균형) - **intrinsic_dim** = 데이터의 본질적 차원 (PCA 누적 분산 비율, 0.85 = 80% 정보 위해 차원의 85% 필요)

SWEET 영역 ($\text{cluster_ratio} > 1.4 + \text{intrinsic_dim} < 0.85$): - 분포 인지 효과 강력 = **-7%~-32%** - 해당 dataset: SIFT (1.65 / 0.71), WIKI (1.84 / 0.81), YFCC (~1.5 / ~0.85)

CEILING 영역 ($\text{cluster_ratio} < 1.4 + \text{intrinsic_dim} > 0.85$): - 분포 균형 → BERN baseline 자체가 이미 ceiling → method 효과 약 (**+1~+2%**) - 해당 dataset: SSN++ (1.29 / 0.88) — uniform-like distribution

비유: 길거리 sample. 강남 (분포 다양, ratio 큼) → 응답 결과 불균형 → sampling 으로 정확 측정. 시골 마을 (분포 균질, ratio 작음) → 어차피 다 비슷 → sampling 효과 작음.

결론: 두 metric 으로 distribution sweet spot 정량 경계 정의 → 적절한 분포에서만 분할이 효과 (Negative Control 본질).

Slide 12 (Cross-scale Sensitivity)

화면: sf1 → sf10 4강 ranking 일관성 + sf100 자문 후 표기

풀어 말하면: - sf1 (800K row) → sf10 (8M row) 으로 10× scale up 했을 때 4강 method 의 ranking + 부호 보존 - 예: SIFT_sf1 -32.63% → SIFT_sf10 -10.47% (magnitude 약화, **부호 유지**) - 즉 "scale 변해도 결론 일관" — **외적 타당성 (external validity)**

sf100 (80M row) = 미측정. 채림 석사 자문 후 5/15+ 진행 예정. **multi-table join (STAGE 3) = 5/8 17:50 측정 완료** — 단일→multi-vector→multi-table-join shrinkage chain 의 lower bound 확정.

비유: 동일한 약효가 어린이 (sf1) 와 성인 (sf10) 모두에서 효과. 노인 (sf100) 검증은 추가 임상 후.

결론: sf1 → sf10 부호 일관 = 외적 타당성 부분 입증. sf100 + multi-relation 일반화는 future work.

Slide 13 (Mechanism + Multi 25.2× shrinkage) —

화면: 단일 17.13% → multi-vector 0.67% → multi-join 0.68% = **25.2× 약화**

풀어 말하면: - 단일 **sweet spot 4강 평균 $|\Delta\%|$ = 17.13%** (SIFT_sf1 / WIKI_sf1 / YFCC_sf1) - **multi-vector 4강 평균 $|\Delta\%|$ = 0.67%** (deep_sift_10 + deep_wiki_10) - **multi-table-join 4강 평균 $|\Delta\%|$ = 0.68%** (partsupp_deep_10 $\bowtie$ part_wiki_10, 8M JOIN, FK 4-to-1) - **25.2× = 17.13 / 0.68** — magnitude 약화 비율, multi-vector 와 multi-join 거의 동일

핵심 메시지:

단일 정확성은 multi 정확성의 **필요조건**만 성립, **충분조건**은 아님

직관적: 단일 잘 ≠ multi 잘. 단일 못 → multi 도 못 가능. 단일 잘 → multi 약 가능. multi-vector 와 multi-table-join 의 magnitude 가 거의 동일 → **shrinkage 발생 지점 = "vector 수 증가" 단계**, table join 은 추가 약화 없음.

multi cell 측정 결과 (sel=0.10):

Cell	Type	4강 paired $\Delta\%$ (hdb / hil / hyb / mb_p)	부호
partsupp_deep_sift_10 (96+128 dim)	multi-vector	-1.02 / -0.48 / +0.31 / -1.30	3/4 negative
partsupp_deep_wiki_10 (96+768 dim)	multi-vector	+1.15 / +0.06 / +0.08 / +0.99	0/4 negative (boundary)
partsupp_deep_10 $\bowtie$ part_wiki_10	multi-table join (8M JOIN)	+0.29 / -0.85 / -0.22 / +1.38	2/4 negative

해석: multi 환경에서 4강 method 의 ranking 도 **노이즈 수준으로 와해** ($|\Delta|$ 모두 $< 1.5\%$) $\rightarrow$ multi-relation 일반화는 **joint-aware clustering** 또는 **multi-vector decomposition** 별도 설계 필요 (future work). multi-join 의 ranking (hilbert $>$ hybrid $>$ hdbscan $>$ mb_partial) 은 단일 (hdbscan $>$ mb_partial $>$ hilbert $>$ hybrid) 과 거의 역순 — 4강 ranking 은 multi 환경에서 보존되지 않음.

비유: 한 사람 진료 (단일) 에 잘 맞는 약 $\rightarrow$ 환자 두 명 동시 진료 (multi) 에는 효과 25 $\times$ 약. 병원 시스템 (multi) 은 다른 설계 필요.

Mechanism (locality): - Hilbert inverse Manhattan **1.000** vs Z-order **1.992** $\rightarrow$ Hilbert 가 거리 보존 정확히 2 $\times$ 좋음 - stratum compactness gain: DEEP_1M **1.25 $\times$** / SIFT_1.5M **2.54 $\times$**

결론: 단일 $\rightarrow$ multi-vector $\rightarrow$ multi-join 25.2 $\times$ shrinkage 가 본 연구의 **outer boundary** 정량화. multi-vector 와 multi-join 의 magnitude 가 거의 동일 $\rightarrow$ shrinkage 의 발생 지점은 join 자체가 아닌 vector 수 증가. multi-relation 일반화 future work.

Slide 14 (Effect Size Honesty)

화면: DEFF 0.338 / ESS 2,325 / 6 $\times$ SRS effective sample + per-query routing ρ 0.78

풀어 말하면: - **DEFF** (Design Effect) = 0.338 $\rightarrow$ SRS (단순 random sample) 대비 **1/0.338 = 3 $\times$ 효율** (분산 절반 이하) - **ESS** (Effective Sample Size) = 2,325 $\rightarrow$ 1만 샘플 중 효과적 정보 = 2,325 (SRS 대비 6 $\times$) - **effect size $d \approx 0.3$ = practical small** (작은 효과) - **per-query routing $\rho = 0.78$** $\rightarrow$ 어려운 query 에서 분포 활용 효과 더 큼 (Q4_hard)

Honest reporting: 평균 effect 는 작지만, **어려운 query 에서 강력** (per-query routing 가치).

SSN++ ceiling (boundary): 4강 모두 +1 $\sim$ +2% $\rightarrow$ 분포 균형 dataset 의 outer boundary 정의 (negative control 의 자연스러운 boundary).

비유: 약효. 평균적으로는 1% 효과 (작음) 지만 중증 환자 (어려운 query) 에는 강력 효과.

결론: effect size 작지만 (practical small), per-query routing 가치 있음. SSN++ ceiling = 본 연구의 outer boundary.

Slide 15 (Limitation 8 항목)

8 카드 (PARTIAL / FUTURE / HONEST 분류):

PARTIAL (부분 입증): - Single-table only (단일 테이블만 측정, multi-table 일부) - KM20 oracle 학습 부담 (production X) - numpy estimator scope (vector.c integration future)

FUTURE (자문 후 진행): - Multi-vector 일반화 (joint-aware clustering 필요) - sf100 cross-scale (자문 합의 후 launch) - vector.c integration (production deployment)

HONEST (negative control): - SSN++ ceiling (분포 균형 dataset 의 outer boundary) - Effect size practical small (per-query routing 으로 보완)

비유: 논문 마지막 "limitation" 섹션. "우리도 다 했다고 못 말한다" 의 정직 reporting.

결론: 8 가지 honest limitation. 모두 자연스러운 후속 연구 출발점.

Slide 16 (Closing)

화면: 감사합니다 / Q&A + GitHub johyunbin/Capstone + arXiv:2512.09695v2 + footer

다음 단계 timeline: - 5/15 자문 회신 (채림 석사 + 박광현 교수님) - 5/22 교수님 미팅 - 5/26 발표 자료 최종 마감 - 5/27 19:00 최종 발표 (오늘 deck 활용) - 6/11 최종 보고서



회의 4 의제 (5/8 19:00)

#	의제	핵심 질문
1	단일 결과 종합 검토	4강 method ranking + Tier 1 17종 + Sweet Spot boundary 합의
2	자문 메일 초안 합의	채림 + 교수님 발송 결정. 4 의제: 4강 production cost / Sweet Spot generalizability / multi 일반화 plan / Exqutor ensemble
3	multi 측정 진행 상황 공유	multi-vector 4강 일반화 25.4× shrinkage + multi-table join 1 cell 추가 (5/8 17:50 STAGE 3 완료, 0.68% 동일 magnitude)
4	5/27 발표 plan 합의	자문 후 v2 작성 일정 (5/15+)

? 예상 질문 + 답변

Q1: KM20 oracle 은 production 가능?

A: 아니다, oracle baseline. 그래서 4강 production-ready method 가 KM20 의 70~100% 회복. 특히 MB_partial = OLTP friendly (online learning).

Q2: SSN++ 만 hurt direction (+1~+2%) 인 이유?

A: cluster_ratio 1.29 + intrinsic_dim 0.88 = 분포 균형 (uniform-like). BERN baseline 자체가 이미 낮음 (ceiling effect). 본 연구의 outer boundary 정의.

Q3: PDX (SIGMOD 2025) 와 우리 연구의 관계?

A: Complementary. PDX = compute layer (data layout, fast similarity). 본 연구 = pre-process layer (sampling/clustering, accurate cardinality). 같은 thesis ("intrinsic_dim + skewness driven") 다른 layer.

Q4: Tier 1 17종 spread 1.21%p 의 의미?

A: HDBSCAN (-8.04) ~ kdtree (-6.83) 까지 모든 Tier 1 method 가 작은 차이. 즉 "method choice 부차, 분포 정보 인지 자체 결정적". 어느 method 든 Tier 1 이면 OK, 4강 = 대표.

Q5: Multi 결과 25.4× shrinkage 는 부정적 결과 아닌가?

A: 아니다, **outer boundary 정량 입증** = honest finding. "단일 정확성 = multi 정확성 필요조건 만" → 본 연구 scope 명확화 + multi-relation 일반화 future work 정당화.

Q6: sf100 (80M) 측정은?

A: 본 W4 sprint 미측정. 5/8 회의 후 자문 합의 → 5/15+ launch. DEEP/SIFT/SSN sf100 = 80M PG 적재 완료.

Q7: 자문 메일 4 의제는?

A: 1. 4강 method 선정의 production cost 차별화 narrative validity 2. Distribution Sweet Spot 정량 boundary (cluster_ratio 1.4 / intrinsic 0.85) generalizability 3. Multi 일반화 검증 plan (joint-aware clustering) 4. Exqutor 통합 ensemble plan 타당성



부록 — 자주 나오는 학술 용어 사전

용어	풀어 말하면
paired $\Delta\%$	같은 query 의 BERN 추정과 method 추정을 짝지어 비교한 % 차이. negative = improvement.
CI 0 제외	95% 신뢰구간이 0을 포함하지 않음 = 통계적 유의 (효과 $\neq 0$).
Spearman ρ	두 변수의 단조 관계 강도 (-1~+1). negative = "더 큰 selectivity $\rightarrow$ 더 작은 오차".
selectivity	query 결과가 전체 row 의 몇 % 인가 (0.001~90%).
stratified sampling	데이터를 cluster (strata) 로 나누고 각 cluster 에서 sampling.
KM20	K-means K=20 cluster 로 stratified (oracle baseline).
BERN (bernoulli)	단순 random sampling baseline (각 row 독립 0/1 선택).
Cohen's d	두 group 평균 차이의 표준화 효과 크기. $ d \geq 0.5$ = medium, ≥ 0.8 = large.
DEFF / ESS	Design Effect / Effective Sample Size — sampling 효율 metric.
HDBSCAN	Hierarchical Density-Based Spatial Clustering of Applications with Noise. 노이즈 자동 분리 + 밀도 기반 cluster.
MiniBatch K-means	K-means 의 mini-batch update 버전. 1000× 빠름 + ARI 1.000 (full 과 동일).
partial_fit	sklearn 의 incremental learning API. streaming 환경에서 새 데이터 들어올 때마다 cluster 갱신.
Hilbert curve	space-filling curve. 다차원 공간을 1D 로 매핑하면서 locality 보존.
cluster_ratio	가장 큰 cluster / 가장 작은 cluster 크기 비율 (1.0 = 균등, > 1 = 불균형).
intrinsic_dim	PCA 누적 분산 ratio. 0.85 = 80% 정보 위해 차원의 85% 필요. 큰 값 = 본질적으로 high-dimensional.

🔗 자료 위치 (회의 진행 중 즉시 참조)

자료	위치	사이즈
Claude Design 16-slide deck	(사용자 카톡 link 공유)	—
본 슬라이드 가이드 (이 PDF)	submission/_drafts/팀원_슬라이드가이드_20260508.pdf	~ KB
상세 narrative (학술적)	submission/_drafts/팀원_이해용_종합_20260508.pdf	975 KB
분석 본체	experiments/results/RQ1_RQ2_RQ3_종합_master_v6_draft_filled_partial.pdf	1.6 MB
자문 메일 초안	submission/_drafts/속도는벡터_자문메일초안_W4_20260508.pdf	678 KB
5/27 발표 plan	submission/_drafts/속도는벡터_5월27일발표_plan_20260508.pdf	831 KB

회의 진행 중 본 가이드 보면서 deck slide 따라가기 + 의제 토론 + 합의 사항 메모. 회의 후 handoff_v11 update 으로 결과 반영.