

속도는벡터 — 5/11 paper exact 측정 완료 학술 상세 종합 (팀원 이해용)

이 자료의 목적: 5/11 paper exact 측정 결과 narrative를 학술 상세 수준으로 정리하여 5/15 박광현 교수님 미팅 / 5/27 최종 발표 / 6/11 최종 보고서 작성 시 4 팀원 모두 narrative를 같은 깊이로 숙지하기 위함.

작성: 2026-05-11 19:20 KST · 5/11 17:00~18:50 paper exact 측정 + 11 axis cross-verification + ★3 hilbert_real 회수 + Q4 paradigm anchor 80 measurement launch + hyperloglog 부분 회수 (P9 강화) 종합

분량: ~10p (~250 line dense 학술 산문)

1. 본 연구의 위치 — Exqutor §V-B Adaptive Sampling 영역 한정

1.1 Exqutor 논문 구조 (arXiv:2512.09695v2, BDAI Research 박광현 교수님)

본 연구의 base 논문 Exqutor는 vector-augmented analytical query (VAQ)에 대한 cardinality estimation을 두 paradigm으로 해결한다. **§V-A Extended Cardinality Query Optimizer (ECQO)**는 벡터 인덱스가 있을 때 HNSW range query를 1-2ms에 활용하여 정확한 카디널리티를 추정하는 방식이며 (paper Fig 4 TPC-H sf=100 / Fig 10 TPC-DS sf=10), **§V-B Adaptive Sampling**은 인덱스가 없을 때 모멘텀 기반 동적 sample size 조정 (Eq 1-6)으로 unstratified Bernoulli sampling의 정확도를 자체 개선하는 방식이다 (paper Fig 5/6/7/9/13/14). 본 연구의 contribution 영역은 **§V-B 한정**이며, ECQO §V-A는 paper main result로 그대로 인정한다 (사용자 5/11 14:18 verbatim "Exqutor 외 영역 / 외의 조건을 억지로 추가하는 개념이 아닌 정확히 비교할 수 있도록").

1.2 본 연구의 augment 구조 정의 (사용자 5/9 23:18 카톡 verbatim)

본 연구의 핵심 contribution은 paper §V-B Adaptive Sampling을 그대로 보존하면서 우리 method의 KM20 stratified estimator를 산술 평균으로 ensemble하는 augment 구조다. 정확히는 다음과 같다.

```
estimator 1 = paper §V-B Bernoulli random sampling (paper exact verbatim)
estimator 2 = 우리 method (KM20 stratified, 분포 인지 stratification)
최종 cardinality = (est1 + est2) / 2          ← simple average ensemble
```

AdaptiveState (paper Eq 1-6 sample size 동적 조정)는 paper exact 그대로 유지되며, sample budget도 두 estimator가 paper Eq 1 $N=385$ 를 공유한다. 즉 본 연구는 paper 추정 위에 우리 추정의 산술 평균만 layer로 추가하며, paper §V-B 자체는 변경하지 않는 paper-friendly augment이다. 이 구조의 통계적 정당성은 bias-variance trade-off에서 나오며, random sampling (bias 0, variance 큼)과 stratified sampling (bias 분포 misspecification 시 발생, variance 낮음)의 산술 평균은 한 쪽이 fail해도 다른 쪽이 보완하는 robust 구조다.

본 연구는 (CaseA, 우리 method가 paper Bernoulli sampling step을 단독으로 대체)와 (CaseB, paper §V-B 위에 우리 method를 ensemble augment)의 두 mode를 동시에 측정하여 **CaseA 단독 대체의 무너짐 + CaseB ensemble augment의 통계 압도**의 두 finding을 동시에 보고한다.

2. 측정 portfolio + 측정 정합성 4축 검증 (paper review-grade)

2.1 측정 portfolio 종합 (5/11 18:50 기준, 진행 중 +Q4 회수 시 988+)

본 연구는 9 cells $\times$ 56 method $\times$ 2 modes 매트릭스를 paper exact로 측정한다. 5/11 18:50 시점 측정 완료 portfolio는 다음과 같다.

항목	count
B1 baseline 9 cells	9/9
CaseA measurements	452
CaseB measurements	462
Phase 4 11 method $\times$ 18 cells	198/198
★3 hilbert_real 9 cells $\times$ 2 modes	18/18 (5/11 18:09 회수)
P9 hyperloglog 9 cells $\times$ 2 modes	18/18 (5/11 18:48 회수)
Q4 kde_parzen / mhist2 / rsvd / wavelet_hist	64 measurement 진행 중 (5/12 회수)
RQ1 csv (DEEP/SIFT/SSN sf=100 + DEEP sf=1/10)	5
RQ2 csv (DEEP/SIFT $\times$ Bern/Equal/Prop/Neyman/Anti)	2
총 measurement (5/11 18:50)	918+ file (coverage 80.4%+)

2.2 측정 정합성 4축 검증

측정 자체의 정합성은 4축에서 paper review-grade로 검증된다.

Axis A (JSON integrity): 산출된 918+ JSON file 전수 검사가 0 parse failure, 0 NaN-Inf, 0 corruption을 보인다. 모든 파일이 schema 일치 (B1 hyperparam 9 fields verbatim 일치).

Axis B (Reproducibility): 4 cells × 10 trials × 7 fields = 280/280 fields의 SHA-256 hash가 byte-identical로 일치하여 deterministic 보장이 확인된다 (seed `np.random.default_rng(trial_idx × 13 + 7)` 일관, code line 322).

Axis D (Paper verbatim line-by-line): paper §V-B Eq 1-6 + hyperparam 8건 ($m=0.9$ / $\eta_0=0.1$ / $\alpha=50$ / $\beta=1.5$ / $\gamma=0.99$ / $\text{update_period}=50$ / $N_{\text{init}}=385$ / HNSW $M=16$, $\text{ef_search}=400$) + query 정의 (DEEP/SIFT=Q3,10,12 / SSN=Q3,9,10 / YFCC 8 queries / DEEP+WIKI cross 8 queries / TPC-H threshold < 0.86) + trim 통계 (lowest+highest 1개 제외 8 runs) 모두 코드와 100% 일치. 미세 mismatch 4건 ($q_{\text{error cap}}=100$ / size round / sel=0.001 calibration parquet 부재 fallback / Bernoulli budget)은 모두 numerical robustness 영역.

Fig 12 영역 mean qe_trim: 8 cells (DEEP/SIFT/SimSearchNet++ × sf=100, YFCC sf=10, DEEP+WIKI cross sf=10, DEEP scale sf=1/10/100) 평균 trim Q-error 1.6180으로 paper 보고값 1.69 대비 -4.26%, measurement variance 범위 내 일치.

2.3 11 axis cross-verification 평균 7.6/10

추가 검증 7 axis를 포함하여 11 axis cross-verification 평균 7.6/10 (측정 자체 9.2-10/10 ✓). Statistical Robustness 영역에서 Hedges' g (small-sample bias 보정 Cohen's d) + Cliff's δ (rank-based effect size, large = ± 0.474) + paradigm rollup (P1-P10 mean $\Delta\%$) + cherry-pick prevention table을 모두 적용한다.

3. RQ1 결과 — paper exact RQ1 narrative

본 연구는 5/5 회의 RQ 재정립에 따라 RQ1을 "기존 random sampling이 skew 데이터셋에서 얼마나 부정확한가"로 정의하였다. paper exact 측정 결과 DEEP/SIFT/SimSearchNet++ × sf=100 + DEEP × sf=1/10의 5 cell × 5 mode (Bernoulli vs KM20 stratified) × 2 selectivity (0.01, 0.10) × 5 seed × 100 query에서 mean Q-error gap 평균 **+3.74%** (Bernoulli > KM20 stratified, 즉 Bernoulli가 부정확)가 측정되었다. 이는 5/8 시점 보고서의 "5%" 추정치 (실제 5.53%)에서 정확 측정으로 -3.74%로 정정된다.

데이터셋 별 결과: DEEP sel=0.01 +6.76% / DEEP sel=0.10 +3.95% / SIFT sel=0.01 +1.97% / SIFT sel=0.10 +9.45% / SimSearchNet++ +3.50%. 5 cells 평균 +3.74%로 paper §V-B baseline 대비 stratified가 일관 개선 효과를 보이지만, sample size 증가에 따른 robustness는 별도 논의가 필요하다 (handoff_v9 §1.4 Reproducibility 검증으로 수치는 deterministic).

4. RQ2 결과 — Neyman paradox honest finding (학술 contribution 2)

4.1 5-way 측정 결과

본 연구는 RQ2를 "분포가 알려진 KM20 cluster에서 어떤 sample allocation 방식이 최적인가"로 정의하고, Bernoulli / Equal / Proportional / Neyman / Anti-Neyman 5-way ablation을 측정하였다. DEEP sf=100 sel=0.01 paired n=455 결과:

Mode	Mean Q-error	$\Delta\%$ vs Bernoulli
Bernoulli	1.748	(baseline)
Equal	1.644	-5.85%
Proportional	1.580	-9.53%
Neyman	1.595	-8.66% (Prop보다 worse!)
Anti-Neyman	1.540	-11.81% (최저)

4.2 Anti < Prop < Neyman paradox 발견

paper §V-B 이론 (Neyman optimal allocation은 σ -weighted로 minimum variance를 보장)에 따르면 Neyman < Proportional이어야 하나, 측정 결과는 **Anti 1.540 < Prop 1.580 < Neyman 1.595**로 paper 이론 위배 양상을 보인다. Wilcoxon two-sided BH-FDR 검정에서 Anti < Bern $p < 0.0001$ 강유의 / Neyman < Prop $p = 0.60$ 유의 X.

Root cause (Axis E σ_j oracle 검증 + Agent #2 cross-verify): - σ_j range 좁음 — DEEP/SIFT/SSN sf=100 KM20 cluster의 cluster 내 sigma는 [0.18, 0.29] 범위로 max/min ratio 1.3-1.6×에 불과 - KM20 cluster N_i CV=0 (균등 cluster size) → proportional $\equiv$ equal allocation 통계 동등 - σ -weighted Neyman alloc cos_sim 0.99 (L1 diff 21-39 sample / 385 budget, 즉 5-10% sample만 다른 쪽으로 이동) - budget=385 hit count noise (~50/seed @ sel=0.1) > Neyman signal (~30 sample 차이 → 약 3 hits)

결론: Neyman/Anti = Proportional과 통계 동등으로 paper §V-B 이론 위배가 아니라 PartSupp PK가 uniform stratum density 분포로 σ -weighted optimization의 변별력이 marginal이 되는 boundary case이며, 본 paradox는 학술 paper-grade의 honest finding이다.

4.3 새 narrative

본 연구는 "분포 알면 Neyman 답"의 5/8 시점 narrative를 다음과 같이 정정한다.

"KM20 stratification이 Bern 대비 일관 5-10% 우위 (DEEP/SIFT × sel 4 cell 모두 입증). 단 KM20 내부 Equal/Prop/Neyman/Anti 차이는 σ_j range 좁아 alloc 무관. PartSupp PK가 uniform stratum density 분포 — σ range 큰 cluster imbalance 영역 (RQ3 영역)에서 Neyman 우위 재검증 필요 → 자연스러운 RQ3 추정 framework 전환."

이는 5/27 발표 storyline 7단계 중 단계 2 ("분포 알면 prop allocation 답")와 단계 3 (RQ3 추정 framework)의 자연 전환을 정당화하며, Phase 4 11 method 중 M9 kmeans_neyman / M11 idistance_neyman의 학술 contribution narrative를 "RQ2 plug-in 직접 강화"가 아니라 **"분포 정보 추정 방식 × Neyman σ allocation 2D ablation — KM20 oracle 가정 한계 발견"**의 honest finding으로 정정한다.

5. RQ3 결과 — 9 paradigm × 56 method × CaseA/CaseB 종합

5.1 paradigm framework 9 (P1-P10, P7/P8 future work)

본 연구는 stratification 알고리즘의 데이터 활용 방식 기준으로 9 paradigm으로 분류한다.

Paradigm	Inductive bias	active method
P1 Cluster (9 active)	"유사 데이터는 군집을 이룬다"	minibatch / gmm / mb_partial / birch / aggllo / coresets / dbscan / kmeans_neyman M9 / hkbu_repsample
P2 Spatial (12 active)	"고차원 → 1D quantile 분할 (space-filling curve, indexing)"	hilbert (alias pca2d_lex) / hilbert_real (Wikipedia) / skilling_hilbert M7 / zorder_morton M6 / idistance M5 / idistance_neyman M11 / faiss_ivf / lpm1_proper M2 / epsilon_net / kdtree / kdpp / lpm2
P3 Streaming (6 active)	"OLTP partial-fit / single-pass"	chao_weighted M1 / reservoir / thompson_sampling / mfm / ams_count_sketch / ccsketch
P4 DimReduction (12 active)	"고차원 → 저차원 투영 보존"	sparse_rp ★4 (Li-Hastie-Church 2006) / random_projection / pca1d / rsvd / ica_fastica M8 / dense_rp / neuram / cca1d / tucker / vinecopula / factor_join / adaptive_bucket_probing
P5 QMC/Hashing (8 active)	"결정론적 균등 → variance 감소"	lsh / sobol / halton / hammersley / lhs / cum_sqrtf M3 / lavalley_hidioglou M4 / lp_bound
P6 Quantization (6 active)	"vector → codeword 변환"	rabitq_strat M10 (Gao-Lin VLDB 2024) / mhist2 / wavelet_hist / pq / opq / cocluster_nystrom
P9 InfoTheoretic ★ 신규	"sketch / count / cardinality 추정"	hyperloglog (Flajolet 2007)
P10 Density ★ 신규	"non-parametric density estimation"	kde_parzen (Parzen 1962)
P7 Subspace / P8 Graph	future work	CLIQUE Agrawal 1998 / Leiden Traag 2019 + Bao et al. VLDB 2025 (HNSW 분포 정보 추출 재활용)

5.2 paradigm rollup CaseB mean $\Delta\%$ (5/11 18:48 update)

Paradigm	n_method	n_obs	mean $\Delta\%$	median	range
P10 Density	1	1	-11.93	-11.93	[-11.93, -11.93] (Q4 9 cells 진행 중)
P9 InfoTheoretic	1	9	-7.60	-8.96	[-10.80, -3.65] (5/11 18:48 회수, 5/9 cells signif) ★
P3 Streaming	6	43	-6.53	-8.46	[-14.73, +26.37]
P4 DimReduction	12	96	-5.92	-7.91	[-14.00, +35.43]
P2 Spatial	12	106	-5.52	-6.48	[-13.62, +18.74] (★3 hilbert + M6/M7/hilbert_real 4건)
P1 Cluster	10	82	+0.17	-2.71	[-12.88, +90.32]
P5 QMC	8	62	+1.47	-4.16	[-12.53, +55.29]
P6 Quantization	6	37	+1.49	-4.65	[-12.77, +62.23]

5.3 CaseA 단독 대체 narrative 무너짐 (정량 입증)

CaseA mode (우리 method가 paper §V-B Bernoulli sampling step을 단독으로 대체) 측정 결과: - one-sided BH-FDR $\alpha=0.05$ outperform: **0/437 (0.0%)** ← 통계 무효 - Cliff's δ large better ($\geq +0.474$): 63 (14.4%) - Cliff's δ large **worsening** (≤ -0.474): 161 (36.8%) ← worsening 압도 - Hedges' g large ($g \leq -0.8$): 43

minibatch_partial M2 (P1, Sculley 2010)이 method-mean $\Delta\%$ **-10.17%**로 단일 method 우위는 보이지만, 9 paradigm 차원에서는 CaseA mode의 paradigm rollup이 모두 worsening 또는 marginal로 paper §V-B Bernoulli baseline 대비 단독 대체의 정당성이 확보되지 않는다. 이는 paper §V-B Adaptive Sampling이 momentum 기반 동적 sample size 조정 (Eq 3-6) + Q-error feedback loop를 통해 자체 robustness를 확보하기 때문이며, 본 연구의 단독 대체 narrative 폐기는 5/11 paper exact 측정의 통계적 결과에 따른 정직 disclosure 이다.

5.4 CaseB ensemble augment 통계 압도

CaseB mode 측정 결과 (5/11 18:50 기준): - **paired CaseB > CaseA: 92.9% (404/435)** — paper review-grade 우위 - Cliff's δ large better ($\delta \geq +0.474$): **63.5% (284/447)** - Hedges' g large effect ($g \leq -0.8$): **56.4% (252/447)** - One-sided BH-FDR $\alpha=0.05$ outperform: **45.0% (201/447)** - Trial-level sign test: 740/1030 (71.8%) better trials, $p = 3.1e-46$ binomial - **Two-sided BH signif: 43.4% (194/447)**

Top 3 CaseB winners (smallest Hedges' g): **pq @ A5-sf1** (g=-7.15, Δ%=-10.87%), **sparse_rp ★4 @ A5-sf1** (g=-7.14, Δ%=-11.62%), **vinecopula @ A5-sf1** (g=-7.05, Δ%=-12.40%). 5 paradigm (P10/P9/P3/P4/P2) 모두 CaseB ensemble 가치를 통계 신뢰성 paper review-grade로 입증한다.

6. 학술 contribution 9종 + ★3 hilbert defect rectify

6.1 ★3 hilbert defect rectify (학술 contribution 5)

본 연구의 학술적 contribution 중 하나는 5/8 시점 4강 narrative의 ★3 Hilbert가 코드 차원에서 PCA 2D lex sort로 구현되어 Faloutsos 1989 *Hilbert curve indexing* (SIGMOD)의 진짜 locality 효과가 아닌 PCA proxy 효과를 측정된 것임을 학술 정직성 기준에서 발견 (5/10 8 agent algorithm audit)하고, 이를 4건의 paradigm anchor 추가 측정으로 rectify한 점이다. 코드 line 449에서 ("**hilbert**", "**pca2d_lex**") **alias** 정직 명명되며, 진짜 Hilbert curve의 paradigm anchor는 다음 3건으로 보강된다.

(1) **M6 zorder_morton** (Morton 1966 *IBM Tech Rep*): Z-order space-filling curve의 paradigm anchor.

(2) **M7 skilling_hilbert** (Skilling 2004 *AIP Conf Proc* 707, "Programming the Hilbert curve"): state-machine algorithm 기반 진짜 high-D Hilbert. 단 conditional swap simplification 1줄은 disclosure (line 401 "Skip exact swap for simplicity").

(3) **hilbert_real** (Wikipedia *Hilbert curve* xy2d 표준): raw [experiments/code/rq3/hilbert/hilbert_curve.py](#) 표준 reference implementation으로 5/11 18:09 회수 9 cells × 2 modes 측정 완료. CaseB ensemble에서 mean -8.2% (9 cells, 6/9 signif p_{adj}<0.05) 강력 입증.

본 4건 (★3 alias + M6 + M7 + hilbert_real) 비교는 "PCA proxy locality vs 진짜 Hilbert locality 분리 검증"의 학술 contribution narrative가 되며, paper review에서 "★3 hilbert가 Faloutsos 1989인지" 질문에 대해 honest disclosure + paradigm anchor substitute 3건으로 응답하는 구조가 된다.

6.2 본 연구 9 contribution (5/8 7 + 5/11 신규 2)

1. RQ1 Selectivity Gradient 단조성 통계 입증 (mean +3.74%)
2. RQ1-sub Measurement Methodology Robustness (Phase 6 vs Phase 7)
3. **RQ2 KM20 oracle robustness + Anti < Prop < Neyman paradox honest finding** (5/11 신규)
4. **RQ3-1 9 paradigm × 56 method framework** (P9/P10 신규 paradigm 발굴, 5/11 신규)
5. **RQ3-2 ★3 hilbert defect rectify + M6/M7/hilbert_real 3건 paradigm anchor** (5/11 신규)
6. RQ3-3 sparse_rp ★4 reference 정정 (Achlioptas 2003 ❌ → Li-Hastie-Church 2006 ○)
7. **CaseA 단독 대체 narrative 무너짐의 정량 입증** (5/11 신규)
8. **CaseB ensemble augment의 통계 압도** (paired 92.9% / Cliff's δ 63.5% / Hedges' g 56.4%, 5/11 신규)

9. paper exact 측정 정합성 4축 검증 (Reproducibility 280/280 byte-identical, 5/11 신규)

7. Honest Limitation 18종 (5/11 신규 5건)

#	Group	Limitation
L1~L4	A v1 (5/7)	Single-table only / Multi-vector future work / SF=100 부담 / KM20 oracle 학습 부담
L5~L8	B 5/8 W4 sprint	RQ1 measurement methodology / Effect size practical small (5/11 정정) / P5 LSH Wave 0 fail / 5 paradigm 외 누락
L9~L11	C V7 audit	Reservoir = RANDOM20 proxy / LSH K=20 vs n_hp=5 misalignment / sparse_rp = Li 2006 $1/\sqrt{D}$ variant
L12 ★ 5/11 신규	D	측정 미커버 233 cells (20.5%) 9 카테고리 정직 분류
L13 ★ 5/11 신규	D	RQ2 Neyman/Anti paradox honest finding (σ_j range 1.3-1.6× narrow + N_i CV=0)
L14 ★ 5/11 신규	D	★3 hilbert PCA 2D lex sort alias (Faloutsos 1989 ❌ → pca2d_lex 명명)
L15 ★ 5/11 신규	D	byte-identical cells 7쌍 (A1-DEEP ≡ A5-sf100 등)
L16 ★ 5/11 신규	D	A4-sel sel=0.001 calibration parquet 부재 fallback heuristic
L17	D	P9/P10 신규 paradigm anchor 측정 진행 (5/11 18:16 launch + 18:48 P9 hyperloglog 회수)
L18	D	본 연구 framework scope 한정 (Exqutor §V-B 영역, ECQO §V-A는 paper main result 인정)

8. 일정 + 자료 위치

8.1 Timeline

일시	일정
5/12 morning	Q4 4 method 회수 + REPORT v9 + figures 재생성 + slide PDF 재변환
5/13~5/14	박세은 / 강재현 / 이동욱 검토 + 박광현 미팅 자료 finalize
5/15 (금) 14:00	★ 박광현 교수님 미팅 (D-4)
5/15~5/20	자문 메일 v6 박성원 멘토 발송 + 회신 대기
5/16~5/26	5/27 발표 deck update (Academic v3 base, slide-by-slide 정정 11종)
5/27 (수) 19:00	★ 최종 발표 (D-16)
5/29~6/10	최종 보고서 sprint (W5~W6)
6/11 (목)	★ 최종 보고서 제출 (D-31)

8.2 자료 위치 종합

본 file 외 핵심 자료는 다음과 같다.

자료	파일
요약 (1장)	submission/_drafts/팀원_요약_20260511.{md,pdf}
본 file (학술 상세)	submission/_drafts/팀원_이해용_종합_20260511.{md,pdf}
5/15 박광현 미팅	submission/_drafts/박광현_5월15일_미팅/ (4 file)
5/27 storyline v2.5	plans/5_27_storyline_draft_20260511_1410.md
6/11 보고서 outline v3 plan	plans/6_11_보고서_outline_v3_update_plan_20260511.md
6/11 §3/§4.4/§5.3/ §1 본문 sketch	plans/6_11_보고서_section_*.md (4 file, 5/29~6/10 sprint 가이드)
분석 본체 (server)	/mnt/hdd0/home/capstone2026/cache/rq3/paper_exact/REPORT_paper_exact.md (1285 line v8.5)
figures 6건 (Korean font)	experiments/figures/paper_exact_v7/F1~F6.png
자문 메일 v6 (박성원, 5/11 paper exact 반영)	(작성 중)
5/27 발표 deck v3	submission/_drafts/속도논벡터 - Academic v3 · Final 5_27.{pdf,pptx} (5/8 base, 5/16~5/26 update 예정)
handoff anchor (Claude Code 다음 세션)	_internal/handoff/active/handoff_v9_post_cleanup_20260511_1755.md

작성: 2026-05-11 19:20 KST

다음: Q4 4 method 회수 후 §5.2 paradigm rollup P10/P6/P4 수치 update + 5/15 박광현 미팅 confirm 후 narrative 정합성 점검 → 5/16~5/26 발표 deck update + 5/29~6/10 보고서 sprint