

Exqutor 벡터 카디널리티 추정의 단일 테이블 사각지대와 Skew-Aware Sampling

팀명: 속도는벡터

소속: 연세대학교 컴퓨터과학과 2026-1 캡스톤 디자인

팀원: 박세은(팀장), 강재현, 조현빈, 이동욱

지도 교수: (지도 교수 성함)

작성일: 2026-04-28

제출 종류: 중간 보고서 v1

1. 연구 주제

본 연구는 벡터 데이터베이스의 카디널리티 추정 정확도 문제를 해결한 Exqutor (arXiv:2512.09695v2)의 Adaptive Sampling이 가진 두 단계 한계 — 단일 테이블 vector range query 사각지대 (motivation finding)와 naive uniform sampling의 정확도 손실 (개입 측정) — 를 정량 드러내고, `vector.c` 한 줄 교체 (Pivot A)와 data-side k-means K=20 기반 stratified sampling의 native 구현 (Pivot C)으로 두 sanitize를 직교 ablation matrix로 분리 측정한다. 본 보고서는 4월 14일~15일 사이에 수행한 RQ1 Motivation + RQ2 본선 (Phase 1~7)의 결과를 정리하고, 6월 11일 최종보고서까지의 RQ3 Distribution-Agnostic 확장 로드맵을 함께 제시한다.

2. 연구의 필요성

2.1 벡터 카디널리티 추정 문제

벡터 데이터베이스에서 주어진 query 벡터와 유사도가 임계값 이상인 행의 개수를 추정하는 문제는 옵티마이저의 실행 계획 선택에 직접 영향을 미치는 핵심 작업이다. pgvector는 벡터 조건의 선택도를 33.3%로 고정 추정하고, VBASE는 50%, DuckDB는 100%로 추정한다. 그러나 실제 선택도는 query에 따라 0.001%부터 90%까지 매우 넓은 범위를 가지며, 고정 비율 추정으로는 옵티마이저가 nested loop join과 hash join 사이, 또는 vector index 사용 여부 사이에서 잘못된 선택을 내리는 사례가 빈번하다. Exqutor는 이 문제에 두 가지 해법을 제시했다. **ECQO**는 HNSW 인덱스가 있을 때 range query를 직접 실행해 1~2 ms 안에 정확한 카디널리티를 획득하는 방식이며, **Adaptive Sampling**은 인덱스가 없을 때 모멘텀 기반 동적 샘플링으로 카디널리티를 근사한다. 두 방법으로 Exqutor는 pgvector에서 최대 1000 배, VBASE에서 10000 배, DuckDB에서 1.5~37 배 성능 향상을 보고했다.

2.2 Exqutor Adaptive Sampling 의 잠재적 약점

본 팀의 출발 가설은 4 월 3 일 교수님 미팅에서 합의된 명제로 정리된다. *Exqutor 의 Adaptive Sampling 은 무작위 샘플이 전체 데이터의 거리 분포를 대표한다는 암묵적 가정 위에 동작하며, 거리 분포가 한쪽으로 치우친 (skewed) 환경에서는 무작위 샘플이 밀도가 높은 영역에 편중되어 카디널리티 추정 정확도가 떨어진다.* 본 가설을 데이터로 확인하고, distribution-aware sampling (분포를 알 때) 과 distribution-agnostic sampling (분포를 모를 때) 두 노선에서 정확도 개선을 정량 측정하는 것이 본 연구의 큰 골격이었다.

본 가설을 4 월 14 일에 직접 검증하는 과정에서 본 팀은 두 가지 발견에 도달했다. 첫째, 4 월 3 일 합의의 핵심 명제 — *글로벌 skewness 지표 (Fisher γ 등) 가 클수록 Q-error 도 크다* — 는 96 차원 DEEP 벡터의 1M subset 100 query $\times$ 6 selectivity $\times$ 5 seed = 3000 측정에서 강하게 기각되었다. 둘째, 같은 데이터에서 Exqutor 가 사용하는 `TABLESAMPLE SYSTEM` 의 block sampling bias 와 `vector.c` 의 hook trigger 조건 (`table_count > 2`) 이 만드는 단일 테이블 vector range query 사각지대 등 네 가지 design constraint 를 발견했다. 본 두 발견은 4 월 3 일 합의의 큰 골격을 유지한 채, 측정 정의와 본선 시나리오를 정교화한 결과 (이하 v4 수정 설계안) 로 이어졌다. 본 보고서의 §4 는 이 정교화의 모든 단계를 정량 결과와 함께 정리한다.

3. 연구 질문

본 연구는 4 월 3 일 합의의 RQ1/RQ2/RQ3 세 단계 구조를 그대로 유지하며, 각 RQ 의 측정 정의를 4 월 14 일~15 일의 정량 결과 위에서 정교화한다.

RQ1 — Motivation 검증 (단일 테이블 사각지대 + 구조적 finding). Exqutor 의 Adaptive Sampling 은 단일 테이블 vector range query 시나리오에서 어떤 구조적 한계를 가지며, 그 한계는 어디에서 측정 가능한가? 본 RQ 는 (i) Hook trigger 사각지대, (ii) plan replacement 부작용, (iii) `TABLESAMPLE SYSTEM` block bias, (iv) query feature 사전 식별 불가능성의 네 finding 을 직접 소스 검증과 EXPLAIN ANALYZE 로 정량 드러낸다.

RQ2 — Distribution-Aware (Pivot A + Pivot C 병합). 분포를 알 때 (또는 데이터 자체의 partition 을 사전 학습할 수 있을 때), 두 단계 sanitize — `vector.c` L889 한 줄 교체로 block sampling bias 제거 (Pivot A) + data-side k-means K=20 기반 stratified sampling 의 native 구현 (Pivot C) — 가 카디널리티 추정 정확도를 얼마나 개선하는가? 본 RQ 는 BERN/STRAT $\times$ dataset $\times$ selectivity 의 직교 ablation matrix 로 두 sanitize 의 효과를 분리 측정한다.

RQ3 — Distribution-Agnostic (1D distance KDE + quantile 경계). 분포를 모르는 상황에서, query 별 pilot sample 의 거리 값을 1D Gaussian KDE 로 fit 하고 quantile 경계로 자동 stratification 하면, 사전 학습 없이도 RQ2 에 준하는 정확도를 얻을 수 있는가? 본 RQ 는 고차원 k-means 재학습을 회피하는 경량 경로로 구현되며, 본 중간 보고서 시점 (4/28) 에서는 진입하지 않고 최종 보고서 (6/11) 국면 (W7, 5/12~5/18) 에서 수행한다.

4. 연구 내용 — 4월 14일 ~ 15일의 측정 결과

4.1 출발점 — 4월 3일 교수님 합의

4 월 3 일 미팅에서 본 팀은 Exqutor 의 Adaptive Sampling 정확도 개선을 본선 주제로 확정하고, 두 트랙 — 분포 인지 / 분포 무인지 — 의 3 단계 실험 구조 (베이스라인 → 트랙 A → 트랙 B) 를 합의했다. 본선 시나리오는 **multi-table join with vector range filter** 로 가정되었고, 첫 단계의 판단 기준은 *Fisher* 의 *skewness* γ 큰 그룹의 *Q-error* 가 작은 그룹 대비 2 배 이상 이었다. 본 합의의 자세한 narrative 는 [plans/연구 설계안_20260403_162818.md](#) (v3) 에 정리되어 있으며, 본 보고서의 모든 정교화는 v3 의 큰 골격을 유지한 채 측정 정의만 4/14~15 데이터 위에서 단단하게 만든 결과다. v4 수정 설계안 ([plans/수정 연구 설계안_20260415_001500.md](#)) 이 두 버전의 차이를 표로 정리한다.

4.2 RQ1 1차 실험 — 가설 H1 기각과 Phase 5 8지표 전수 검증

본 팀은 4 월 14 일 오전에 연세대학교 BDAI Lab 서버 ([capstone2026@165.132.140.240](#)) 에 vanilla PG 16.9 + pgvector 0.7.1 환경을 구축하고, [partsupp_deep_10](#) (TPC-H sf10 + 96 차원 DEEP 벡터, 8M 행) 의 1M 결정론적 서브셋 위에서 RQ1 1차 실험을 5 단계 (Stage 1~5) 로 수행했다. 100 query 를 무작위 추출하고, 각 query 에 대해 6 개 선택도 구간 (0.001 / 0.010 / 0.050 / 0.100 / 0.300 / 0.500) 의 D_{target} 을 사전 계산한 뒤, Adaptive Sampling 을 Python 으로 재구현해 5 seed $\times$ 2 mode ([bernoulli](#) , [block_system](#)) $\times$ 100 query $\times$ 6 selectivity = 6000 측정의 q-error 를 산출했다. 본 실험의 자세한 절차와 산출물은 [experiments/results/rq1_motivation/summary.md §I~II](#) 에 정리되어 있다.

검증 결과는 가설 H1 을 강하게 기각했다. 4 가지 글로벌 skew 지표 (Fisher γ , log-Fisher γ , tail ratio P99/P50, Bowley skew) 와 query 별 median Q-error 의 Spearman 상관은 모든 24 개 조합 (4 지표 $\times$ 6 선택도) 에서 절대값이 0.2 미만이었으며, $|\gamma| > 1$ 그룹과 $|\gamma| < 0.5$ 그룹의 median Q-error 비율도 12 개 조합 모두에서 1.00 근처였다. 100 query 가 모두 Fisher $\gamma < 0$ (left-skewed) 이며 tail ratio P99/P50 도 1.07~1.17 의 좁은 범위에 모여 있어, 96 차원 벡터의 *고차원 거리 집중 (distance concentration)* 현상이 글로벌 skewness 지표의 변별력을 평탄화시켰다는 것이 1 차 진단이었다.

본 진단을 보강하기 위해 4 월 14 일 저녁 (Phase 5) 에 **로컬 4 지표** — k-NN distance entropy, k-NN PCA EVR1, KDE modality count, NN clustering coefficient — 를 numpy + scipy 만으로 직접 구현해 같은 100 query 에 적용했다. 결과는 24 개 조합 (4 지표 $\times$ 6 선택도) 모두에서 $|\text{Spearman } \rho| < 0.2$ 였다. 글로벌 4 + 로컬 4 = **8 지표 전수 검증 후 query-conditional layer 정의가 사전 식별 불가능** 함이 확정되었다. 이는 본 연구의 중요한 negative result 이며, RQ1 motivation 의 한 축으로 직접 편입되어 *query feature* 가 아닌 *data-side* 에서 *layer* 를 가져와야 한다는 Pivot C 의 정당화로 사용되었다.

4.3 Exqutor Design Constraint 발견 — 새 motivation 첫 줄

H1 기각의 정량 결과 위에서 본 팀은 Python 재구현이 Exqutor 네이티브와 정확히 일치하는지 확인하기 위한 옵션 A (Phase 3 native bitwise 검증) 를 같은 날 오후에 시도했다. 그 시도는 두 가지 강력한 finding 으로 이어졌으며, 본 두 finding 은 본 연구 motivation 의 새 첫 줄로 격상되었다.

첫째 — Hook trigger 사각지대. Exqutor 의 `pgvector_set_base_rel_rows_estimate_hook` 은 `vector.c` line 243 의 `if (table_count > 2)` 조건을 통과해야만 활성화된다. 본 팀의 검증 query 인 `SELECT count(*) FROM partsupp_deep_10_subset_1m WHERE (ps_embedding <-> q) < D` 는 단일 테이블이므로 `table_count = 1` 이고, 따라서 hook 이 우회되어 PostgreSQL default selectivity 1/3 으로 fall-through 된다. 즉 단일 테이블 vector range query 는 Exqutor 의 Adaptive Sampling 함수 자체에 도달하지 못하는 사각지대다. 이는 Exqutor 원문 본문에 명시되지 않은 design constraint 이며, 본 팀의 직접 소스 검증으로 처음 정량 확인되었다. 이미지 검색, 추천 시스템, RAG 의 retrieval 단계가 모두 단일 테이블 vector range query 의 전형이라는 실무적 관찰은 본 사각지대를 본 연구가 채울 수 있는 학술적 빈자리로 격상시킨다.

둘째 — Plan replacement 부작용. 위 hook 을 `if (table_count >= 1)` 로 한 줄 우회하면, outer query 의 base relation 노드 자체가 PostgreSQL 의 `Sample Scan` 으로 plan-tree 가 교체된다 (`Sampling Method: system, Sampling Parameters: ['0.0385'::real]`). 단일 테이블 시나리오에서는 outer query 결과 자체가 sample 안 부분 카운트로 격하되어 (예: true=100,000 query 에서 `SELECT count(*)` 가 32 반환), outer query 의 정확성이 깨진다. multi-table join 에서는 base table sample scan 으로의 교체가 join 결과의 부분 영향만 주지만, 단일 테이블에서는 outer query 의 의미를 잃게 만드는 design constraint 다.

본 두 finding 외에도 옵션 A 시도 중 (iii) q-error inf 발산, (iv) sample_size NaN 발산, (v) Adaptive update path SIGSEGV 의 세 가지 추가 design constraint 가 발견되었다. 본 세 finding 은 Adaptive Sampling 의 update path 가 multi-table only design intent 를 가정하고 만들어진 결과이며, 본 연구의 측정 단계에서는 `vector.update_sample_size = off` GUC 로 update 경로를 차단하고 sampling method 자체의 효과만 분리 측정하는 방식으로 회피했다. 자세한 narrative 는 `experiments/results/rq1_motivation/direction_pivot_rationale.md` 에 187 줄로 정리되어 있다.

4.4 Pivot A + Pivot C 병합 노선 확정 (4월 14일 17:35 KST)

위 finding 들을 근거로 본 팀은 4 월 14 일 17:35 KST 에 **Pivot A + Pivot C 병합 노선** 을 확정했다. 4 월 3 일 합의의 큰 골격은 그대로 유지되며, 다음 두 차원에서 정교화가 일어났다.

시나리오 좁힘. 본선 시나리오를 multi-table join with vector range filter 에서 단일 테이블 vector range query 사각지대로 좁힌다. 좁힘의 비용은 multi-table 벤치마크와의 직접 비교 불가능이며, 대응은 (i) 본 연구 motivation 자체가 사각지대를 드러내는 것이므로 multi-table 비교가 필요 없고, (ii) 단일 테이블 시나리오의 실무적 중요성이 본 연구의 외적 타당성을 강화한다는 것이다.

측정 도구의 교체. Layer 정의를 query-side feature 에서 data-side partition 으로 이전한다. Phase 5 의 8 지표 negative result 가 query-side feature 의 사전 식별 불가능성을 보였으므로, 본 팀은 데이터 자체에 대한 numpy mini-batch k-means K=20 (seed=42) 학습으로 stratum 을 정의하고 각 행에 `stratum_id smallint` 컬럼을 사전 부여해 query 시점의 overhead 를 0 으로 만든다.

본 두 정교화 위에서 두 sanitize 가 정의된다. **Pivot A** 는 `vector.c` L889 의 `TABLESAMPLE SYSTEM(%f)` 을 `TABLESAMPLE BERNOULLI(%f)` 로 한 줄 교체하는 단순 변경이며, Exqutor 가 사용하는 block sampling 의 row-correlation bias 를 제거하는 *fair baseline* 도구다. **Pivot C** 는 `vector.c` 에 +228 줄의 stratified sampling 분기를 추가하여 GUC `vector.sampling_method = 'stratified'` 활성화 시 per-stratum `ORDER BY random() LIMIT sample_size/K` 형태의 SPI SQL 로 층별 균등 sample 을 추출하고 Horvitz-Thompson 가중 카디널리티 추정식 $est = \sum (n_i \times cnt_i / s_i)$ 을 native 에서 계산하는 본 연구의 핵심 본선 구현이다. 두 Pivot 은 직교적이므로 SYSTEM/BERNOULLI/STRATIFIED × dataset × selectivity 의 ablation matrix 로 각 개선의 기여를 분리 측정할 수 있다.

4.5 Phase 4 — Pivot A Native 검증 (4월 14일 19:30~19:40 KST)

`vector.c` L889 한 줄을 sed 로 교체하고 (BERNOULLI), `make USE_PGXS=1 install` 로 새 `vector.so` 를 빌드한 뒤 Exqutor PG 55436 을 fast restart 했다. 100 query × 6 selectivity × 1 seed × 2 mode = 1200 query 를 native 경로에서 EXPLAIN (ANALYZE, FORMAT JSON) 으로 측정했고, 각 query 의 plan tree 첫 Scan 노드의 Plan Rows + Sampling Method 를 추출해 q-error 를 계산했다. 결과는 다음과 같다.

selectivity	SYS median	BERN median	diff% (SYS- BERN)	paired Wilcoxon p (alt: SYS > BERN)	win (SYS<BERN)
0.001	2.5970	2.5970	+0.0%	0.596	6/8
0.010	1.5584	1.2987	+20.0%	0.240	45/40
0.050	1.2031	1.1948	+0.7%	0.0009 ★★	58/37
0.100	1.2120	1.1323	+7.0%	< 0.001 ★★★	66/31
0.300	1.2095	1.0794	+12.0%	< 0.001 ★★★	76/24
0.500	1.1527	1.0519	+9.6%	< 0.001 ★★★	78/22

selectivity 0.05 이상 4 구간에서 모두 paired Wilcoxon p < 0.001 (s=0.05 만 0.0009) 로 SYSTEM 의 q-error 가 BERNOULLI 보다 통계적으로 유의하게 크다. 가장 큰 효과는 s=0.500 에서 78/100 query 가 SYSTEM 쪽 불리, median 기준 9.6%p 개선. `src/vector.c` 한 줄 sed 교체로 Exqutor 의 카디널리티 추정 정확도가 측정 가능한 수준으로 개선된다는 것이 native 로 직접 확인되었다. Phase 4 의 native 수치는 §4.2 의 Python counterfactual (+3.8~9.1%) 과 같은 order of magnitude 로 방향이 일치한다. 자세한 산출물은 `experiments/results/rq1_motivation/phase4_*.parquet` + `phase4_compare.json` .

4.6 Phase 6 Step 4 — Pivot C KM20 Native 구현과 정상 selectivity 검증 (4월 14일 22:00 KST)

Phase 6 Step 1~3 (Python counterfactual) 와 Step 3' (4 layer 비교: bernoulli / pca_decile / kmeans_k10 / kmeans_k20) 위에서 KM20 = best layer 가 확정되었으며, 본 Step 4 는 그 KM20 stratified 를 native 로 직접 구현한 단계다. 본 팀은 `vector.c` 에 +228 줄의 stratified 분기를 추가하고 (GUC 3 개 + stratum_sizes 캐시 + estimate 함수), `partsupp_deep_10_subset_1m` 에 `stratum_id smallint` 컬럼 + 인덱스를 부여한 후 (data-side ALTER TABLE 옵션 B), 100 query × 6 selectivity × 1 seed × 2 mode = 1200 query 를 native 경로에서 측정했다. q-error 는 EXPLAIN 의 plan_rows 와 서버 로그의 hook estimate 에서 양쪽으로 추출해 일치성을 검증했다.

selectivity	BERN median	STRAT median	diff%	paired Wilcoxon p (alt: STRAT < BERN)	win
0.001	2.5806	2.5806	+0.00%	0.451	26/22
0.010	1.2917	1.3874	-7.41%	0.797	44/56
0.050	1.2109	1.1429	+5.62%	0.00678 ★★	64/36
0.100	1.1097	1.1083	+0.12%	0.0447 ★	61/39
0.300	1.0623	1.0523	+0.94%	0.102	52/48
0.500	1.0529	1.0339	+1.81%	4.01e-05 ★★★	66/34

3 selectivity 구간 ($s=0.050, 0.100, 0.500$) 에서 STRAT 가 BERN 대비 paired Wilcoxon $p < 0.05$ 우위. **최강 신호는 $s=0.500$ 에서 $p = 4.01e-05$** 로 본 연구 RQ2 본선의 한 anchor 가 된다. 작은 selectivity 영역 ($s=0.001$) 에서는 두 모드가 동률 (median 2.5806) 이었는데, 이는 sample 385 안에서 매칭이 0~1 개로 떨어져 BERN 의 cnt-clamp `cnt=0 → 1` 와 STRAT 의 `cnt_total=0 → est_total=total/budget` fallback 이 같은 값 ($993541/385 \approx 2.581$) 을 반환하는 구조적 동치성의 결과다. 본 영역은 어떤 stratification 도 개선이 어렵다는 것이 본 시점의 진단이었으나, §4.7 의 Phase 7 8M 측정에서 같은 영역이 다른 결과를 보이게 된다.

본 Step 4 의 결과는 Python counterfactual (Step 3') 와도 직접 비교되었다. 6 selectivity 구간 중 4 구간 ($s=0.001, 0.010, 0.100, 0.500$) 에서 양쪽이 정성적으로 일치 (둘 다 무의 또는 둘 다 ★) 하며, 2 구간 ($s=0.050, 0.300$) 에서 부분 이동 (한쪽만 ★). 유의 구간 수 (3 개) 가 보존되고 효과 크기가 같은 order of magnitude (0.33 ~ 5.62%) 인 점에서 Python 재구현의 native 재현 가능성이 확정되었다. 자세한 수치는 `phase6_native_paired.json` 과 `summary.md §IX.4` 에 정리되어 있다.

4.7 Phase 7 — 외적 타당성 확장 (4월 15일 08:31 KST)

Phase 6 Step 4 직후의 결과는 $1M\ subset \times 96d\ DEEP\ 단일\ dataset \times 100\ query \times 1\ seed$ 라는 좁은 조건에 한정되어 있어 외적 타당성이 부족했다. 본 팀은 4 월 15 일 오전에 두 가지 외적 타당성 확장을 추가로 수행했다.

Phase 7-1 sf10 8M 재현 (`partsupp_deep_10_phase7_8m_subset` , 옵션 B 안전 경로). 원본 `partsupp_deep_10` 8M 행을 별도 테이블로 COPY 후 (보존) numpy mini-batch k-means K=20 (seed=42) 으로 8M 전체에 stratum_id 를 학습·UPDATE 하고 인덱스 + VACUUM ANALYZE 를 적용했다. setup 17 분 + measurement 23 분, 100 query × s=0.500 D_target × 2 mode = 200 query 측정.

Phase 7-2 sift 128d 확장 (`customer_sift_10_phase7_noidx_subset`). vanilla PG 55435 의 `customer_sift_10` (1.5M, 128d, HNSW 있음) 에서 c_custkey + c_embedding 만 Exqutor PG 55436 으로 minimal transfer 한 후 (838 MB, 2 분 33 초), HNSW 없이 별도 테이블에 KM20 stratum_id 를 부여했다. setup 3 분 + measurement 7 분, 100 query × s=0.500 D_target × 2 mode = 200 query 측정.

본 두 실험의 결과는 다음 표로 정리된다. 의도한 selectivity 0.500 이 1M subset 에서 derive 된 D_target 의 8M / 128d 적용에서 actual selectivity 약 0.0001 영역으로 이동했는데 (1M 과 8M / 96d 와 128d 의 거리 분포 dense 효과), 이는 paired 비교의 타당성을 깨지 않으며 같은 D_target 위에서 두 모드의 q-error 차이는 valid 한 측정이다.

단계	데이터셋	dataset size	actual sel	BERN median q-error	STRAT median q-error	improvement	paired Wilcoxon p	win/total
Phase 6 Step 4	deep 96d 1M	1,000,000	0.500	1.0529	1.0339	1.018×	4.01e-05 ★★★	66/100
Phase 6 Step 4	deep 96d 1M	1,000,000	0.001	2.5806	2.5806	1.0× (동률)	0.451	26/100
Phase 7-1	deep 96d 8M	8,000,000	0.000024	20810.21	9.60	2,168×	1.95e-18 ★★★★★	100/100
Phase 7-2	sift 128d 1.5M	1,500,000	0.000128	3875.34	9.48	409×	1.95e-18 ★★★★★	100/100

본 결과의 학술적 함의는 세 가지다.

첫째, **Pivot C 의 효과가 정상 selectivity 영역과 small selectivity 영역 양쪽에서 정량 확인됨**. 정상 영역 (Phase 6 Step 4 의 s=0.500) 에서는 +1.81% 의 정량 개선과 paired Wilcoxon p=4.01e-05 의 통계적 유의로 측정되며, small selectivity 영역 (Phase 7 의 actual sel ≈ 0.0001) 에서는 median q-error 가 BERN 의 1/409 ~ 1/2168 수준으로 감소한다. 두 영역은 효과 크기가 매우 다르지만 (1.018× vs 2168×), 두 영역 모두에서 STRAT 가 win 한다는 일관성 자체가 본 노선의 강건성을 입증한다.

둘째, **Small selectivity 영역의 강한 효과**는 BERN 의 **cnt-clamp fallback 구조적 한계**와 STRAT 의 **stratum 균등 추출 + HT 가중 estimator 의 차이**를 직접 드러낸다. Phase 7-1 의 BERN 측정은 sample 385 안에서 dense cluster 의 매칭이 우연히 들어와 estimator 가 약 4M 의 plan_rows 를 반환하는 반면 (true $\approx$ 200, q-error $\approx$ 20810), STRAT 는 20 stratum 으로 cluster 를 사전 분리해서 dense cluster 의 매칭에 작은 weight 를 적용하므로 estimator 가 안정적이다 (median q-error 9.60). 이는 본 연구가 Pivot C 의 학술적 motivation 으로 제시한 *data-side partition* 의 효과는 *sample 안 분포 균등성에서 온다* 라는 명제를 직접 데이터로 확인한 결과다.

셋째, **Phase 7-1 의 ratio 2168×** 는 본 연구 전체의 단일 최강 신호이며, Phase 6 Step 4 의 $s=0.500$ $p=4.01e-05$ 와 함께 RQ2 본선의 양대 anchor 를 형성한다. 본 두 anchor 는 정확도 영역의 양극단 (정상 selectivity 영역의 정량 우위, small selectivity 영역의 정성 압도) 을 커버하며 상호 보완적이다.

본 Phase 7 측정 진행 중 발견한 다섯 가지 기술 이슈 — psycopg3 copy iterator 의 memoryview chunk yield, Adaptive update path snapshot 부재 에러, Exqutor stratified hook 의 normal SELECT 와의 plan tree 충돌, Postgres log file 의 UTC date rotation, EXPLAIN ANALYZE hook call 횟수 align 어려움 — 은 모두 본 보고서 작성 시점까지 fix 완료되어 위 정량 결과를 확보했다. 본 finding 들은 RQ1 motivation 의 Exqutor design constraint 목록에 추가되지 않으며, 본 팀의 측정 코드 안정화 작업으로 분류된다.

5. 종합 — 보고서 시점의 RQ 진행률과 한계

5.1 RQ 진행률

RQ	정의	진행률	핵심 결과
RQ1	4 design constraint finding + query feature 사전 식별 불가능성	~95%	8 지표 negative + 5 design constraint 모두 정량 확인. 시각화 6 figure 완성.
RQ2	Pivot A + Pivot C 직교 ablation	~70%	Phase 4 4 구간 $p < 0.001$ + Phase 6 Step 4 3 구간 ★ + Phase 7 deep 8M (2168×) + sift 128d (409×) 모두 완주
RQ3	1D distance KDE quantile 경계	0%	최종발표 W7 (5/12~5/18) 진입 예정

5.2 본 시점의 한계 (honest report)

본 중간 보고서 시점의 RQ1/RQ2 결과는 다음 네 가지 한계를 인지하고 기록한다.

(a) **단일 dataset family 에 대한 제한된 외적 타당성**. Phase 7 까지의 측정은 deep 96d (1M, 8M) + sift 128d (1.5M) 의 두 데이터셋 family 에서 수행되었으며, 차원 96~128 의 좁은 영역만 커버한다. 768 차원 wiki 데이터셋 ([part_wiki_10](#)) 은 최종발표 W5 에 검증한다.

(b) 작은 query × seed 표본. 100 query × 1 seed 의 측정은 paired Wilcoxon test 의 통계적 power 측면에서 충분하지만, 효과 크기의 신뢰구간이 좁아 보일 위험이 있다. 최종발표 W6 의 전면 ablation 은 500 query × 10 seed 로 표본을 확대한다.

(c) Phase 7 의 actual selectivity 가 의도한 0.500 이 아닌 약 0.0001 영역. 이는 1M subset → 8M 원본 또는 96d → 128d 의 거리 분포 dense 효과로 인한 자연스러운 결과이며, paired 비교는 valid 하지만 narrative 작성 시 honest 보고가 필요하다. 본 보고서 §4.7 와 자문 이메일 §5 에서 이를 명시했다.

(d) `vector.c` 의 단일 테이블 hook 우회 수정의 reviewer 관점 위험. 본 팀의 측정은 `vector.c` line 243 의 `if (table_count > 2)` 를 `if (table_count >= 1)` 로 한 줄 수정한 상태에서 수행되었으며, 변경된 binary 와 원본 백업을 모두 보존해 검증 가능하게 만들어두었다. 그러나 이 변경 자체가 Exquitor 의 design intent 를 임의로 patch 한 것으로 보일 위험이 있어, 본 팀은 멘토 자문 이메일에서 이를 직접 질의하고 narrative 톤 조정 권고를 요청했다.

본 네 가지 한계 외에 본 연구의 측정 자체가 가진 정량적 약점은 §4 의 각 절에서 honest 하게 기록되었으며, Phase 5 의 8 지표 negative result 는 부정 결과로서 motivation 의 한 축으로 직접 편입되었다.

6. 남은 작업 — 최종발표 (5/27) + 최종보고서 (6/11) 까지

본 팀은 4 월 28 일 중간발표 직후부터 6 월 11 일 최종보고서 제출까지의 4 주를 W5~W8 로 분할해 다음과 같이 수행한다. 자세한 세부 작업과 리스크 대응은 `plans/수정 연구 설계안_20260415_001500.md` SVI 에 정리되어 있다.

W5 (4/28~5/4) — 최적화 + Layer sweep + wiki 768d 검증. (i) 현재 STRAT 의 `ORDER BY random() LIMIT` 의 BERN 대비 11 배 비용을 per-stratum `TABLESAMPLE BERNOULLI` 로 교체하여 2 배 이내로 줄인다. (ii) Layer 후보 4 종 (KM30/40/50, random projection, multi-layer PCA, k-means on float16) 의 selectivity 3 구간 비교로 KM20 유지 또는 전환을 결정한다. (iii) `part_wiki_10` (768d) 에서 KM20 학습이 empty cluster 없이 동작하는지 사전 검증하고, 실패 시 PCA 96d 축소 또는 100K subset 으로 fall-back 한다. (iv) sift 128d 를 6 selectivity 전 구간 + 500 query 로 확대 측정한다.

W6 (5/5~5/11) — 3 dataset × 3 mode × 6 sel × 10 seed × 500 query 전면 ablation. 본 주차의 핵심 결과는 최종보고서의 main result table. 예산 계산은 270,000 측정 × query 당 1~2 초 = 75~150 시간 → W5 의 per-stratum BERN 최적화 적용 시 약 25 시간 → 주말 + 주중 야간 분할 수용 가능. 결과 분석과 시각화 1 차도 본 주차 말에 착수한다.

W7 (5/12~5/18) — RQ3 KDE-pilot 구현. (i) Python counterfactual 로 1D distance KDE + quantile 경계 estimator 를 먼저 구현하고 RQ2 의 KM20 estimator 와 동치성을 확인한다. (ii) `vector.c` 에 `sampling_method = 'kde_pilot'` 분기를 추가 (+200 줄 예상) 하고 native 로 측정한다. (iii) pilot 크기 sensitivity (0.5 / 1 / 2 / 5%) 와 비용-정확도 trade-off 곡선을 산출한다. 본 RQ3 의 핵심 회피 경로는 *고차원 k-means 재학습 없이 1D distance KDE 만 사용* 하는 것이며, 본 경로가 실패하면 histogram 기반 단순 총화로 degrade 한다.

W8 (5/19~5/25) — 최종보고서 + 포스터 + 전시회 데모. (i) 본 중간보고서를 확장 + Phase 7 후속 결과 + RQ3 결과 반영. (ii) 포스터 제작 (KM20 의 $s=0.500$ $p=4.01e-05$ 와 Phase 7-1 의 ratio 2168 을 hero figure 로 배치). (iii) 전시회 데모 스크립트 (Exqutor 기본 vs Pivot A vs Pivot C 세 경로 실시간 시연). (iv) 팀 내부 리허설 2 회.

본 4 주 로드맵의 세 가지 리스크 — (R1) 측정 시간 폭발, (R2) wiki 768d k-means 재학습 실패, (R3) RQ3 KDE 고차원 불안정성 — 각각에 대한 fall-back 경로도 v4 수정 설계안 §VI.5 에 정리되어 있다.

7. 일정 및 역할 분담

본 팀의 4 월 14 일 단독 결정에 따라 RQ1 의 실험 설계 / 실행 / 결과 수집 / 분석 / 시각화 / 문서 초안 작성은 조현빈이 전담하고, 멘토 자문 / 보고서 구성 조율은 박세은 (팀장) 이 담당한다. 발표는 팀원이 분담하며, 조현빈이 발표자용 기술 맥락 문서와 예상 Q&A 를 제공한다. 본 분담은 환경 세팅 (4/13 수령, 4/14 빌드 완주) 직후의 **맥락 단 일화 + 도구 확보 + 공동 계정 충돌 방지** 의 세 근거에 따라 단독으로 공지되었으며, 본 보고서 작성 시점까지 그대로 유지된다.

담당	역할
박세은 (팀장)	멘토 자문 / 보고서 구성 조율 / 발표 분담 / 자문내역서 수령
조현빈	RQ1/2/3 실험 설계·실행·분석·시각화·초안 / 기술 맥락·예상 Q&A 문서
강재현	슬라이드 검토 / 발표 분담 / 리허설
이동욱	슬라이드 검토 / 발표 분담 / 리허설

일정	핵심 작업
4/14 화	환경 빌드 완료 + RQ1 Phase 1~6 Step 4 완주
4/15 수	RQ1 Phase 7 (sf10 8M + sift 128d) 완주 + 자문 이메일 발송 준비
4/15~17	자문 이메일 발송 + 회신 수령
4/17~21	자문 결과 narrative 반영 + 중간보고서 v2
4/22 화	1차 팀 리뷰 라운드
4/24 목	2차 팀 리뷰 + 1차 리허설
4/26 토	2차 리허설
4/28 화	★ 중간발표 + 중간보고서 제출
4/28~5/4	W5: 최적화 + Layer sweep + wiki 검증
5/5~5/11	W6: 3 dataset × 3 mode × 6 sel 전면 ablation
5/12~5/18	W7: RQ3 KDE-pilot 구현
5/19~5/25	W8: 최종보고서 + 포스터 + 전시회 데모
5/27~5/29	최종발표 + 전시회 마감
6/5	전시회
6/11	★ 최종보고서 제출

8. 결론

본 중간보고서는 4 월 14 일 ~ 15 일의 RQ1 Motivation + RQ2 본선 (Phase 1~7) 의 정량 결과를 종합한다. 4 월 3 일 합의의 큰 골격 (Exqutor Adaptive Sampling 의 정확도 한계를 데이터로 드러내고 두 트랙으로 sanitize 한다) 은 그대로 유지된 채, RQ1 의 측정 정의가 8 지표 negative result + 5 design constraint finding 으로 정교화되었고, RQ2 의 본선이 Pivot A (BERNOULLI 한 줄 교체) + Pivot C (data-side KM20 stratified native 구현) 의 직교 병합 노선으로 재정의되었다. Phase 4 의 native 측정에서 selectivity 4 구간 모두 paired Wilcoxon $p < 0.001$ 로 Pivot A 의 효과가 확인되었으며, Phase 6 Step 4 의 native 측정에서 selectivity 3 구간이 ★ 우위 (최강 $s=0.500$ $p=4.01e-05$) 로 Pivot C 의 정상 selectivity 영역 효과가 확인되었다. Phase 7 의 외적 타당성 확장에서는 두 dataset 모두에서 100/100 query × $p < 1e-18$ 의 극단적 통계적 유의로 small selectivity 영역의 Pivot C 효과가 압도적임이 확인되었으며, Phase 7-1 의 ratio 2168× 는 본 연구 전체의 단일 최강 신호다.

본 두 sanitize 의 효과는 정상 selectivity 영역 (정량 +1.81%) 과 small selectivity 영역 (정성 409~2168 배) 양 쪽에서 보완적으로 확인되며, Pivot C 의 학술적 motivation — *data-side partition* 의 효과는 *sample 안 분포 균 등성에서 온다* — 을 직접 데이터로 입증한다. 본 중간보고서 시점의 한계는 단일 dataset family + 작은 query × seed 표본 + actual selectivity 의 의도와의 차이 + **vector.c** 우회 수정의 reviewer 관점 위험이며, 4 가지 모두 최종보고서 (6/11) 까지의 W5~W8 로드맵에서 해소된다. RQ3 (1D distance KDE + quantile 경계) 는 W7 에 진입하며, Pivot C 의 자연스러운 확장 경로 — 분포를 알 때 사용한 stratum 정의를 분포를 모를 때 query 시점의 1D 거리 분포로 대체 — 로 합류한다.

본 연구의 학술적 명제는 다음과 같이 좁고 정확하다.

본 연구는 Exqutor 가 자신의 multi-table only design intent 로 배제한 단일 테이블 vector range query 사각지대를 두 단계로 분석하고 개선한다. 첫째 단계는 finding 제시 (Hook trigger 사각지대 + plan replacement 부작용 + query feature 사전 식별 불가능성) 이며, 둘째 단계는 개입 측정 (**TABLESAMPLE SYSTEM** 의 block bias 를 BERNOULLI 한 줄 교체로 sanitize, naive uniform sampling 을 data-side k-means K=20 stratified 로 sanitize) 이다. 두 sanitize 의 정확도 이득은 정상 selectivity 영역과 small selectivity 영역 양쪽에서 직교 ablation 으로 분리 측정되며, 본 중간 보고서 시점에서 Phase 4 (4 구간 $p<0.001$) + Phase 6 Step 4 ($s=0.500$ $p=4.01e-05$) + Phase 7 (deep 8M 2168× / sift 128d 409×, $p<1e-18$) 의 양대 anchor 를 확보했다.

참고 문헌

- Park, S. et al. *Exqutor: Extended Query Optimizer for Vector-augmented Analytical Queries*. arXiv:2512.09695v2, 2024.
- Haas, P. J. and Stokes, L. *Estimating the number of classes in a finite population*. JASA 1998.
- Lipton, R. J., Naughton, J. F., and Schneider, D. A. *Practical selectivity estimation through adaptive sampling*. SIGMOD 1990.
- Sculley, D. *Web-scale k-means clustering*. WWW 2010.
- Horvitz, D. G. and Thompson, D. J. *A generalization of sampling without replacement from a finite universe*. JASA 1952.
- Indyk, P. and Motwani, R. *Approximate nearest neighbors: towards removing the curse of dimensionality*. STOC 1998.
- (RQ3 단계에서 추가) Latin Hypercube Sampling 관련: McKay, M. D., Beckman, R. J., and Conover, W. J. *JTechnometrics* 1979.

부록 — 참조 문서

- `plans/연구 설계안_20260403_162818.md` — v3 원안 (4/3 교수님 미팅 후)
- `plans/수정 연구 설계안_20260415_001500.md` — v4 수정본 (4/15)
- `experiments/results/rq1_motivation/summary.md` — Phase 1~6 측정 상세 (717 줄)
- `experiments/results/rq1_motivation/direction_pivot_rationale.md` — 4/14 pivot narrative (187 줄)
- `experiments/results/rq1_motivation/equivalence_check.md` — Stage 4.5 수학적 동치 검증
- `experiments/results/rq1_motivation/phase7*_paired_qerror.json` — Phase 7 paired 결과
- `experiments/figures/rq1_motivation/figure_{1..6}.png` — Stage 5b 시각화 6 종
- `submission/속도는벡터_자문이메일_20260415.md` — 멘토 자문 이메일
- `submission/속도는벡터_중간발표.md` — 중간발표 슬라이드 구조 md (12 + 1 장)