

Exqutor 벡터 카디널리티 추정의 단일 테이블 사각지대와 Skew-Aware Sampling

팀명: 속도는벡터

소속: 연세대학교 컴퓨터과학과 2026-1 캡스톤 디자인

팀원: 박세은(팀장), 강재현, 조현빈, 이동욱

지도 교수: (지도 교수 성함)

작성일: 2026-04-28

제출 종류: 중간 보고서 v2 (4/17 통합 결과 반영)

1. 연구 주제

벡터 데이터베이스는 `WHERE (v <-> q) < D` 꼴의 거리 기반 조건을 처리할 때 카디널리티를 정확히 추정해야 옵티마이저가 nested-loop 과 hash-join, 인덱스 사용 여부를 올바르게 선택할 수 있다. 그러나 pgvector, VBASE, DuckDB 는 각각 33.3%/50%/100% 의 고정 비율 추정에 의존하여 실제 selectivity 0.001~90% 범위에서 수십~수천 배 오차를 낸다. Exqutor (arXiv:2512.09695v2, 2024) 는 multi-table join 시나리오에서 이 문제를 Adaptive Sampling 과 ECQO 로 해소하였으나, 이미지 검색·추천·RAG retrieval 의 근간인 **단일 테이블 vector range query** 는 `vector.c` line 243 의 `if (table_count > 2)` 조건에 의해 hook 경로에서 배제되는 **명시되지 않은 사각지대**를 남긴다. 본 연구는 이 사각지대를 소스 검증으로 정량 드러내고, 두 단계 `sanitize — TABLESAMPLE SYSTEM → BERNOULLI` 한 줄 교체 (Pivot A) 와 data-side k-means K=20 기반 stratified sampling 의 native 구현 (+228 줄, Pivot C) — 를 직교 ablation matrix 로 분리 측정한다. DEEP 1M/8M 및 SIFT 1.5M 세 데이터셋의 5-seed 95% 신뢰구간 측정에서 Q-error median 이 **+1.6~4.4%** 개선되고, 좁은 selectivity ($s=0.010$) 에서 공간 인식 파티션이 무작위 파티션 대비 **19.6 %p** 의 격차를 만든다. 더욱이 개선폭은 클러스터 크기 분포의 변동계수 (CV) 로 예측 가능하여 — DEEP CV 0.234 vs SIFT CV 0.394 (68% 증가) 가 Q-error 개선폭의 2 배 격차로 단조 연결된다. 본 보고서는 RQ1 Motivation + RQ2 본선 (Phase 1~7 + 4/16~4/17 5-seed 보강) 의 결과를 정리하고, RQ3 Distribution-Agnostic 확장을 Recovery Rate 프레임워크로 설계한 뒤 최종보고서 (6/11) 단계의 7-way 비교 실험 계획을 제시한다.

본 v2 는 4 월 15 일자 초안 이후 확보된 세 가지 보강을 반영한다. 첫째, 5-seed 반복 측정과 95% 신뢰구간 산출로 Phase 6 Step 4 의 단일 seed 수치가 확률적 우연이 아님을 확인하였다. 둘째, D_{target} 을 각 데이터셋별로 재계산하여 SIFT 1.5M 과 DEEP 8M 에서의 외적 타당성을 정상 selectivity 영역에서 재확인하였다. 셋째, KM20 개선편을 Level 1 (비례 배분) 과 Level 2 (공간 인식) 로 분해하여 쏠림 기여를 정량화하고, 클러스터 분포의 HHI/CV 지표로 데이터셋 간 쏠림 격차가 KM20 효과 격차의 직접 원인임을 인과적으로 규명하였다.

2. 연구의 필요성

2.1 벡터 카디널리티 추정 문제

벡터 데이터베이스에서 주어진 query 벡터와 유사도가 임계값 이상인 행의 개수를 추정하는 문제는 옵티마이저의 실행 계획 선택에 직접 영향을 미치는 핵심 작업이다. pgvector 는 벡터 조건의 선택도를 33.3% 로 고정 추정하고, VBASE 는 50%, DuckDB 는 100% 로 추정한다. 그러나 실제 선택도는 query 에 따라 0.001% 부터 90% 까지 매우 넓은 범위를 가지며, 고정 비율 추정으로는 옵티마이저가 nested loop join 과 hash join 사이, 또는 vector index 사용 여부 사이에서 잘못된 선택을 내리는 사례가 빈번하다. Exqutor 는 이 문제에 두 가지 해법을 제시했다. **ECQO** 는 HNSW 인덱스가 있을 때 range query 를 직접 실행해 1~2 ms 안에 정확한 카디널리티를 획득하는 방식이며, **Adaptive Sampling** 은 인덱스가 없을 때 모넨텀 기반 동적 샘플링으로 카디널리티를 근사한다. 두 방법으로 Exqutor 는 pgvector 에서 최대 1000 배, VBASE 에서 10000 배, DuckDB 에서 1.5~37 배 성능 향상을 보고했다.

2.2 Exqutor Adaptive Sampling 의 잠재적 약점

본 팀의 출발 가설은 4 월 3 일 교수님 미팅에서 합의된 명제로 정리된다. *Exqutor 의 Adaptive Sampling 은 무작위 샘플이 전체 데이터의 거리 분포를 대표한다는 암묵적 가정 위에 동작하며, 거리 분포가 한쪽으로 치우친 (skewed) 환경에서는 무작위 샘플이 밀도가 높은 영역에 편중되어 카디널리티 추정 정확도가 떨어진다.* 본 가설을 데이터로 확인하고, distribution-aware sampling (분포를 알 때) 과 distribution-agnostic sampling (분포를 모를 때) 두 노선에서 정확도 개선을 정량 측정하는 것이 본 연구의 큰 골격이었다.

본 가설을 4 월 14 일에 직접 검증하는 과정에서 본 팀은 두 가지 발견에 도달했다. 첫째, 4 월 3 일 합의의 핵심 명제 — *글로벌 skewness 지표 (Fisher γ 등) 가 클수록 Q-error 도 크다* — 는 96 차원 DEEP 벡터의 1M subset 100 query $\times$ 6 selectivity $\times$ 5 seed $\times$ 2 mode = 6000 측정에서 강하게 기각되었다. 둘째, 같은 데이터에서 Exqutor 가 사용하는 `TABLESAMPLE SYSTEM` 의 block sampling bias 와 `vector.c` 의 hook trigger 조건 (`table_count > 2`) 이 만드는 단일 테이블 vector range query 사각지대 등 다섯 가지 design constraint (본문 4 + 부록 1) 를 발견했다. 본 두 발견은 4 월 3 일 합의의 큰 골격을 유지한 채, 측정 정의와 본선 시나리오를 정교화한 결과 (이하 v4 수정 설계안) 로 이어졌다. 본 보고서의 §4 는 이 정교화의 모든 단계를 정량 결과와 함께 정리한다.

3. 연구 질문

본 연구는 4 월 3 일 합의의 RQ1/RQ2/RQ3 세 단계 구조를 그대로 유지하며, 각 RQ 의 측정 정의를 4 월 14 일~17 일의 정량 결과 위에서 정교화한다.

RQ1 — Motivation 검증 (단일 테이블 사각지대 + 구조적 finding). Exqutor 의 Adaptive Sampling 은 단일 테이블 vector range query 시나리오에서 어떤 구조적 한계를 가지며, 그 한계는 어디에서 측정 가능한가? 본 RQ 는 (i) Hook trigger 사각지대, (ii) plan replacement 부작용, (iii) [TABLESAMPLE SYSTEM](#) block bias, (iv) query feature 사전 식별 불가능성의 네 finding 을 직접 소스 검증과 EXPLAIN ANALYZE 로 정량 드러낸다.

RQ2 — Distribution-Aware (Pivot A + Pivot C 병합). 분포를 알 때 (또는 데이터 자체의 partition 을 사전 학습할 수 있을 때), 두 단계 sanitize — [vector.c](#) L889 한 줄 교체로 block sampling bias 제거 (Pivot A) + data-side k-means K=20 기반 stratified sampling 의 native 구현 (Pivot C) — 가 카디널리티 추정 정확도를 얼마나 개선하는가? 본 RQ 는 BERN/STRAT × dataset × selectivity 의 직교 ablation matrix 로 두 sanitize 의 효과를 분리 측정하며, 개선분을 Level 1 (비례 배분) 과 Level 2 (공간 인식) 로 분해하여 설명 기여를 수리적으로 분리한다.

RQ3 — Distribution-Agnostic (Recovery Rate 프레임워크 7-way 비교 — 본 보고서 시점에는 설계만 확정). 분포를 모르는 상황에서, 사전 학습 없이 KM20 의 공간 인식 효과를 얼마나 회수할 수 있는가? 본 RQ 는 세 가지 패러다임 (Offline Partition / Online Query-Adaptive / Weight-based) 에 속하는 7 가지 방법을 Recovery Rate = (방법X - RANDOM20) / (KM20 - RANDOM20) 프레임워크로 비교한다. **본 중간 보고서 시점 (4/28)에서는 7-way 설계안만 확정된 상태이며, 실험은 최종보고서 (6/11) 국면 W5~W7 (4/28~5/18) 에서 수행한다.** 설계안에 명시된 "기대 Recovery Rate" 범위 (예: C 10~40%, F 75~95%) 는 검증된 결과가 아닌 사전 예측이며, 분모 (KM20 - RANDOM20) 가 $|\pm 1\%|$ 이하인 경계 셀 (예: DEEP 1M s=50% 의 -0.56%p) 에서는 Recovery Rate 대신 절대 Q-error 개선폭으로 보고하여 metric non-identifiability 를 회피한다. 상세 설계·탈락 후보·맹점 점검은 §6 과 [plans/RQ3설계안_20260416_213500.md](#) 에 정리되어 있다.

4. 연구 내용 — 4월 14일 ~ 17일의 측정 결과

4.1 출발점 — 4월 3일 교수님 합의

4 월 3 일 미팅에서 본 팀은 Exqutor 의 Adaptive Sampling 정확도 개선을 본선 주제로 확정하고, 두 트랙 — 분포 인지 / 분포 무인지 — 의 3 단계 실험 구조 (베이스라인 → 트랙 A → 트랙 B) 를 합의했다. 본선 시나리오는 **multi-table join with vector range filter** 로 가정되었고, 첫 단계의 판단 기준은 *Fisher* 의 skewness γ 큰 그룹의 Q-error 가 작은 그룹 대비 2 배 이상 이었다. 본 합의의 자세한 narrative 는 [plans/archive/연구설계안_20260403_162818.md](#) (v3) 에 정리되어 있으며, 본 보고서의 모든 정교화는 v3 의 큰 골격을 유지한 채 측정 정의 만 4/14~17 데이터 위에서 단단하게 만든 결과다. v4 수정 설계안 ([plans/연구재설계안_20260415_131400.md](#)) 이 두 버전의 차이를 표로 정리한다.

4.2 RQ1 1차 실험 — 가설 H1 기각과 Phase 5 8지표 전수 검증

본 팀은 4 월 14 일 오전에 연세대학교 BDAI Lab 서버 (`capstone2026@165.132.140.240`) 에 vanilla PG 16.9 + pgvector 0.7.1 환경을 구축하고, `partsupp_deep_10` (TPC-H sf10 + 96 차원 DEEP 벡터, 8M 행) 의 1M 결정론적 서브셋 위에서 RQ1 1차 실험을 5 단계 (Stage 1~5) 로 수행했다. 100 query 를 무작위 추출하고, 각 query 에 대해 6 개 선택도 구간 (0.001 / 0.010 / 0.050 / 0.100 / 0.300 / 0.500) 의 D_{target} 을 사전 계산한 뒤, Adaptive Sampling 을 Python 으로 재구현해 5 seed $\times$ 2 mode (`bernoulli` , `block_system`) $\times$ 100 query $\times$ 6 selectivity = 6000 측정의 q-error 를 산출했다. 본 실험의 자세한 절차와 산출물은 [experiments/results/rq1_motivation/summary.md §I~II](#) 에 정리되어 있다.

검증 결과는 가설 H1 을 강하게 기각했다. 4 가지 글로벌 skew 지표 (Fisher γ , log-Fisher γ , tail ratio P99/P50, Bowley skew) 와 query 별 median Q-error 의 Spearman 상관은 모든 24 개 조합 (4 지표 $\times$ 6 선택도) 에서 절대값이 0.2 미만이었으며, `!v! > 1` 그룹과 `!v! < 0.5` 그룹의 median Q-error 비율도 12 개 조합 모두에서 1.00 근처였다. 100 query 가 모두 Fisher $\gamma < 0$ (left-skewed) 이며 tail ratio P99/P50 도 1.07~1.17 의 좁은 범위에 모여 있어, 96 차원 벡터의 *고차원 거리 집중 (distance concentration)* 현상이 글로벌 skewness 지표의 변별력을 평탄화시켰다는 것이 1 차 진단이었다.

본 진단을 보강하기 위해 4 월 14 일 저녁 (Phase 5) 에 **로컬 4 지표** — k-NN distance entropy, k-NN PCA EVR1, KDE modality count, NN clustering coefficient — 를 numpy + scipy 만으로 직접 구현해 같은 100 query 에 적용했다. 결과는 24 개 조합 (4 지표 $\times$ 6 선택도) 모두에서 $|\text{Spearman } \rho| < 0.2$ 였다. 글로벌 4 + 로컬 4 = **8 지표 전수 검증 후 query-conditional layer 정의가 사전 식별 불가능** 함이 확정되었다. 이는 본 연구의 중요한 negative result 이며, RQ1 motivation 의 한 축으로 직접 편입되어 *query feature 가 아닌 data-side 에서 layer 를 가져와야 한다* 는 Pivot C 의 정당화로 사용되었다.

4.3 Exqutor Design Constraint 발견 — 새 motivation 첫 줄

H1 기각의 정량 결과 위에서 본 팀은 Python 재구현이 Exqutor 네이티브와 정확히 일치하는지 확인하기 위한 옵션 A (Phase 3 native bitwise 검증) 를 같은 날 오후에 시도했다. 그 시도는 두 가지 강력한 finding 으로 이어졌으며, 본 두 finding 은 본 연구 motivation 의 새 첫 줄로 격상되었다.

첫째 — Hook trigger 사각지대. Exqutor 의 `pgvector_set_baserel_rows_estimate_hook` 은 `vector.c` line 243 의 `if (table_count > 2)` 조건을 통과해야만 활성화된다. 본 팀의 검증 query 인 `SELECT count(*) FROM partsupp_deep_10_subset_1m WHERE (ps_embedding <-> q) < D` 는 단일 테이블이므로 `table_count = 1` 이고, 따라서 hook 이 우회되어 PostgreSQL default selectivity 1/3 으로 fall-through 된다. 즉 단일 테이블 vector range query 는 Exqutor 의 Adaptive Sampling 함수 자체에 도달하지 못하는 사각지대다. 이는 Exqutor 원논문 본문에 명시되지 않은 design constraint 이며, 본 팀의 직접 소스 검증으로 처음 정량 확인되었다. 이미지 검색, 추천 시스템, RAG 의 retrieval 단계가 모두 단일 테이블 vector range query 의 전형이라는 실무적 관찰은 본 사각지대를 본 연구가 채울 수 있는 학술적 빈자리로 격상시킨다.

둘째 — Plan replacement 부작용. 위 hook 을 `if (table_count >= 1)` 로 한 줄 우회하면, outer query 의 base relation 노드 자체가 PostgreSQL 의 `Sample Scan` 으로 plan-tree 가 교체된다 (`Sampling Method: system, Sampling Parameters: ['0.0385':real]`). 단일 테이블 시나리오에서는 outer query 결과 자체가 sample 안 부분 카운트로 격하되어 (예: true=100,000 query 에서 `SELECT count(*)` 가 32 반환), outer query 의 정확성이 깨진다. multi-table join 에서는 base table sample scan 으로의 교체가 join 결과의 부분 영향만 주지만, 단일 테이블에서는 outer query 의 의미를 잃게 만드는 design constraint 다.

본 두 finding 외에도 옵션 A 시도 중 (iii) q-error inf 발산, (iv) sample_size NaN 발산, (v) Adaptive update path SIGSEGV 의 세 가지 추가 design constraint 가 발견되었다. 본 세 finding 은 Adaptive Sampling 의 update path 가 multi-table only design intent 를 가정하고 만들어진 결과이며, 본 연구의 측정 단계에서는 `vector.update_sample_size = off` GUC 로 update 경로를 차단하고 sampling method 자체의 효과만 분리 측정하는 방식으로 회피했다. 자세한 narrative 는 `experiments/results/rq1_motivation/direction_pivot_rationale.md` 에 187 줄로 정리되어 있다.

4.4 Pivot A + Pivot C 병합 노선 확정 (4월 14일 17:35 KST)

위 finding 들을 근거로 본 팀은 4 월 14 일 17:35 KST 에 **Pivot A + Pivot C 병합 노선** 을 확정했다. 4 월 3 일 합의의 큰 골격은 그대로 유지되며, 다음 두 차원에서 정교화가 일어났다.

시나리오 좁힘. 본선 시나리오를 multi-table join with vector range filter 에서 단일 테이블 vector range query 사각지대로 좁힌다. 좁힘의 비용은 multi-table 벤치마크와의 직접 비교 불가능이며, 대응은 (i) 본 연구 motivation 자체가 사각지대를 드러내는 것이므로 multi-table 비교가 필요 없고, (ii) 단일 테이블 시나리오의 실무적 중요성이 본 연구의 외적 타당성을 강화한다는 것이다.

측정 도구의 교체. Layer 정의를 query-side feature 에서 data-side partition 으로 이전한다. Phase 5 의 8 지표 negative result 가 query-side feature 의 사전 식별 불가능성을 보였으므로, 본 팀은 데이터 자체에 대한 numpy mini-batch k-means K=20 (seed=42) 학습으로 stratum 을 정의하고 각 행에 `stratum_id smallint` 컬럼을 사전 부여해 query 시점의 overhead 를 0 으로 만든다.

본 두 정교화 위에서 두 sanitize 가 정의된다. **Pivot A** 는 `vector.c` L889 의 `TABLESAMPLE SYSTEM(%f)` 을 `TABLESAMPLE BERNOULLI(%f)` 로 한 줄 교체하는 단순 변경이며, Exqutor 가 사용하는 block sampling 의 row-correlation bias 를 제거하는 *fair baseline* 도구다. **Pivot C** 는 `vector.c` 에 +228 줄의 stratified sampling 분기를 추가하여 GUC `vector.sampling_method = 'stratified'` 활성화 시 per-stratum `ORDER BY random() LIMIT sample_size/K` 형태의 SPI SQL 로 층별 균등 sample 을 추출하고 Horvitz-Thompson 가중 카디널리티 추정식 $est = \sum (n_i \times cnt_i / s_i)$ 을 native 에서 계산하는 본 연구의 핵심 본선 구현이다. 두 Pivot 은 직교적이므로 SYSTEM/BERNOULLI/STRATIFIED × dataset × selectivity 의 ablation matrix 로 각 개선의 기여를 분리 측정할 수 있다.

4.5 Phase 4 — Pivot A Native 검증 (4월 14일 19:30~19:40 KST)

`vector.c` L889 한 줄을 `sed` 로 교체하고 (BERNOULLI), `make USE_PGXS=1 install` 로 새 `vector.so` 를 빌드한 뒤 Exqutor PG 55436 을 fast restart 했다. 100 query × 6 selectivity × 1 seed × 2 mode = 1200 query 를 native 경로에서 EXPLAIN (ANALYZE, FORMAT JSON) 으로 측정했고, 각 query 의 plan tree 첫 Scan 노드의 Plan Rows + Sampling Method 를 추출해 q-error 를 계산했다. 결과는 다음과 같다.

selectivity	SYS median	BERN median	diff% (SYS-BERN)	paired Wilcoxon p (alt: SYS > BERN)	win (SYS<BERN)
0.001	2.5970	2.5970	+0.0%	0.596	6/8
0.010	1.5584	1.2987	+20.0%	0.240	45/40
0.050	1.2031	1.1948	+0.7%	0.0009 ★★	58/37
0.100	1.2120	1.1323	+7.0%	< 0.001 ★★★	66/31
0.300	1.2095	1.0794	+12.0%	< 0.001 ★★★	76/24
0.500	1.1527	1.0519	+9.6%	< 0.001 ★★★	78/22

selectivity 0.05 이상 4 구간에서 모두 paired Wilcoxon $p < 0.001$ ($s=0.05$ 만 0.0009) 로 SYSTEM 의 q-error 가 BERNOULLI 보다 통계적으로 유의하게 크다. 가장 큰 효과는 $s=0.500$ 에서 78/100 query 가 SYSTEM 쪽 불리, median 기준 9.6%p 개선. `src/vector.c` 한 줄 `sed` 교체로 Exqutor 의 카디널리티 추정 정확도가 측정 가능한 수준으로 개선된다는 것이 native 로 직접 확인되었다. Phase 4 의 native 수치는 §4.2 의 Python counterfactual (+3.8~9.1%) 과 같은 order of magnitude 로 방향이 일치한다. 본 측정의 hook 활성화 전제와 페어 공정성: 본 실험은 `vector.c` line 243 의 단일 테이블 hook trigger 를 `table_count > 2` → `table_count >= 1` 로 수정해 hook 경로를 활성화한 상태에서 수행되었으며, 이 수정은 SYSTEM arm 과 BERNOULLI arm 양 쪽에 완전히 동일하게 적용되어 상쇄되므로 paired Wilcoxon 비교의 상대적 개선율 (SYS-BERN)/SYS 는 hook 수정 여부와 독립적이다. 원본 `vector.c` 와 수정본 `vector_patched.c` , 그리고 두 빌드의 `.so` 아티팩트를 모두 보존하여 제 3 자 검증 시 재현 가능하도록 하였다 (Exqutor design intent 로부터의 일탈에 대한 reviewer 관점 주의는 §5.2(d) 에 별도 명시). 자세한 산출물은 `experiments/results/rq1_motivation/phase4_*.parquet` + `phase4_compare.json` .

4.6 Phase 6 Step 4 — Pivot C KM20 Native 구현과 5-seed CI 확정 (4월 14일 22:00 / 4월 16일 보강)

Phase 6 Step 1~3 (Python counterfactual) 와 Step 3' (4 layer 비교: bernoulli / pca_decile / kmeans_k10 / kmeans_k20) 위에서 KM20 = best layer 가 확정되었으며, 본 Step 4 는 그 KM20 stratified 를 native 로 직접 구현한 단계다. 본 팀은 `vector.c` 에 +228 줄의 stratified 분기를 추가하고 (GUC 3 개 + stratum_sizes 캐시 + estimate 함수), `partsupp_deep_10_subset_1m` 에 `stratum_id smallint` 컬럼 + 인덱스를 부여한 후 (data-side ALTER TABLE 옵션 B), 100 query × 6 selectivity × 1 seed × 2 mode = 1200 query 를 native 경로에서 측정했다. q-error 는 EXPLAIN 의 plan_rows 와 서버 로그의 hook estimate 에서 양쪽으로 추출해 일치성을 검증했다.

1차 결과 — Phase 6 Step 4 초기 측정 (1 seed)

selectivity	BERN median	STRAT median	diff%	paired Wilcoxon p (alt: STRAT < BERN)	win
0.001	2.5806	2.5806	+0.00%	0.451	26/22
0.010	1.2917	1.3874	-7.41%	0.797	44/56
0.050	1.2109	1.1429	+5.62%	0.00678 ★★	64/36
0.100	1.1097	1.1083	+0.12%	0.0447 ★	61/39
0.300	1.0623	1.0523	+0.94%	0.102	52/48
0.500	1.0529	1.0339	+1.81%	4.01e-05 ★★★	66/34

s=0.500 에서 STRAT 가 BERN 대비 paired Wilcoxon **p = 4.01e-05** 로 통계적 유의. Bonferroni 보정 (전체 110 검정, $\alpha_{adj}=4.5e-04$) 적용 시 **s=0.500 만 생존**하며, 본 연구 RQ2 본선의 1 차 유효 anchor 가 확보되었다. 작은 selectivity 영역 (s=0.001) 에서는 두 모드가 동률 (median 2.5806) 이었는데, 이는 sample 385 안에서 매칭이 0~1 개로 떨어져 BERN 의 cnt-clamp `cnt=0 → 1` 와 STRAT 의 `cnt_total=0 → est_total=total/budget` fallback 이 같은 값 (993541/385 $\approx$ 2.581) 을 반환하는 구조적 동치성의 결과다.

2차 결과 — 5-seed 반복 측정과 95% 신뢰구간 (4월 16일 보강)

1 차 결과의 단일 seed 수치가 확률적 우연이 아님을 확인하기 위해 setseed 0.1~0.5 의 5 seed 로 반복 측정을 수행하고, 평균과 표준편차로부터 95% 신뢰구간 ($\text{mean} \pm t(4, 0.975) \times \text{std} / \sqrt{5}$, $t = 2.776$) 을 산출하였다. DEEP 1M 의 5 selectivity 구간 결과는 다음과 같다.

selectivity	5-seed 평균 개선	95% CI	유의한 seed
50% (넓은 범위)	+1.64%	[+1.11, +2.18]	5/5 (전부 유의)
30%	+2.62%	[+1.45, +3.80]	5/5 (전부 p<0.001)
10%	+4.19%	[+0.72, +7.66]	5/5 (전부 p<0.004)
5%	+1.85%	(단일)	3/5
1%	+8.93%	(단일)	4/5

50%, 30%, 10% 세 구간의 신뢰구간이 모두 0 을 포함하지 않으며 하한 역시 +1.11%, +1.45%, +0.72% 로 양수로 확정되었다. 이는 효과 크기가 noise 가 아닌 real effect 임을 통계적으로 확정하는 결과이며, 단일 seed 수치 +1.81% (s=0.500) 가 +1.64% 근처로 수렴되어 재현성이 확보되었다. 5% 와 1% 는 초기 Phase 6 단일 측정으로 신뢰구간이 없으나, §4.8 의 5-seed RANDOM20 대조와 §4.10 의 gradient 해석에서 일관성이 뒷받침된다. Phase 6 Step 4 의 결과는 Python counterfactual (Step 3') 와 6 selectivity 구간 중 4 구간에서 정성적으로 일치하며, 유의 구간 수 (3 개) 와 효과 크기의 order of magnitude 가 보존되어 Python 재구현의 native 재현 가능성이 확정되었다. **5-seed 설계의 한계와 W6 확장 계획.** 본 5-seed 반복은 단일 seed 수치가 우연이 아님을 확인하는 **seed-to-seed 변동성 검출** 목적이며, 출판 급 검정력 확보를 위해 최종보고서의 main result table 은 W6 (5/5~5/11) 에 3 dataset × 6 selectivity × 3 mode × **10 seed × 500 query** 로 확대 측정한다. 본 중간보고서 시점에서 표준화 효과 크기 Cohen's d = 평균개선률 / 표준편차 기준으로 DEEP 1M s=0.500 의 d ≈ 3.3, DEEP 8M s=0.500 의 d ≈ 1.98, SIFT 1.5M s=0.500 의 d ≈ 15 는 n=5 / α=0.05 two-sided 에서 검정력 ≥ 80% 를 확보한 반면, s=0.010 Anomaly 구간은 d < 1 로 under-powered 이므로 "no effect" 판정이 아닌 "효과 식별 불가" 로 해석하고 W6 의 10-seed 재측정으로 해소한다. 보고된 95% CI 는 sample std (ddof=1) 와 t(4, 0.975) = 2.776 을 사용한 t-CI 이며, 일부 중간 JSON ([phase6_multiseed_summary.json](#)) 에 병기된 bootstrap 95% CI 는 참고용 보조 지표로 최종 권위 있는 값은 본 보고서 표에 기재한 t-CI 이다.

4.7 Phase 7 — 외적 타당성 확장 시도와 측정 artifact (4월 15일 08:31 KST)

Phase 6 Step 4 직후의 결과는 *1M subset × 96d DEEP 단일 dataset × 100 query × 1 seed* 라는 좁은 조건에 한정되어 있어 외적 타당성이 부족했다. 본 팀은 4 월 15 일 오전에 두 가지 외적 타당성 확장을 시도했다. **Phase 7-1 sf10 8M 재현** ([partsupp_deep_10_phase7_8m_subset](#)) 에서는 원본 [partsupp_deep_10](#) 8M 행을 별도 테이블로 COPY 후 (보존) numpy mini-batch k-means K=20 (seed=42) 으로 8M 전체에 stratum_id 를 학습·UPDATE 하고 인덱스 + VACUUM ANALYZE 를 적용했다. setup 17 분 + measurement 23 분, 100 query × s=0.500 D_target × 2 mode = 200 query 측정. **Phase 7-2 sift 128d 확장** ([customer_sift_10_phase7_noidx_subset](#)) 에서는 vanilla PG 55435 의 [customer_sift_10](#) (1.5M, 128d, HNSW 있음) 에서 c_custkey + c_embedding 만 Exquor PG 55436 으로 minimal transfer 한 후 (838 MB, 2 분 33 초), HNSW 없이 별도 테이블에 KM20 stratum_id 를 부여했다. setup 3 분 + measurement 7 분, 100 query × s=0.500 D_target × 2 mode = 200 query 측정.

본 두 실험에서 의도한 selectivity 0.500 은 1M subset 에서 derive 된 D_{target} 을 8M / 128d 에 그대로 적용했기 때문에 actual selectivity 가 약 0.0001 영역으로 이동했다 (1M 과 8M, 96d 와 128d 의 거리 분포 차이). 이 극극소 selectivity 영역에서 BERN 의 `cnt=0 → 1` clamp fallback 과 STRAT 의 stratum 균등 추출이 모두 fallback 경로로 진입한다.

초기 분석의 오류와 artifact 발견 — 타임라인. 4 월 15 일 08:31 KST 초기 내부 보고에서는 plan_rows 기반 q-error 로 2168× / 409× 의 개선율이 잠정 집계되었다 (이 수치는 어떤 외부 공식 문서에도 채택된 적 없으며, 본 팀의 내부 메모에만 남아 있었다). 같은 날 오전 3 측 심층 디리뷰에서 plan_rows 분포의 이상 — STRAT 100/100 쿼리 모두에서 `plan_rows = 20` (min = max = 20, std = 0) — 이 지적되었고, 즉시 parquet 원본과 서버 로그를 대조하여 artifact 의 실체를 확정하였다. 4 월 15 일 중 hook_est 기반 재분석이 완료되었고 (결과: 8M STRAT -26.5%, sift STRAT -325%), 이로써 Phase 6 Step 4 에서 이미 확립되었던 측정 원칙 — "`hook_est` 를 authoritative metric 으로 사용하며, plan_rows 는 첫 Subquery Scan 의 LIMIT 상수를 반환할 수 있으므로 q-error 계산에 사용하지 않는다" — 가 재확인되었다. 본 artifact 는 공개 보고서 단계에 도달하기 전에 팀 내부 검증으로 포착되어 철회된 전형적 preprocessing 오류이며, 이후의 §4.8 재측정에서 D_{target} 을 각 데이터셋별로 재계산하여 정상 selectivity 영역에서의 외적 타당성을 회복하였다. 본 팀은 최초로 EXPLAIN ANALYZE plan tree 의 `plan_rows` 값을 q-error 산출에 사용했으며, 이로부터 BERN median q-error 20810 vs STRAT 9.60 (8M, ratio 2168×) 및 BERN 3875 vs STRAT 9.48 (sift, ratio 409×) 이라는 극단적 개선율을 산출했다. 그러나 심층 검증 결과, STRAT 측의 `plan_rows` 가 100/100 row 에서 정확히 20 (min=max=20, std=0) 으로 고정되어 있음이 확인되었다. 이 값은 stratified estimator 의 추정 출력력이 아니라 plan tree `Aggregate → Append → [Subquery Scan × 20]` 구조에서 `find_scan_node` 가 반환한 stratum LIMIT 상수였다. q-error 9.60 은 true_card 193 / plan_rows 20 = 9.65 의 산술적 결과일 뿐이다. Phase 6 Step 4 에서 확립한 측정 원칙 — `find_scan_node` 가 첫 Subquery Scan 의 plan_rows 를 반환하면 garbage 이므로 hook 이 `eelog` 로 서버 로그에 기록한 `hook_est` 를 authoritative metric 으로 사용한다 — 에 따라 `hook_est` 기반으로 재분석한 결과는 완전히 반전되었다 (8M: STRAT -26.5%, sift: STRAT -325%). 두 데이터셋의 plan_rows 기반 paired Wilcoxon p 가 정확히 `1.948279922547955e-18` 로 identical 한 것도 scipy `wilcoxon` 의 `w_stat=0` saturation floor 에 의한 artifact 임이 확인되었다.

Phase 7 의 reframing — boundary condition 과 후속 해소. 본 결과는 Phase 4 의 $s=0.001$ tie 패턴 (sample 안 매칭 0~1 개로 두 모드 동치) 및 Phase 6 Step 4 의 $s=0.001$ 동률 (median 2.5806) 과 일관된다. 극극소 selectivity 영역 (actual ≈ 0.0001) 에서는 어떤 stratification 전략도 cnt-clamp fallback 을 벗어나지 못하며, KM20 의 stratum 균등 추출이 오히려 BERN 대비 불리한 분배를 만든다. 이는 Pivot C 의 효과가 정상 selectivity 영역에 한정된다는 경계 조건을 정량적으로 확인한 결과이다. 본 팀은 이후 D_{target} 을 각 데이터셋별로 재계산하여 actual selectivity ≈ 0.5 로 재진입한 뒤 SIFT 1.5M 과 DEEP 8M 에서 Pivot C 효과를 재측정하였으며, 그 결과는 §4.8 에 상세 서술된다. Phase 7 의 외적 타당성 결손이 해소되는 동시에, 층화 샘플링의 효과가 안정적으로 발현되는 selectivity 하한 ($s \geq 0.050$) 이 정량적으로 확정되었다. 상세한 검증 과정과 증거는 [experiments/results/rq1_motivation/phase7_artifact_verification_20260415.md](#) 에 공식 기록되어 있다.

4.8 외적 타당성 재확인 — SIFT 1.5M 과 DEEP 8M 의 정상 selectivity 재측정 (4월 16일)

Phase 7 의 D_target 부적합을 해소하기 위해, 본 팀은 SIFT 1.5M 과 DEEP 8M 각각의 거리 분포 quantile 0.5 로 D_target 을 재계산하고 setseed 0.1~0.5 의 5 seed 로 반복 측정을 수행하였다. DEEP 1M 에서 확립한 측정 파이프라인 (multiseed_paired, hook_est 기반 q-error, paired Wilcoxon) 을 그대로 재사용하였으며, 두 데이터셋 모두에서 s=0.500 외에 s=0.050 과 s=0.010 을 추가 측정하여 gradient 의 외적 재현성도 확인하였다.

SIFT 1.5M (128d) 결과

selectivity	KM20 5-seed 평균	95% CI	유의한 seed
50%	+3.07%	[+2.66, +3.48]	5/5 (전부 p<1e-8)
5%	+4.39%	[+2.63, +6.15]	5/5 (전부 유의)
1%	-0.53%	[-3.18, +2.11]	1/5

SIFT 1.5M 에서 KM20 의 개선 효과는 DEEP 1M (+1.64%) 대비 s=0.500 에서 약 2 배 (+3.07%) 로 관찰되었으며, 95% 신뢰구간 [+2.66, +3.48] 은 DEEP 1M 의 [+1.11, +2.18] 과 겹치지 않아 통계적으로 구별된다. s=0.050 에서도 +4.39% [+2.63, +6.15] 로 DEEP 1M 의 +1.85% 대비 2 배를 상회하는 효과가 확인되었다. s=0.010 은 1 M 에서 본 동물 패턴 및 hook_est 양자화 (5 seed 모두 BERN median 1.4435 로 동일) 로 인해 실질적 차이가 관찰되지 않았으며, 이는 §4.10 에서 층화 샘플링의 안정 하한 논의로 연결된다.

DEEP 8M (96d) 결과

selectivity	KM20 5-seed 평균	95% CI	유의한 seed
50%	+1.76%	[+0.65, +2.86]	4/5
5%	+0.55%	[-3.11, +4.21]	0/5
1%	-0.71%	[-21.13, +19.70]	0/5 (노이즈 지배)

DEEP 8M 에서는 s=0.500 에서 +1.76% [+0.65, +2.86] 로 1 M 의 +1.64% [+1.11, +2.18] 과 신뢰구간이 겹쳐 CONSISTENT 판정되었다. 규모를 8 배 늘려도 동일 차원의 DEEP 데이터셋에서 KM20 효과가 보존된다는 외적 재현 증거이다. s=0.050 과 s=0.010 에서는 CI 가 0 을 포함하여 효과가 식별되지 않는데, 이는 sample_size=385 가 8M 의 최소 매칭 (s=0.010 에서 true_card ≈ 8 만) 을 추정하기에 절대적으로 부족하다는 구조적 한계의 결과이며 (Anomaly 2, §4.10), KM20 의 속성이 아니라 Exqutor Adaptive Sampling 의 기본 sample_size 설정과 관련된다.


KM20 vs RANDOM20 대조 — 공간 인식의 인과 기여 증명

개선의 원인이 "20 개로 나누는 것 자체" 가 아니라 "공간 구조를 아는 파티션" 임을 증명하기 위해, 본 팀은 RANDOM20 (벡터를 완전 무작위로 20 개 그룹에 배정) 파티션으로도 같은 실험을 수행하였다. DEEP 1M selectivity 전 5 구간의 결과는 다음과 같다.

selectivity	KM20 (CI)	RANDOM20 (CI)	격차
50%	+1.64% [+1.11, +2.18]	+2.20%	~0 (차이 없음)
30%	+2.62% [+1.45, +3.80]	+0.26% [-0.52, +1.05]	2.4%p
10%	+4.19% [+0.72, +7.66]	+1.74% [+0.50, +2.99]	2.5%p
5%	+1.85%	+0.79%	+1.1%p
1%	+8.93%	-10.67%	19.6%p


쿼리 범위가 좁아질수록 KM20 과 RANDOM20 의 격차가 지수적으로 벌어지며, $s=0.010$ 에서는 RANDOM20 이 -10.67% 로 악화되는 동안 KM20 은 $+8.93\%$ 로 개선된다. 10% 와 30% 구간에서도 KM20 과 RANDOM20 의 신뢰구간이 분리되어 격차가 통계적으로 유의하다. 즉 Pivot C 의 개선은 "20 등분" 이라는 분할 행위 자체가 아니라 "공간 구조를 반영한 분할" 에서 발생함이 정량적으로 증명되었다. SIFT 1.5M 의 대조도 동일 방향이며 격차의 크기가 더 크다 ($s=0.500$ KM20 $+3.07\%$ vs RANDOM20 $+1.01\%$, $s=0.050$ 격차 $+4.4\%p$, $s=0.010$ 격차 $+11.6\%p$).

Figure 7 · DEEP 1M Selectivity Gradient — KM20 vs RANDOM20 (95% CI)



주: KM20은 모든 selectivity에서 양의 개선. RANDOM20은 s=0.01에서 -10.67%로 악화.
 격차가 클수록 공간 인식의 가치가 큼 (좁은 범위일수록 KM20 우위 확대).
 s=0.05, s=0.01은 단일 측정(Phase 6)이라 CI 없음 — 보충 5-seed 재측정은 최종보고서 예정.

Figure 8 · 외적 타당성 — 3 데이터셋에서 KM20 $s=0.500$ 효과 (95% CI)



주: DEEP 1M/8M의 CI는 겹침(외적 재현 CONSISTENT). SIFT의 CI는 DEEP과 겹치지 않아 통계적으로 구별. 쓸림도(CV)가 큰 데이터일수록 공간 인식 샘플링의 이점이 더 크게 발현됨.

본 절의 5-seed 결과와 CI 는 [experiments/results/rq2_aware/sift_1m_mid_summary.json](#) , [8m_km20_s0500_5seed.json](#) , 그리고 통합본 [experiments/results/RQ1_RQ2 실험 결과 정리.md](#) §실험 4~5 에 정리되어 있다.


4.9 클러스터 쓸림 정량화 — HHI 와 CV 지표로 본 데이터셋 간 격차

SIFT 의 KM20 효과가 DEEP 의 약 2 배에 달하는 이유를 인과적으로 설명하기 위해, 본 팀은 각 데이터셋의 K-means $K=20$ 클러스터 크기 분포를 HHI (Herfindahl-Hirschman Index) 와 CV (변동계수) 로 정량화하였다. HHI 는 각 클러스터가 차지하는 비율의 제곱합으로 균일할 때 $1/K = 0.05$ 이며 한 클러스터에 집중될수록 1.0 에 접근한다. CV 는 표준편차를 평균으로 나눈 값으로 균일할 때 0 이며 쓸림수록 증가한다.

지표	DEEP 1M (96d)	SIFT 1.5M (128d)	균일 기준
K	20	20	20
최소 클러스터 크기	26,343	33,330	50,000 / 75,000
최대 클러스터 크기	81,233	148,202	50,000 / 75,000
최대/최소 비율	3.08배	4.45배	1.00
HHI	0.05274	0.05776	0.05000
CV (변동계수)	0.234	0.394	0.000

SIFT 의 CV (0.394) 는 DEEP (0.234) 대비 **68% 높다**. 특히 SIFT 의 최대 클러스터는 기대값 (7.5 만) 의 약 2 배 인 14.8 만에 달하며, 상위 두 클러스터 (14.8 만 + 14.0 만) 가 전체의 약 19% 를 차지하여 균일 가정의 10% 대비 거의 2 배에 이른다. 이 쏠림의 정량 차이가 §4.8 에서 확인된 KM20 효과의 2 배 격차의 직접 원인이다. 즉 "데이터가 쏠려 있을수록 공간 인식 샘플링의 이점이 더 크다" 는 연구 가설이 HHI/CV 의 정량 지표와 Q-error 개선폭 의 정량 차이 사이에 일관된 단조 관계로 뒷받침된다.

Figure 10 · 데이터셋 클러스터 쏠림 — DEEP 1M vs SIFT 1.5M



본 정량화의 상세는 [experiments/results/rq2_aware/cluster_distribution.md](#) 에 정리되어 있다.


4.10 Two-Level Decomposition, Gradient 해석, Anomaly

§4.8 의 KM20 vs RANDOM20 대조는 "공간 인식" 의 기여를 식별할 수 있게 해준다. 본 팀은 개선분을 두 층으로 수리적으로 분해한다. **Level 1 (비례 배분)** 은 RANDOM20 의 개선분이며 파티션의 공간 품질과 무관하게 "나누는 것 자체" 가 제공하는 표본 크기 안정화 효과이다. **Level 2 (공간 인식)** 는 KM20 개선분에서 RANDOM20 개선분을 뺀 것이며, 공간 구조를 반영한 파티션만이 제공하는 추가 이점이다. 두 층의 합은 정의상 KM20 개선분과 같다.

selectivity	Level 1 (비례 배분)	Level 2 (공간 인식)	Total (KM20)
50%	+2.20%	-0.56%	+1.64%
30%	+0.26%	+2.36%	+2.62%
10%	+1.74%	+2.45%	+4.19%
5%	+0.79%	+1.06%	+1.85%
1%	-10.67%	+19.60%	+8.93%

DEEP 1M 의 분해 결과는 selectivity 가 줄수록 Level 2 의 기여가 급격히 증가한다는 것을 보여준다. $s=0.500$ 에서는 Level 1 이 지배적이고 Level 2 는 거의 0 이며, 쿼리 범위가 넓을 때는 파티션 품질과 무관하게 비례 배분의 안정화 효과만으로 충분함을 의미한다. 그러나 $s=0.010$ 에서는 Level 2 가 단독으로 +19.60%p 를 기여하며 전체 개선의 원동력이 된다. 이는 좁은 범위 쿼리에서 결과 행이 소수 클러스터에 집중되므로 해당 클러스터를 정확히 아는 파티션 (KM20) 만이 올바른 표본을 추출할 수 있기 때문이다. SIFT 1.5M 에서는 쓸림이 더 크므로 $s=0.500$ 부터 이미 Level 2 가 +2.06% 로 유의하며, $s=0.050$ 에서는 +4.44%p 로 DEEP 1M 대비 더 이른 selectivity 에서 Level 2 가 지배적이 된다.

Figure 9 · Two-Level Decomposition — KM20 개선을 비례 배분(L1)과 공간 인식(L2)으로 분해



주: Level 1은 RANDOM20의 개선분(파티션 품질 무관), Level 2는 KM20-RANDOM20 격차(공간 인식 기여). selectivity가 줄수록 Level 2의 기여가 급증하며, DEEP 1M s=0.01에서 Level 2 단독 +19.60%p. SIFT는 s=0.50부터 이미 Level 2(+2.06%)가 유의 — 솔림이 클수록 공간 인식의 영향이 넓은 구간이 발현.

Gradient 비단조성의 방법론적 배경

DEEP 1M의 KM20 gradient에서 $s=0.100$ (+4.19%) $\rightarrow s=0.050$ (+1.85%)의 비단조적 하락이 관찰된다. 이 비단조성의 일부는 D_{target} 계산 방식 차이에서 기인한다. $s=0.050$ 실험은 초기 Phase 6에서 SQL 기반 이진 탐색으로 D_{target} 을 산출하였으며, $s=0.100$ 과 $s=0.300$ 은 최종 실험 일괄 수행 (Phase 7)에서 numpy 기반 D_{target} 계산으로 전환된 후 측정되었다. 두 방식은 부동소수점 정밀도와 실제 selectivity 달성 정도에 미세한 차이를 유발할 수 있으며, 이것이 인접 구간의 부분적 불연속에 기여한 것으로 판단된다. 전체적 상승 추세 ($s=0.500 \rightarrow s=0.010$)는 이 방법론적 차이와 무관하게 견고하며, SIFT mid-selectivity 보충 실험이 완료되면 교차 검증될 예정이다.

Anomaly 3건의 구조적 해석

선택도 구간별 세부 결과에서 세 가지 일관된 anomaly가 관찰되는데, 이는 모두 같은 구조적 원인 — $\text{sample_size}=385$ 의 절대적 부족 —에서 기인한다.

- Anomaly 1 (DEEP 1M $s=0.500$ 에서 RANDOM20 > KM20):** 이 영역에서 BERNOLLI의 Q-error가 이미 1.04~1.07로 낮아 어떤 파티션이든 소폭 개선만 발생한다. KM20과 RANDOM20의 차이 0.56%p는 seed 간 분산 (~0.5~1% std) 안에 있어 비유의적이며, Level 1 효과만 작동하고 Level 2가 불필요함을 확인시킨다.
- Anomaly 2 (DEEP 8M $s=0.010$ 에서 KM20이 -0.71%):** 8M에서 $s=0.010$ 이면 true_card는 약 8만이지만 $\text{sample_size}=385$ 가 추출하는 표본은 전체의 0.005%에 불과하다. 이 극소 표본으로 8만 건을 추정하면 Q-error가 6~8배까지 치솟으며 95% CI가 [-21.13, +19.70]으로 0을 포함한다. 어떤 샘플링 방식이든 정확한 추정이 불가능한 영역이다.

- **Anomaly 3 (SIFT 1.5M $s=0.010$ 에서 KM20 이 -0.53%):** 5 seed 모두 BERNOULLI median Q-error 가 1.4435 로 동일하다. 이는 hook estimation 이 같은 값을 반환하는 양자화 현상이며, 방향 자체가 불안정하다. KM20 이 방어 역할은 하지만 (RANDOM20 의 -12.11% 악화를 방지), 적극적 개선은 표본 부족으로 불가능하다.

세 anomaly 를 종합하면 **충화 샘플링의 효과가 안정적으로 발현되는 selectivity 하한은 $s \geq 0.050$** 이라는 실험적 경계 조건이 확정된다. 이 범위에서 KM20 은 DEEP 1M/8M 에서 $+1.6\sim 1.9\%$, SIFT 1.5M 에서 $+3.1\sim 4.4\%$ 의 일관된 개선을 보이며, Phase 7 에서 관찰된 극극소 selectivity 의 negative finding 과 상호 보완된다. 세부 분석은 [experiments/results/rq2_aware/anomaly_analysis.md](#) 와 통합본 §Anomaly 설명 절에 정리되어 있다.

5. 종합 — 보고서 시점의 RQ 진행률과 한계

5.1 RQ 진행률

RQ	정의	진행률	핵심 결과
RQ1	5 design constraint finding (본문 4 + 부록 1) + query feature 사전 식별 불가능성	~95%	8 지표 negative + 5 design constraint 모두 정량 확인. 시각화 6 figure 완성.
RQ2	Pivot A + Pivot C 직교 ablation + 5-seed CI + Two-Level 분해	~80%	Phase 4 4 구간 $p < 0.001$. Phase 6 Step 4 $s=0.500 + 1.64\%$ [$+1.11, +2.18$] 5-seed 확정. 3 데이터셋 외적 재현 (DEEP 1M/8M CONSISTENT, SIFT 2배 격차). Level 1/2 분해로 공간 인식 기여 정량. W5~W6 에서 wiki 768d 검증 + 500×10 ablation + Cohen's d · BH-FDR 보정 + TOST 등가성 검정 진행.
RQ3	Recovery Rate 프레임 워크 7-way 비교 (3 패러다임)	설계 100% · 실험 0%	7 방법 $\times$ 3 패러다임 설계안 확정 (plans/RQ3설계안_20260416_213500.md , 17 탈락 후보 상세 기록). 본 보고서에는 실험 결과 없음. W5~W7 (4/28~5/18) 구현·측정 예정. 설계안의 "기대 Recovery" 열은 사전 예측이며 검증된 결과가 아님. 분모 (KM20 – RANDOM20) 가

5.2 본 시점의 한계 (honest report)

본 중간 보고서 시점의 RQ1/RQ2 결과는 다음 네 가지 한계를 인지하고 기록한다.

(a) **단일 dataset family 에 대한 제한된 외적 타당성.** 4/16~17 보강 측정으로 deep 96d (1M, 8M) + sift 128d (1.5M) 의 두 데이터셋 family 에서 KM20 효과가 재현되었으나, 차원 96~128 의 좁은 영역에 한정된다. 768 차원 wiki 데이터셋 ([part_wiki_10](#)) 은 최종발표 W5 에 검증한다.

(b) **Mid-selectivity 의 5-seed CI 보충 결론.** DEEP 1M 은 5 selectivity 중 50%/30%/10% 에서 5-seed CI 를 확보하였으나, 5% 와 1% 는 단일 seed 측정에 그쳐 CI 가 없다. SIFT 1.5M 도 50%/5%/1% 의 3 구간만 5-seed 로 측정되었고 10% 와 30% 의 mid-selectivity 는 서버의 D_target 재계산 경로에서 `unrecognized node type` 오류가 발생하여 미측정 상태이다. 본 오류는 Adaptive Sampling 의 내부 노드 식별 자료구조와 보조 스크립트의 인터페이스 불일치로 보이며, 최종발표 W5 의 per-stratum BERNOULLI 최적화 작업에 부수하여 해소할 예정이다. 본 결론이 §4.10 의 gradient 비단조성 해석에 불확실성을 남긴다는 점은 명시한다.

(c) **Phase 7 의 경계 조건 명시.** Phase 7 의 8M / sift 128d 확장에서 D_target 을 재계산하지 않아 actual selectivity 가 약 0.0001 로 이동했으며, 초기 plan_rows 기반 q-error (2168× / 409×) 는 stratum LIMIT 상수 artifact 로 확정되어 철회되었다. 이후 D_target 을 각 데이터셋별로 재계산한 §4.8 의 재측정에서 DEEP 8M 은 1M 과 CONSISTENT, SIFT 는 DEEP 대비 2 배 효과로 정상 selectivity 영역에서의 외적 타당성이 회복되었다. 남은 한계는 $s \geq 0.050$ 에서만 층화 샘플링 효과가 안정적으로 발현되며, 그 이하 selectivity 는 Exqutor 기본 sample_size=385 의 구조적 하한에 의해 boundary condition 으로 분류된다는 점이다. 최종발표 W5 에서 per-stratum BERNOULLI 최적화 + sample_size 조정 sensitivity 실험으로 하한 완화 여지를 탐색한다.

(d) **vector.c 의 단일 테이블 hook 우회 수정의 reviewer 관점 위험.** 본 팀의 측정은 `vector.c` line 243 의 `if (table_count > 2)` 를 `if (table_count >= 1)` 로 한 줄 수정한 상태에서 수행되었으며, 변경된 binary 와 원본 백업을 모두 보존해 검증 가능하게 만들어두었다. 그러나 이 변경 자체가 Exqutor 의 design intent 를 임의로 patch 한 것으로 보일 위험이 있어, 본 팀은 멘토 자문 이메일에서 이를 직접 질의하고 narrative 톤 조정 권고를 요청했다 (회신 수령 후 §2~§4 서술에 반영 예정).

본 네 가지 한계 외에 본 연구의 측정 자체가 가진 정량적 약점은 §4 의 각 절에서 honest 하게 기록되었으며, Phase 5 의 8 지표 negative result 는 부정 결과로서 motivation 의 한 축으로 직접 편입되었다.

6. 남은 작업 — 최종발표 (5/27) + 최종보고서 (6/11) 까지

본 팀은 4 월 28 일 중간발표 직후부터 6 월 11 일 최종보고서 제출까지의 4 주를 W5~W8 로 분할해 다음과 같이 수행한다. 자세한 세부 작업과 리스크 대응은 `plans/연구재설계안_20260415_131400.md` §VI 과 `plans/RQ3설계안_20260416_213500.md` 에 정리되어 있다.

W5 (4/28~5/4) — 최적화 + Layer sweep + wiki 768d 검증. 첫째, 현재 STRAT 의 `ORDER BY random()` LIMIT 의 BERN 대비 11 배 비용을 per-stratum `TABLESAMPLE BERNOULLI` 로 교체하여 2 배 이내로 줄인다. 둘째, Layer 후보 4 종 (KM30/40/50, random projection, multi-layer PCA, k-means on float16) 의 selectivity 3 구간 비교로 KM20 유지 또는 전환을 결정한다. 셋째, `part_wiki_10` (768d) 에서 KM20 학습이 empty cluster 없이 동작하는지 사전 검증하고, 실패 시 PCA 96d 축소 또는 100K subset 으로 fall-back 한다. 넷째, SIFT 1.5M 의 mid-selectivity ($s=0.100, 0.300$) 와 sample_size sensitivity 실험으로 §5.2(b) 의 결론을 해소하고 $s \geq 0.050$ boundary 의 완화 여지를 탐색한다.

W6 (5/5~5/11) — 3 dataset × 3 mode × 6 sel × 10 seed × 500 query 전면 ablation. 본 주차의 핵심 결과는 최종보고서의 main result table 이 된다. 예산 계산은 270,000 측정 × query 당 1~2 초 = 75~150 시간 으로, W5 의 per-stratum BERN 최적화 적용 시 약 25 시간으로 단축되어 주말 + 주중 야간 분할 수용이 가능하다. 결과 분석과 시각화 1 차도 본 주차 말에 착수한다.

W7 (5/12~5/18) — RQ3 Distribution-Agnostic 7-way 비교. 분포 무인지 상황에서 사전 학습 없이 공간 인식 효과의 몇 % 를 회수할 수 있는지를 측정하는 Recovery Rate 지표 — $\text{recovery} = (\text{방법X} - \text{RANDOM20}) / (\text{KM20} - \text{RANDOM20})$ — 를 도입하고, 세 가지 패러다임의 7 가지 방법을 체계적으로 비교한다. **Offline Partition** 패러다임은 데이터 로드 시 1 회 계산하는 경량 사전 처리로 A(LSH 랜덤 하이퍼플레인), C(Random Projection · Johnson-Lindenstrauss lemma), E(Hilbert Curve · 공간 DB 의 space-filling 기법을 벡터 카디널리티 추정에 최초 적용), F(Mini-batch K-means · 1~5% 데이터만으로 근사 학습) 의 4 종을 포함한다. **Online Query-Adaptive** 패러다임은 쿼리 시점에 pilot sample 로 동적 적응하는 방식으로 G(Distance-Shell · 쿼리 벡터 중심 동심원), B(KDE-pilot · Neyman 최적 배분) 의 2 종을 포함하며, **Weight-based** 패러다임은 파티션 없이 가중치로 분산을 감소시키는 H(Importance Sampling) 의 1 종을 포함한다.

방법	패러다임	기대 Recovery	사전 학습	구현 난이도
C. Random Projection	Offline	10~40%	사영 1회	하
A. LSH	Offline	30~60%	해시 1회	중
E. Hilbert Curve	Offline	20~60%	index 1회	중
F. Mini-batch K-means	Offline	75~95%	1~5% 데이터	하
G. Distance-Shell	Online	25~50%	불필요	중
B. KDE-pilot	Online	50~80%	불필요	상
H. Importance Sampling	Weight-based	30~70%	불필요	상

7 가지 방법의 차이는 stratum_id 할당 방식뿐이며, 측정 파이프라인 (multiseed_paired, hook_est 파싱, paired Wilcoxon) 은 RQ2 에서 완성된 것을 재활용한다 (H 만 hook_est 반환 공식을 가중 평균으로 수정). 핵심 회피 경로는 **Hilbert Curve 의 공간 DB 기법 최초 적용** 으로, 실패하더라도 negative finding 자체가 고차원 벡터에서 space-filling locality 가 붕괴하는 경계를 정량 확인하는 기여를 가진다. RQ3 의 구현 계획, 맹점 점검, 탈락 후보 상세는 [plans/RQ3설계안_20260416_213500.md](#) 에 12 개 대안의 탈락 근거까지 정리되어 있다.

W8 (5/19~5/25) — 최종보고서 + 포스터 + 전시회 데모. 본 중간보고서를 확장 + Phase 7 후속 결과 + RQ3 결과 반영하고, 포스터 제작 (Phase 6 Step 4 의 s=0.500 + 5-seed CI 를 hero figure 로 배치, Two-Level 분해와 Recovery Rate 결과 병기), 전시회 데모 스크립트 (Exqutor 기본 vs Pivot A vs Pivot C 세 경로 실시간 시연), 팀 내부 리허설 2 회를 완료한다.

본 4 주 로드맵의 세 가지 리스크 — (R1) 측정 시간 폭발, (R2) wiki 768d k-means 재학습 실패, (R3) RQ3 고차원 locality 붕괴 — 각각에 대한 fall-back 경로는 v4 수정 설계안과 RQ3 설계안에 정리되어 있다.

7. 일정 및 역할 분담

본 팀은 4월 14일 단독 결정에 따라 환경 세팅 (4/13 수령, 4/14 빌드 완주) 직후의 **맥락 단일화 + 도구 확보 + 공동 계정 충돌 방지**의 세 근거에서 출발하여 RQ1/2/3 실험 설계·실행·분석·시각화·문서 초안 작성을 조현빈이 전담하고 멘토 자문·보고서 구성 조율을 박세은 (팀장) 이 담당하도록 합의하였다. 4월 17일 overnight 진행 이후 실험·보고서·발표 초안이 모두 갖춰지면서 발표 분담이 다음과 같이 확정되었다. **강재현이 중간발표 주 발표자로서 슬라이드 15 장 전체 (표지~부록) 를 전담**하고, 조현빈은 발표자용 기술 맥락 문서·예상 Q&A 답변지·실험 수치 재현 백업을, 박세은 팀장은 전체 조율과 자문 회신 관련 Q&A 대응을, 이동욱은 슬라이드 시각 검토 (오타자·레이아웃·해상도) 와 리허설 청중 피드백·제출 파일 무결성 점검을 담당한다. 본 분담은 4월 22일 1차 팀 리뷰·4월 24일·26일 리허설 2회 (최소) 를 거쳐 4월 28일 중간발표에 적용된다.

담당	역할
박세은 (팀장)	전체 조율 / 멘토 자문 대응 / 자문 회신 Q&A / 자문내역서·지도확인서 수령·제출
조현빈	RQ1/2/3 실험 설계·실행·분석·시각화·초안 / 발표 기술 백업 (Q&A 답변지·수치 재현·기술 맥락 문서)
강재현	중간발표 주 발표자 (Slide 1~15 전담) / 리허설 주도
이동욱	슬라이드 시각 검토 (오타자·레이아웃·해상도) / 리허설 청중 피드백 / 제출 파일 무결성 점검

일정	핵심 작업
4/14 화	환경 빌드 완료 + RQ1 Phase 1~6 Step 4 완주
4/15 수	RQ1 Phase 7 (sf10 8M + sift 128d) 완주 + 자문 이메일 발송 준비
4/16 목	5-seed 반복 + SIFT/8M D_target 재계산 + Two-Level 분해 + HHI/CV
4/17 금	통합 실험 결과 정리본 + 중간보고서 v2
4/17~21	자문 결과 narrative 반영 + v2 수정
4/22 화	1차 팀 리뷰 라운드
4/24 목	2차 팀 리뷰 + 1차 리허설
4/26 토	2차 리허설
4/28 화	★ 중간발표 + 중간보고서 제출
4/28~5/4	W5: 최적화 + Layer sweep + wiki 검증 + SIFT mid-sel 보충
5/5~5/11	W6: 3 dataset × 3 mode × 6 sel 전면 ablation (500 query × 10 seed)
5/12~5/18	W7: RQ3 Recovery Rate 7-way 비교
5/19~5/25	W8: 최종보고서 + 포스터 + 전시회 데모
5/27~5/29	최종발표 + 전시회 마감
6/5	전시회
6/11	★ 최종보고서 제출

8. 결론

본 중간보고서는 4 월 14 일 ~ 17 일의 RQ1 Motivation + RQ2 본선 (Phase 1~7 및 4/16~17 보강 측정) 의 정량 결과를 종합한다. 4 월 3 일 합의의 큰 골격 (Exqutor Adaptive Sampling 의 정확도 한계를 데이터로 드러내고 두 트랙으로 sanitize 한다) 은 그대로 유지된 채, RQ1 의 측정 정의가 8 지표 negative result + 5 design constraint finding 으로 정교화되었고, RQ2 의 본선이 Pivot A (BERNOULLI 한 줄 교체) + Pivot C (data-side KM20 stratified native 구현) 의 직교 병합 노선으로 재정의되었다.

RQ2 본선의 유효 anchor 는 단일 Phase 6 Step 4 의 $s=0.500 \pm 1.81\%$ $p=4.01e-05$ 에서 **5-seed CI 로 확정된 3 데이터셋 결과 집합** 으로 승격되었다. 구체적으로 (i) DEEP 1M 에서 $s=0.500/0.300/0.100$ 세 구간이 모두 95% 신뢰구간 하한이 양수 $[+1.11, +1.45, +0.72]$ 로 확정되었고, (ii) DEEP 8M 에서 $s=0.500$ CI $[+0.65, +2.86]$ 이 1M 의 $[+1.11, +2.18]$ 과 겹쳐 규모 불변성이 확인되었으며, (iii) SIFT 1.5M 에서 $s=0.500$ CI $[+2.66, +3.48]$ 이 DEEP 과 겹치지 않아 더 쏠린 분포에서 효과가 2 배로 정량 확대됨이 확인되었다. 추가로 Two-Level Decomposition 분석에서 KM20 개선분을 비례 배분 (Level 1) 과 공간 인식 (Level 2) 으로 분해하였으며, DEEP 1M $s=0.010$ 에서 Level 2 가 단독으로 $+19.60\%$ 를 기여함을 확인하여 본 연구의 핵심 가설 — "데이터의 쏠림이 클수록 공간 인식 샘플링의 가치가 크다" — 가 인과적으로 뒷받침되었다. 클러스터 분포의 HHI/CV 정량화는 SIFT 의 CV 가 DEEP 대비 68% 높다는 사실이 KM20 효과의 2 배 격차의 직접 원인임을 데이터로 확증한다.

Phase 7 의 초기 외적 확장 시도에서 발견된 plan tree artifact 는 철회되었으며, D_target 재계산 후의 정상 selectivity 재측정으로 외적 타당성이 회복되었다. 남은 경계 조건은 $s \geq 0.050$ 에서만 총화 샘플링 효과가 안정적으로 발현된다는 것이며, 이는 Exqutor 기본 sample_size=385 의 구조적 하한의 결과로 최종발표 W5 의 sample_size sensitivity 실험에서 완화 여지를 탐색한다. 본 중간보고서 시점의 네 가지 한계 — 단일 dataset family / mid-selectivity CI 결손 / selectivity 하한 / **vector.c** 우회 수정의 reviewer 관점 위험 — 는 W5~W8 로드맵에서 체계적으로 해소되며, RQ3 의 Recovery Rate 7-way 비교는 Pivot C 의 자연스러운 확장 경로로 W7 에 합류한다.

본 연구의 학술적 명제는 다음과 같이 좁고 정확하다.

본 연구는 Exqutor 가 자신의 multi-table only design intent 로 배제한 단일 테이블 vector range query 사각지대를 두 단계로 분석하고 개선한다. 첫째 단계는 finding 제시 (Hook trigger 사각지대 + plan replacement 부작용 + query feature 사전 식별 불가능성) 이며, 둘째 단계는 개입 측정 (**TABLESAMPLE SYSTEM** 의 block bias 를 BERNOLLI 한 줄 교체로 sanitize, naive uniform sampling 을 data-side k-means $K=20$ stratified 로 sanitize) 이다. 두 sanitize 의 정확도 이득은 직교 ablation 으로 분리 측정되며, 본 중간 보고서 시점에서 Phase 4 (4 구간 $p<0.001$) + Phase 6 Step 4 의 5-seed CI (3 데이터셋 / 3 selectivity 구간) + Two-Level 분해 (Level 2 단독 $+19.60\%$) 의 복수 유효 anchor 를 확보했다. 더 쏠린 SIFT 1.5M 에서 KM20 효과가 DEEP 의 2 배로 확대됨을 HHI/CV 정량 지표로 인과적으로 설명하였으며, Phase 7 의 boundary 조건 ($s \geq 0.050$) 은 Pivot C 의 효과 범위를 정량적으로 확정하는 학술적 기여를 가진다. 최종 보고서 단계의 RQ3 Recovery Rate 프레임워크는 분포 무인지 상황에서 공간 인식 효과의 회수율을 7 가지 방법으로 체계적으로 비교한다.

참고 문헌

- Park, S. et al. *Exqutor: Extended Query Optimizer for Vector-augmented Analytical Queries*. arXiv:2512.09695v2, 2024.
- Haas, P. J. and Stokes, L. *Estimating the number of classes in a finite population*. JASA 1998.

- Lipton, R. J., Naughton, J. F., and Schneider, D. A. *Practical selectivity estimation through adaptive sampling*. SIGMOD 1990.
- Sculley, D. *Web-scale k-means clustering*. WWW 2010.
- Horvitz, D. G. and Thompson, D. J. *A generalization of sampling without replacement from a finite universe*. JASA 1952.
- Indyk, P. and Motwani, R. *Approximate nearest neighbors: towards removing the curse of dimensionality*. STOC 1998.
- Johnson, W. B. and Lindenstrauss, J. *Extensions of Lipschitz mappings into a Hilbert space*. Contemporary Mathematics 1984.
- Faloutsos, C. and Roseman, S. *Fractals for secondary key retrieval*. PODS 1989 (Hilbert curve indexing).
- Silverman, B. W. *Density Estimation for Statistics and Data Analysis*. Chapman and Hall 1986 (KDE bandwidth).
- (RQ3 단계에서 추가) Latin Hypercube Sampling 관련: McKay, M. D., Beckman, R. J., and Conover, W. J. *Technometrics* 1979.

층화 샘플링 고전 (Two-Level Decomposition 의 수학적 기초): - Neyman, J. *On the Two Different Aspects of the Representative Method: The Method of Stratified Sampling and the Method of Purposive Selection*. Journal of the Royal Statistical Society 1934 — 본 연구 Level 1 (proportional allocation) · Level 2 (optimal allocation) 분해의 수학적 기초. - Cochran, W. G. *Sampling Techniques* (3rd ed.). Wiley 1977 — 층화 샘플링 · Horvitz-Thompson 가중 추정의 교과서 참조.

DB 층화 샘플링 (Pivot C 포지셔닝): - Acharya, S., Gibbons, P. B., Poosala, V., and Ramaswamy, S. *Congressional Samples for Approximate Answering of Group-By Queries*. SIGMOD 1999 — DB 에서의 층화 샘플링 본격 도입. - Chaudhuri, S., Das, G., and Narasayya, V. *A Robust, Optimization-Based Approach for Approximate Answering of Aggregate Queries*. SIGMOD 2001 — stratified AQP 의 견고성 분석. - Babcock, B., Chaudhuri, S., and Das, G. *Dynamic Sample Selection for Approximate Query Processing*. SIGMOD 2003 — 쿼리 시점 동적 층화. - Agarwal, S. et al. *BlinkDB: Queries with Bounded Errors and Bounded Response Times on Very Large Data*. EuroSys 2013 — stratified sampling 의 운영 DB 스케일링 사례.

벡터 DB·ANN (Exqutor 경쟁 포지션): - Wang, J. et al. *Milvus: A Purpose-Built Vector Data Management System*. SIGMOD 2021. - Chen, Y. et al. *SPFresh: Incremental In-Place Update for Billion-Scale Vector Search*. SOSP 2023 — IVF partition 의 INSERT 대응. - Yang, Z. et al. *NeuroCard: One Cardinality Estimator for All Tables*. VLDB 2020 — learned cardinality estimation 의 비교 baseline.

등가성 검정 및 다중 비교 (CONSISTENT 판정 · W6 계획 근거): - Schuirmann, D. J. *A Comparison of the Two One-Sided Tests Procedure and the Power Approach for Assessing the Equivalence of Average Bioavailability*. Journal of Pharmacokinetics and Biopharmaceutics 1987 (TOST) — CI overlap 대신 사용할 공식 equivalence test. - Benjamini, Y. and Hochberg, Y. *Controlling the False Discovery Rate: a Practical and Powerful Approach to Multiple Testing*. JRSS-B 1995 — multiple testing 의 BH-FDR 보정 (W6 에 full ablation 의 110+ 검정에 적용 예정). - Cohen, J. *Statistical Power Analysis for the Behavioral Sciences* (2nd ed.). Lawrence Erlbaum 1988 — 효과 크기 (Cohen's d) · 검정력 분석 참조.

부록 — 참조 문서

- [plans/archive/연구설계안_20260403_162818.md](#) — v3 원안 (4/3 교수님 미팅 후)
- [plans/연구재설계안_20260415_131400.md](#) — v4 수정본 (4/15)
- [plans/RQ3설계안_20260416_213500.md](#) — RQ3 Distribution-Agnostic 7-way 설계안 (4/16)
- [experiments/results/RQ1_RQ2 실험 결과 정리.md](#) — 4/17 통합본 (RQ1/RQ2 전체 진실 소스, 291 줄)
- [experiments/results/rq1_motivation/summary.md](#) — Phase 1~6 측정 상세 (717 줄)
- [experiments/results/rq1_motivation/direction_pivot_rationale.md](#) — 4/14 pivot narrative (187 줄)
- [experiments/results/rq1_motivation/equivalence_check.md](#) — Stage 4.5 수학적 동치 검증
- [experiments/results/rq1_motivation/phase7*_paired_qerror.json](#) — Phase 7 paired 결과
- [experiments/results/rq1_motivation/phase7_artifact_verification_20260415.md](#) — artifact 공식 기록
- [experiments/results/rq2_aware/sift_1m_mid_summary.json](#) — SIFT/DEEP mid-sel 5-seed
- [experiments/results/rq2_aware/8m_km20_s0500_5seed.json](#) — DEEP 8M s=0.500 5-seed
- [experiments/results/rq2_aware/cluster_distribution.md](#) — HHI/CV 정량
- [experiments/results/rq2_aware/anomaly_analysis.md](#) — Anomaly 3건 구조적 설명
- [experiments/figures/rq1_motivation/figure_{1..6}.png](#) — Stage 5b 시각화 6 종
- [experiments/figures/rq2_aware/figure_{7..10}.png](#) — 4/17 추가 시각화 4 종
- [submission/속도는벡터_자문이메일_20260415.md](#) — 멘토 자문 이메일
- [submission/속도는벡터_중간발표_20260417_0000.md](#) — 중간발표 슬라이드 구조 md