

# [속도는 벡터] 연구 진행 경과 보고 및 2차 자문 요청

---

멘토님 안녕하십니까, 연세대학교 캡스톤 디자인 속도는벡터 팀입니다.

3월 25일 1차 자문에서 데이터셋 선정, 대조군 설정, 평가 지표 구체화에 대해 조언해주신 이후로 연구가 꽤 진전되어, 현재까지의 경과를 공유드리고 몇 가지 방향에 대해 자문을 구하고자 합니다.

---

## 연구 경과

1차 자문 이후 멘토님 조언에 따라 데이터셋은 TPC-H SF10 + DEEP 96d/SIFT 128d 벡터를 사용하고 있고, Q-error(추정 행 수 대비 실제 행 수의 비율)와 paired Wilcoxon 검정을 주요 평가 도구로 쓰고 있습니다.

4월 3일 교수님 지도 미팅에서 Exqutor 논문(arXiv:2512.09695v2)의 sampling 방식 자체를 개선하는 방향으로 연구를 좁혔습니다. 교수님께서 제시해주신 틀은 "데이터가 공간적으로 쏠려 있으면 uniform sampling의 추정 정확도가 떨어지니, 이를 개선하자"입니다.

이 틀에 맞춰 아래 세 단계로 실험을 진행했습니다.

### Step 1 — 데이터의 공간적 쏠림 확인

k-means(K=20)로 100만 건의 벡터를 클러스터링한 결과, 클러스터 크기가 2.6만~8.1만 건으로 약 3배 차이가 났습니다. 데이터가 고르게 분포하지 않고 특정 영역에 몰려 있는 것을 확인했습니다.

### Step 2 — 쏠림이 추정 정확도를 실제로 떨어뜨리는가

이 부분이 저희 실험의 핵심 결과입니다. 같은 층화 샘플링을 두 가지 파티션으로 비교했습니다. 하나는 k-means 파티션(KM20, 공간 구조 반영), 다른 하나는 무작위 파티션(RANDOM20, 공간 구조 무시)입니다.

쿼리 범위가 넓을 때(전체의 50%)는 두 방식의 차이가 거의 없었는데, 쿼리 범위가 좁아질수록(전체의 1%) 격차가 벌어졌습니다. 구체적으로 전체의 1% 범위에서 KM20은 기존 대비 +8.93% 개선, RANDOM20은 오히려 -10.67% 악화되어 차이가 19.6%p에 달했습니다. 두 결과의 95% 신뢰구간이 완전히 분리되어, 공간 구조를 아는 파티션만이 좁은 범위 쿼리에서 개선 효과를 낸다는 것을 확인했습니다.

### Step 3 — 공간 인식 sampling으로 개선

KM20 기반 층화 샘플링을 Exqutor 소스에 직접 구현하여, 기존 무작위 샘플링 대비 5-seed 평균 +1.64%(95% CI [1.25%, 2.02%])의 추정 정확도 개선을 확인했습니다.

---

## Two-Level Decomposition

Step 2의 RANDOM20 대조 실험을 통해, 층화 샘플링의 개선 효과가 두 가지 경로로 작동함을 알게 되었습니다.

첫째는 비례 배분(proportional allocation) 효과입니다. 기존 무작위 샘플링은 각 행을 독립적으로 추출하므로 표본 크기 자체가 확률적으로 흔들리는데, 층화 샘플링은 각 층에서 정확히 비례 배분하므로 표본 크기가 안정됩니다. 이 효과는 파티션 품질과 무관하게 보편적으로 나타납니다.

둘째는 공간 인식(spatial awareness) 효과입니다. 쿼리 결과가 소수 클러스터에 집중되는 상황(좁은 범위 쿼리)에서, 해당 클러스터를 제대로 아는 파티션이 추가 이점을 제공합니다. 전체의 1% 범위에서 KM20과 RANDOM20의 극단적 차이가 바로 이 효과입니다.

## 현재 한계와 후속 계획

100만 건 DEEP 96d에서 확인한 결과를 800만 건, 다른 벡터 종류(SIFT 128d)로 확장하는 실험을 현재 진행 중입니다. 이전에 800만 건으로 외적 타당성 검증을 시도했으나 거리 임계값 설정이 미흡하여 의미 있는 결과를 얻지 못했는데, 이를 수정하여 재측정하고 있습니다.

중간 발표까지 RQ1(문제 제기)과 RQ2(개선 방안)를 다루고, 최종 발표에서 RQ3(분포를 사전에 모를 때의 자동 층화) 또는 RQ2 고도화를 다룰 계획입니다.

## 자문 요청

세 가지에 대해 멘토님의 판단을 여쭙고 싶습니다.

첫째, 연구 시나리오를 원논문의 다중 테이블 조인에서 단일 테이블 벡터 범위 쿼리로 좁힌 것이 학술적으로 타당한지 궁금합니다. Exquitor 소스 분석에서 단일 테이블 쿼리에 대한 처리 경로 누락 등 4가지 설계 제약을 발견한 것이 전환 근거인데, 이 근거가 충분한지 멘토님의 의견을 듣고 싶습니다.

둘째, RANDOM20 대조 실험으로 비례 배분 효과와 공간 인식 효과를 분리한 것(Two-Level Decomposition)이 학술적 기여로서 가치가 있는지 판단을 구합니다. 벡터 데이터 카디널리티 추정 맥락에서 이 두 효과를 분리한 사례를 찾지 못해, 분해 자체가 기여가 될 수 있다고 생각하고 있습니다.

셋째, 중간 발표의 핵심 메시지를 RANDOM20 대조 실험 결과(19.6%p 차이)로 잡을지, 실제 구현의 +1.64% 개선을 중심으로 잡을지 고민 중입니다. 교수님의 "솔림→성능저하→개선" 프레이밍에는 전자가 더 직결되는 것 같은데, 어느 쪽이 설득력 있을지 조언 부탁드립니다.