

소프트웨어종합설계
연구지도 확인서

팀 명	속도는 벡터
지도교수	박광현 교수님
연구주제	Query Optimizer for Vector Database
회차	8 회차
지도일	2026년 5월 8일

팀원 인적사항 및 지도교수 서명					
구분	성명	학과	학번	학년	지도교수 서명
팀장	박세은	컴퓨터과학과	2023148086	4	
팀원	강재현	컴퓨터과학과	2019147573	4	
팀원	조현빈	컴퓨터과학과	2019147551	4	
팀원	이동욱	컴퓨터과학과	2023148048	4	

내용
중간 발표 이후 기존 실험 결과를 바탕으로 추가 실험 방향을 정리하고, 데이터셋 규모와 sampling 방법에 대한 실험 범위를 조정하였다. 우선 데이터셋은 Scale Factor 1과 Scale Factor 10을 중심으로 실험을 진행하기로 하였다. 이를 통해 지나치게 많은 규모로 실험을 확장하기보다, 두 규모에서 관찰되는 경향을 비교하고 결과를 안정적으로 정리하는 방향으로 연구 범위를 설정하였다. 데이터셋 분포를 알고 있는 상황에서는 기존에 적용했던 row 단위 sampling과 k-means 기반 sampling에 더해, Neyman allocation 방식을 추가로 실험하였다. Neyman allocation은 각 클러스터에 같은 수의 샘플을 배정하는 방식이 아니라, 클러스터 내부의 분산이 큰 경우 더 많은 샘플을 할당하는 방식이다. 이를 통해 단순히 데이터를 클러스터로 나누는 것뿐 아니라, 클러스터별 특성을 반영한 샘플 배분이 cardinality 추정 정확도 개선으로 이어지는지 확인하고자 하였다. 실험 결과, skew가 큰 데이터셋의 작은 selectivity 구간에서는 Neyman allocation을 적용했을 때 일부 성능 개선이 나타났다. 이는 데이터가 특정 영역에 치우쳐 있고 검색 범위가 좁은 경우, 클러스터별 분산을 고려한 샘플 배분이 도움이 될 수 있음을 보여준다. 다만 모든 데이터셋과 selectivity 구간에서 일관되게 성능이 개선되지는 않았으므로, Neyman allocation을 일반적으로 항상 우수한 방식으로 보기보다는 특정 조건에서 효과가 나타나는 보완적 방법으로 해석하는 것이 적절하다고 판단하였다. 또한 데이터셋 분포를 사전에 알기 어려운 상황에 대해서는 본 실험에 사용할 후보 방법들을 조사하였다. 현재 MiniBatch K-means, HDBSCAN, Hilbert curve, Random Projection, LSH, Sobol/Halton 등을 후보로 정리하였다. 이 방법들은 분포 정보를 직접 알고 있다고 가정하지 않고도 데이터의 구조를 근사적으로 반영할 수 있는 방법들이다. 향후에는 각 방법을 실제 실험에 적용하여 cardinality 추정 오차 개선 정도를 비교하고, 성능뿐 아니라 학습 비용과 실제 시스템 적용 가능성도 함께 검토할 예정이다. 정리하면, 중간 발표 이후에는 데이터셋 규모를 Scale Factor 1과 10으로 설정하고, 분포를 알고 있는 경우에는 Neyman allocation을 추가로 검증하였으며, 분포를 모르는 경우에 사용할 sampling 후보 방법들을 조사하였다. 이후 연구는 후보 방법들의 실제 성능을 비교하고, 기존 방식 대비 어떤 조건에서 개선 효과가 나타나는지 정리하는 방향으로 진행할 예정이다.