


소프트웨어종합설계

연구지도 확인서

팀 명	속도는 벡터
지도교수	박광현 교수님
연구주제	Query Optimizer for Vector Database
회차	9 회차
지도일	2026년 5월 15일

팀원 인적사항 및 지도교수 서명					
구분	성명	학과	학번	학년	지도교수 서명
팀장	박세은	컴퓨터과학과	2023148086	4	
팀원	강재현	컴퓨터과학과	2019147573	4	
팀원	조현빈	컴퓨터과학과	2019147551	4	
팀원	이동욱	컴퓨터과학과	2023148048	4	

내용
이번 주 연구지도에서는 기존 실험 방향을 재검토하고, 프로젝트의 문제 정의를 수정하였다. 기존에는 데이터 분포를 "알고 있는 경우"와 "모르는 경우"로 구분하여 샘플링 방법을 비교하려 하였으나, 실제 시스템 환경에서는 이러한 이분법적 구분이 적절하지 않다는 점을 논의하였다. 이에 따라 데이터셋이 입력되면 먼저 분포 특성을 빠르게 파악하고, 그 결과에 따라 적합한 샘플링 방식을 선택하는 방향으로 연구 흐름을 조정하였다. 구체적으로는 입력 데이터셋의 벡터 공간상 분포를 낮은 비용으로 진단하는 방법을 검토하기로 하였다. 이 과정에서는 기존에 분포를 모르는 상황에서 고려했던 k-means 기반 클러스터링, 차원 축소, random projection, 공간 분할 계열의 방법 등을 활용할 수 있다. 이 단계의 목적은 데이터 분포를 정밀하게 추정하는 것이 아니라, 데이터가 비교적 균일한지, 특정 영역에 집중되어 있는지, 또는 여러 군집으로 나뉘는지 등을 빠르게 파악하는 데 있다. 이후에는 파악된 분포 특성을 바탕으로 데이터셋을 2~3가지 유형으로 분류하고, 각 유형에 적합한 샘플링 방식을 제안하는 방향으로 실험을 재구성할 예정이다. 예를 들어 비교적 균일한 분포에서는 row-level random sampling이 충분히 효과적일 수 있으며, 데이터가 특정 영역에 몰린 경우에는 cluster 기반 stratified sampling이 더 적합할 수 있다. 또한 군집별 분산이나 selectivity에 따라 샘플 할당 방식을 조정하는 방법도 조건부 선택지로 함께 검토한다. 따라서 향후 연구는 "분포를 아는 경우와 모르는 경우의 비교"가 아니라, "분포를 빠르게 진단하고, 진단 결과에 따라 샘플링 전략을 선택하는 적응형 샘플링 방식"을 중심으로 진행한다. 이를 통해 Exqutor의 기존 block-level random sampling 방식이 데이터 분포에 따라 한계를 가질 수 있음을 보이고, 분포 특성을 반영한 샘플링 전략이 카디널리티 추정 정확도를 개선할 수 있는지 분석할 계획이다.