

Skew-Aware Stratified Sampling 을 이용한 Vector Cardinality 추정 정확도 개선 연구

Table of Contents

01

Problem

Vector Cardinality Estimation: Blind Spots

02

Background

Exqutor: Methods & Limits

03

Our Approach

Skew-Aware/Unaware Sampling

04

Experiments

RQ1·RQ2·RQ3: Design / Results

05

Plan

Current progress & Future plans

1. Problem

벡터 range 조건의 선택도는 query마다 크게 달라지지만, 기존 optimizer는 벡터 공간 분포를 반영하지 못한다.

기존 시스템 — 고정 비율 추정

pgvector

fixed estimator

33.3%

VBASE

fixed estimator

50.0%

DuckDB

scan all rows

100%

실제 — Query마다 달라지는 분포

- 실제 선택도는 query에 따라 0.001% ~ 100%의 광범위한 분포
- 잘못된 cardinality 추정 → join, index 유무, scan 전략 선택 왜곡 (비효율적 실행 계획)

고정 비율 추정으로는 query-dependent vector selectivity를 설명할 수 없다.

2-1. Background — Exqutor의 방법론

ECQO(Exact Cardinality Query Optimization)

HNSW 인덱스가 있을 때

실행 계획 단계에서 HNSW range query를 직접 실행하여
정확한 Cardinality 산출

1~2 ms

단시간 내 정확한 Cardinality 획득

Adaptive Sampling

HNSW 인덱스가 없을 때

— 모멘텀 기반 동적 uniform sampling
Sample size를 조금씩 늘려가며 Cardinality를 근사

~3.2x

No index VAQ 성능 개선

→ No-index sampling path에서 uniform sample이 skewed vector distribution을 대표할 수 있는가?

HNSW: 고차원 벡터 데이터에서 유사도가 가장 높은 이웃을 빠르게 찾는 그래프 기반의 최근접 이웃(ANN) 검색 알고리즘

2-2.Background — Adaptive Sampling의 한계

#1

Hook Trigger에 의한 AS 적용 범위 누락

table_count > 2 조건으로 single vector table range query는 AS 미진입 → pgvector default selectivity 1/3 로 fallback

#2

단순 Gate Relaxation 불가

Hook 조건 완화 시 추정용 Tablesample이 실제 실행 plan에 반영
SELECT count(*)의 결과가 전체 테이블 기준이 아니라 sample기준으로 계산.

#3

Block-level sampling bias

System sampling은 page/block 단위 추출
→ Row-level uniform sample을 보장하지 못해 skewed vector space에서 대표성 저하

vector.c — Hook Trigger 사각지대 (line 243)

vector.c (Exqutor adaptive sampling hook)

Pivot A — Hook trigger (line 243)

```
- if (table_count > 2)
+ if (table_count >= 1)

# 2-way join 부터 hook 활성화 → 단일 테이블 query 에도 주입
```

Pivot B — Sampling method (line 889)

```
- TABLESAMPLE SYSTEM(%f)
+ TABLESAMPLE BERNOULLI(%f)

# 블록 단위 SYSTEM → 행 단위 BERNOULLI 로 교체 (skew 내성 +)
```

Pivot C — Stratified sampling branch

```
- (no stratification logic)
+ +228 lines: KM20 strata read -> per-stratum BERNOULLI -> HT aggregate

# skew 을 명시적으로 활용하는 층화 추정 경로 추가 (합산/분산 추정 포함)
```

★ 단일 테이블 range query에 적용하려면, 실행 plan을 바꾸지 않는 estimation-only sampling 경로가 필요하다.

3. Our Approach — Skew-Aware Sampling

기존 연구

Uniform Adaptive Sampling

차별성

원인 분리 및 독립 측정

제안

Skew-aware Stratified Sampling

✦ 본 연구는 block bias를 제거한 뒤 skewed vector space에서 sample allocation을 재설계한다.

핵심 기여

- Target: 단일 테이블 vector range query의 no-index sampling path
- Decomposition & Method: block-level sampling bias/spatial skew 문제 분리
- SYSTEM → BERN → KM20
- Validation: RANDOM20 / Two-Level 분해로 spatial-aware 효과 정량화

4-1. RQ1 — Query-side Skew지표는 Q-error를 설명하지 못했다


실험 셋업

데이터셋	DEEP 1M subset · 96d
쿼리	100 query × 6 selectivity × 5-seed = 3000
지표 (글로벌)	Fisher γ , tail ratio, P99/P50, skewness
지표 (로컬)	k-NN entropy, PCA EVR1, KDE modality, NN clustering

주요 발견

- ① 글로벌, 로컬 지표 모두 Q-error와 안정적인 상관을 보이지 않음
- ② 로컬 4 지표 x 6 selectivity에서 Spearman $|\rho| < 0.2$
- ③ query-side feature만으로 어떤 영역을 더 샘플링해야 할지 결정하기 어려움

Phase 5 Local Skew × Selectivity Spearman ρ



주: $|\rho| \geq 0.2$ 를 strong correlation 임계로 정의. 24 조합 모두 임계 미만 ($n_{\text{strong}} = 0$).
global 24 조합과 합산 시 총 48 조합 모두 $|\rho| < 0.2 \Rightarrow$ Local skew 가 Q-error 의 단일 원인이 아님 (RQ1 Phase 5 negative result).

Phase 5 — 로컬 4 지표 × 6 selectivity = 24 조합 모두 $|\rho| < 0.2$
Local Skew 지표도 Q-error와 약한 상관만 보임


→ Query-side feature만으로 sampling layer를 정하기 어렵다.

4-2. RQ2(1)— Block-level SYSTEM vs Row-level BERN

select	SYS(block)	BERN(row)	diff%	p-value	행 단위 우위
0.001	2.597	2.597	+0.0	0.596	6/8
0.010	1.558	1.299	+20.0	0.240	45/40
0.050	1.203	1.195	+0.7	0.0009	58/37
0.100	1.212	1.132	+7.0	<0.001	66/31
0.300	1.210	1.079	+12.0	<0.001	76/24
0.500	1.153	1.052	+9.6	<0.001	78/22

Takeaways

- ① $s=0.05\sim0.5$ 에서 BERN이 SYSTEM보다 일관되게 낮은 Q-error
- ② $s=0.5$: median Q-error 1.1527
→ 1.0519, +9.6%, 78/100 query 개선
- ③ low selectivity 에서는 true cardinality가 작아 Q-error 변동이 커짐




Phase 4 — SYS vs BERN paired Q-error 4 panel ($s=0.05/0.10/0.30/0.50$)

4-3. RQ2(2)— KM20 Stratified: spatial allocation 추가

selectivity	5-seed 평균	95% CI	유의 seed
50%	+1.64%	[+1.11, +2.18]	5/5
30%	+2.62%	[+1.45, +3.80]	5/5 (p<0.001)
10%	+4.19%	[+0.72, +7.66]	5/5 (p<0.004)
5%	+1.85%	[-0.22, +3.42]	5/5
1%	+8.93%	[+6.59, +10.95]	5/5

BERNOULLI vs STRATIFIED (KM20)




Phase 6 — BERNOLLI vs STRATIFIED (KM20) 100 query

- ① s=0.500에서 KM20은 BERN 대비 +1.64%, 5-seed 95% CI [+1.11,+2.18]
- ② s=0.050, s=0.010에서도 개선 신호는 있으나 일부는 단일 seed / low-cardinality noise로 해석 보류
- ③ KM20의 역할은 sample size 증가가 아니라 vector-space region별 sample allocation 보정

KM20은 vector-space skew를 sample allocation에 반영하는 첫 번째 positive result다.

4-4. External Validity— $s=0.500$ 에서 3개 데이터셋 교차 검증



주: DEEP 1M/8M의 CI는 겹침(외적 재현 CONSISTENT). SIFT의 CI는 DEEP과 겹치지 않아 통계적으로 구별. 윌림도(CV)가 큰 데이터일수록 공간 인식 샘플링의 이점이 더 크게 발현됨.

외적 타당성 — DEEP 1M / 8M / SIFT 1.5M, KM20 $s=0.500$ 효과 95% CI

DEEP 1M (96d)

CI [+1.11, +2.18] · CV 0.234

+1.64%

DEEP 8M (96d)

CI [+0.65, +2.86] · 8x scale validation

+1.76%

SIFT 1.5M (128d)

CI [+2.66, +3.48] · CV 0.394

+3.07%

주요 발견 + 시사점

① DEEP 1M ↔ 8M : CI 겹침 (CONSISTENT)

② SIFT: DEEP보다 더 큰 개선폭.

→ 더 skewed 한 데이터에서 KM20 효과 증가 가능성

③ skewed ↑ ⇒ spatial-aware 가치 ↑

4-5. RQ3(Design)— spatial-unawareness에서의 Recovery Rate

$$\square \text{ Recovery Rate} = (\text{방법X} - \text{RANDOM20}) / (\text{KM20} - \text{RANDOM20})$$

P1 Offline Partition

- Random Projection
- MiniBatch k-means
- Hash partition (LSH)

P2 Online Query-Adaptive

- Distance-Shell sampling
- KDE-pilot

P3 Weight-based

- Importance sampling
- Density-based reweighting

평가 조건

→ DEEP 1M · 8M · SIFT 1.5M 3 데이터셋 × 5-seed × 5 selectivity 동일 조건

★ 목표: 적어도 하나의 저비용 방법이 KM20 효과의 50% 이상을 회수하는지 검증

5-1. Current Progress

W1 ✓	W2 ✓	W3 ✓	W4 ▶
4/4~4/11 환경 인수인계 · 빌드 · Exqutor source / dataset / server 인계 · PostgreSQL + pgvector + Exqutor build · 실험 테이블 및 실행 환경 세팅	4/12~4/19 RQ1 구조분석 + RQ2 본 측정 · Single-table AS branch 비활성 확인 · Forced hook 적용 시 Sample Scan 부작용 확인 · SYSTEM→BERN, BERN→KM20 본 측정 시작	4/20~4/26 외적 타당성 + 원인분석 · DEEP 8M / SIFT 1.5M 교차 검증 · 5-seed 95% CI 산출 · RANDOM20 / Two-Level / HHI / CV 분석	4/27~4/28 중간 산출물 정리 · 중간보고서 최종화 · 발표자료 정리 · 코드·결과 재현 가능 형태로 보존

5-2. 향후 계획

W5	4/29~5/6	RQ2 보강 + RQ3 Offline Pilot	Low-selectivity 구간 반복 실험 보강
W6	5/7~5/13	RQ3 Offline 5-seed	선별된 1~2 방법 5-seed × 3 데이터셋 — Recovery Rate 산출
W7	5/14~5/20	RQ3 Online / Weight-based	Distance-Shell, KDE-pilot 등 query-adaptive 후보
W8	5/21~5/27	민감도 분석 + 최종발표 준비	Sample_size sensitivity, K sweep = 10/20/30/50, BERN 최적화
W9	5/28~6/4	최종발표 + 전시회 준비	Q&A 예상 질문 정리, 발표/포스터 준비
W10	6/5~6/11	최종보고서 작성	RQ1 + RQ2 + RQ3 통합 + 실험 재현 가이드

감사합니다

Q & A

속도는벡터

박세은 (팀장) · 강재현 · 조현빈 · 이동욱