

분포 인지 표본 선택을 통한 카디널리티 추정 개선

Improving Cardinality Estimation through Distribution-Aware Sample Selection

박세은 · 강재현 · 조현빈 · 이동욱

속도는벡터 · 연세대학교 인공지능융합설계 2026

지도 박광현 교수님 (BDAI 연구실)


지도연구원 임채림 · 멘토 박성원 (삼성전자 AI센터)

1 연구 배경



RAG, 멀티모달 검색 등의 확산으로 벡터 유사도 검색과 SQL의 함수가 결합된 VAQ(Vector-Augmented Analytical Query)가 증가하였다.



Vector Search
(벡터 유사도 검색)



SQL Operations
(조인, 필터, 집계)



VAQ

VAQ를 효율적으로 실행하려면 벡터 조건을 만족하는 행 수를 정확히 추정해야 한다. 이를 카디널리티라고 한다.

기존 시스템은 데이터 분포와 무관한 고정 선택도를 사용하여 잘못된 추정을 하고, 이는 비효율적인 실행 계획과 성능 저하로 이어진다.

기존 시스템의 고정 선택도 예시

pgvector
33.3%

VBASE
50%

DuckDB
100%

2 문제점 및 해결방안


벡터 인덱스가 없을 때 Adaptive Sampling이라는 기법을 사용하면, 카디널리티를 고정값으로 사용하는 것이 아닌 표본을 뽑은 후 추정하여 사용하게 된다. 이때 표본 추출 단계를 개선하여 카디널리티 추정을 개선할 수 있는지 탐구하였다.

Research Question

Adaptive Sampling에서 카디널리티 추정을 더 잘 할 수 있는 표본 추출 방식은 무엇인가?


BASELINE

베르누이 기반 추출



NEW

분포 인지 기반 추출




3 연구 방법

5개의 데이터셋과 4개의 조작변인을 기반으로, Adaptive Sampling의 조건을 유지하면서 표본을 뽑는 방법이 주는 영향을 측정하였다. 베르누이 기반의 Baseline, 분포 인지 기반의 Case A, 두 값의 평균을 취한 Case B로 나누어 각 조건에서 Q-error(정확도)와 latency, 최적 계획 선택 비율을 측정하였다.

Baseline


Bernoulli Sampling
무작위 (베르누이)로 표본 선택



추정값 est_b1

분포 인지 기반 추출

Stratified Sampling
데이터 분포 인지 기반 표본 선택



추정값 est_A

결합

Combine
두 추정값의 평균을 취해
안정성과 정확성을 확보

$$\frac{\text{est_b1} + \text{est_A}}{2}$$

Dataset 데이터셋

DEEP (이미지 검색)

SIFT (이미지 특징)

SSN++(이미지 유사도)

YFCC(멀티미디어)

PartSupp PK (TPC-H)

Variables 조작변인

데이터 크기 (1 / 10 / 100)

쿼리 조건 폭 (0.001~0.1)

K-means 클러스터 수
(10~30)

표본 추출 방식 14종

4 연구 결론

Q-error



latency



베르누이 추출과 분포 인지 표본 추출의 평균을 이용하는 결합 방법이 기존 방법과 속도는 동일하면서 더욱 정확하게 추정하였다. 결합 방식은 1508개의 실험 표본 중 1344개의 경우에서 정확도 우위를 보였다.

최적 plan 선택

91/156

baseline

148/156

결합

정확한 카디널리티 추정을 이끌어 결과적으로 빠른 계획을 선택하게 하는 요인인 최적 계획 선택도 결합 방식이 우위를 보였다. 같은 표본 수에서 선택 방식을 베르누이 방식에서 제안한 방식으로 바꾸는 것 만으로 응답 속도를 유지하면서 정확도를 올릴 수 있었다. 특히 결합 방식은 무작위 표본의 안정성과 분포 인지의 정보를 모두 활용하여 좋은 결과를 보여주었다.

소개 동영상

